

# Optimización y Evaluación Comparativa de Métodos Computacionales en Sistema de Predicción del Rendimiento de Cultivos

Por:

Miguel Angel Panqueva Pulido

Andrés Felipe Arias Guevara



**UNIVERSIDAD DISTRITAL  
FRANCISCO JOSÉ DE CALDAS**  
Acreditación Institucional de Alta Calidad

Ingeniería de sistemas

Bogotá D.C.

2025

## **Índice**

<b>1. Resumen</b>	<b>2</b>
<b>2. Introducción</b>	<b>2</b>
<b>3. Planteamiento del problema</b>	<b>3</b>
<b>4. Justificación</b>	<b>3</b>
<b>5. Objetivos</b>	<b>4</b>
5.1 General	4
5.2 Específicos	4
<b>6. Marco referencial</b>	<b>4</b>
6.1 Marco Teórico	4
6.2 Estado del Arte	5
7. Metodología	5
<b>8. Cronograma tentativo</b>	<b>5</b>
<b>9. Recursos</b>	<b>6</b>
<b>10. Resultados esperados</b>	<b>6</b>
<b>11. Referencias bibliográficas</b>	<b>6</b>

## **1. Resumen**

El presente trabajo tiene como propósito realizar un análisis comparativo y optimizado de distintos métodos computacionales aplicados a la predicción del rendimiento agrícola. A partir de un estudio previo desarrollado en MATLAB, donde se implementaron redes neuronales NARX y sistemas difusos, se busca superar las limitaciones identificadas en cuanto a calidad de datos, validación y complejidad de los modelos.

La investigación plantea el uso de conjuntos de datos más completos y diversos, incorporando variables adicionales como humedad del suelo, radiación solar y prácticas de cultivo. Así mismo, se emplearán técnicas de optimización matemática para ajustar de manera eficiente los modelos, garantizando interpretabilidad y escalabilidad.

Se espera obtener una comparación clara entre las distintas técnicas, destacando sus fortalezas y limitaciones, con el fin de aportar al ámbito académico y a la toma de decisiones en la producción agrícola. Los resultados de este estudio contribuirán a fortalecer el uso de la inteligencia computacional en el sector, ofreciendo modelos más robustos, precisos y aplicables en escenarios reales.

## **2. Introducción**

La agricultura continúa siendo uno de los sectores más sensibles a la variabilidad climática, la calidad del suelo y los costos de los insumos. Estas condiciones generan una alta incertidumbre en la planeación y gestión de la producción, lo que plantea la necesidad de contar con herramientas que permitan anticipar escenarios y optimizar la toma de decisiones.

En este contexto, los modelos computacionales se han convertido en una alternativa de gran valor, al ofrecer la posibilidad de predecir rendimientos agrícolas mediante el análisis de variables múltiples y el uso de técnicas avanzadas de inteligencia artificial y optimización. Experimentos iniciales con redes neuronales y sistemas difusos demostraron el potencial de estas metodologías, pero también dejaron en evidencia limitaciones relacionadas con la calidad de los datos y la validación de los modelos.

El presente proyecto busca dar un paso más allá, desarrollando un estudio sistemático y comparativo que incorpore nuevas variables y técnicas de ajuste más rigurosas. Con ello se pretende no solo mejorar la precisión de las predicciones, sino también generar un análisis crítico sobre la aplicabilidad real de cada método en la gestión agrícola. La propuesta se enmarca como un aporte académico y práctico, que contribuya tanto a la investigación en ingeniería de sistemas como al fortalecimiento del sector agropecuario mediante soluciones tecnológicas confiables.

### 3. Planteamiento del problema

El sector agrícola enfrenta desafíos constantes relacionados con la variabilidad climática, las propiedades del suelo y el costo de los insumos, lo que dificulta la planificación y optimización de la producción. En este contexto, contar con modelos predictivos robustos es esencial para tomar decisiones informadas y reducir riesgos.

En un trabajo previo, se desarrollaron pruebas de concepto en MATLAB aplicando redes neuronales NARX y sistemas difusos. Estas pruebas consistieron en:

- Ajuste de parámetros como número de neuronas, retardos y reglas difusas.
- Análisis de distintas combinaciones de variables (lluvia, temperatura, pesticidas) y configuraciones de datasets.
- Optimización básica mediante algoritmos genéticos y métodos Cuasi-Newton.

Si bien estos experimentos permitieron evidenciar tendencias y potenciales ventajas de cada técnica, también revelaron limitaciones:

- Dataset limitado y con pocas variables.
- Falta de normalización y validación cruzada rigurosa.
- Complejidad de algunos modelos sin mejoras significativas en precisión.

Por lo anterior, surge la necesidad de refinar y ampliar este trabajo con un enfoque más metodológico y sistemático, evaluando el rendimiento de cada técnica bajo condiciones más completas y documentadas.

### 4. Justificación

Este proyecto busca consolidar un análisis detallado de métodos computacionales para predicción agrícola, con mejoras significativas respecto al trabajo previo:

- Mayor solidez científica: Se propone trabajar con datasets más diversos, integrando variables adicionales (humedad del suelo, radiación solar, prácticas de cultivo, entre otras).
- Optimización realista: Ajustar los modelos mediante técnicas matemáticas y computacionales, priorizando interpretabilidad y escalabilidad.
- Comparación clara: Documentar ventajas y limitaciones de cada enfoque, facilitando su elección en escenarios reales.
- Aporte académico: Generar una monografía de grado que no solo aplique herramientas, sino que explique en profundidad su funcionamiento, su ajuste y su impacto práctico.

Este proyecto permitirá pasar de simples pruebas de concepto a una propuesta rigurosa, replicable y con potencial de implementación.

## **5. Objetivos**

### **5.1 General**

Desarrollar y documentar un estudio comparativo y optimizado de métodos computacionales (redes neuronales, lógica difusa y técnicas de optimización) para la predicción del rendimiento de cultivos, integrando nuevas variables, configuraciones y datos.

### **5.2 Específicos**

1. Analizar el trabajo previo realizado en MATLAB y sistematizar los resultados de las pruebas iniciales.
2. Incorporar datasets más completos y variables adicionales relevantes para la producción agrícola.
3. Ajustar y optimizar modelos de redes neuronales y sistemas difusos mediante métodos matemáticos avanzados.
4. Realizar validaciones exhaustivas (normalización, validación cruzada, particiones de entrenamiento, validación y prueba).
5. Comparar el desempeño de cada técnica usando métricas estadísticas (ECM, MAE,  $R^2$ ) y criterios de complejidad e interpretabilidad.
6. Elaborar una monografía con los hallazgos, recomendaciones y propuestas de mejora para aplicaciones prácticas.

## **6. Marco referencial**

### **6.1 Marco Teórico**

- Modelado de sistemas agrícolas: Revisión de variables críticas que impactan en la productividad.
- Redes neuronales: Arquitectura, parámetros clave y su uso en series temporales.
- Lógica difusa: Fundamentos matemáticos, diseño de reglas, funciones de pertenencia y sistemas de inferencia.
- Optimización: Métodos Cuasi-Newton, algoritmos genéticos y otras técnicas para ajuste de modelos.
- Comparación de métodos: Discusión sobre interpretabilidad, costo computacional y escalabilidad.

### **6.2 Estado del Arte**

Revisión de literatura reciente sobre modelos híbridos (difuso-neuronales), uso de machine learning clásico y técnicas matemáticas aplicadas a predicción agrícola.

## 7. Metodología

1. Revisión bibliográfica: Sistematizar estudios relacionados con predicción de cultivos.
2. Análisis del trabajo previo: Documentar en detalle las pruebas de concepto realizadas en MATLAB.
3. Adquisición y preprocesamiento de datos: Integrar datasets públicos y privados, limpiar, normalizar y preparar datos.
4. Implementación de modelos:
  - Redes neuronales NARX con distintas configuraciones.
  - Sistemas difusos ajustados con diferentes funciones de pertenencia y reglas.
  - Algoritmos de optimización para refinamiento de parámetros.
5. Validación: Aplicar validación cruzada, análisis de sensibilidad y pruebas con datos no vistos.
6. Comparación: Evaluar modelos según métricas estadísticas, interpretabilidad y escalabilidad.
7. Monografía: Documentar resultados, análisis crítico y proyecciones.

## 8. Cronograma tentativo

Actividad	Mes 1	Mes 2	Mes 3	Mes 4	Mes 5	Mes 6
Revisión bibliográfica	X	X				
Análisis del trabajo previo	X	X				
Procesamiento de datos		X	X			
Implementación de modelos			X	X		
Validación y evaluación comparativa				X	X	
Redacción de monografía					X	X
Revisión final						X

## 9. Recursos

- Software: MATLAB, Python, librerías para optimización y lógica difusa.
- Hardware: Computador de mediano rendimiento para simulación y análisis.
- Datos: Series históricas de clima, manejo de cultivos y rendimiento.
- Bibliografía: Acceso a publicaciones académicas.

## 10. Resultados esperados

- Un análisis profundo de técnicas computacionales aplicadas a predicción agrícola.
- Modelos más robustos, con menor error y mejor capacidad de generalización.
- Documentación clara que sirva como referencia para futuras investigaciones.

## 11. Referencias bibliográficas

- Abrougui, K., Gabisi, K., Mercatoris, B., Khemis, C., Amami, R., & Chehaibi, S. (2019). Prediction of organic potato yield using tillage systems and soil properties by artificial neural network (ANN) and multiple linear regressions (MLR). *Soil and Tillage Research*, 190, 202–208. <https://doi.org/10.1016/j.still.2019.01.011>
- Garg, B., Aggarwal, S., & Sokhal, J. (2018). Crop yield forecasting using fuzzy logic and regression model. *Computers & Electrical Engineering*, 67, 383–403. <https://doi.org/10.1016/j.compeleceng.2017.08.001>
- Hernández, N., Soto, F., & Caballero, A. (2009). Modelos de simulación de cultivos: Características y usos. *Cultivos Tropicales*, 30(1), 1–10. [http://scielo.sld.cu/scielo.php?script=sci\\_arttext&pid=S0258-59362009000100014](http://scielo.sld.cu/scielo.php?script=sci_arttext&pid=S0258-59362009000100014)
- Jayaram, M. A., & Marad, N. (2013). Fuzzy inference systems for crop yield prediction. *Journal of Intelligent Systems*, 21(4), 363–372. <https://doi.org/10.1515/jisys-2012-0016>
- Khaki, S., & Wang, L. (2019). Crop yield prediction using deep neural networks. *Frontiers in Plant Science*, 10, 621. <https://doi.org/10.3389/fpls.2019.00621>

- López Seijas, T., Cabrera Pérez, J., Hernández, A., & Arias, M. (2010). Adecuación de un modelo de simulación de cultivo para la predicción del crecimiento y producción del arroz en el sur de La Habana. *Revista Ciencias Técnicas Agropecuarias*, 19(1), 90–95. [http://scielo.sld.cu/scielo.php?script=sci\\_arttext&pid=S0258-59362010000100014](http://scielo.sld.cu/scielo.php?script=sci_arttext&pid=S0258-59362010000100014)
- Pascual, I. de los A., Ramírez, J. L., & Ortiz, A. (2016). Métodos de inteligencia artificial para la predicción del rendimiento y calidad de gramíneas. *REDVET. Revista Electrónica de Veterinaria*, 17(12), 1–9. <http://www.redalyc.org/articulo.oa?id=63649052026>
- Rashid, M., Bari, B., Yusup, Y., Kamaruddin, M., & Khan, N. (2021). A comprehensive review of crop yield prediction using machine learning approaches with special emphasis on palm oil yield prediction. *IEEE Access*, 9, 72390–72410. <https://doi.org/10.1109/ACCESS.2021.3075159>
- Servín Palestina, M., Salazar, R., López-Cruz, I., Medina-García, G., & Cid-Ríos, J. (2022). Predicción de la producción y rendimiento de frijol con modelos de redes neuronales artificiales y datos climáticos. *Biotecnia*, 24(2), 104–111. <https://doi.org/10.18633/biotecnia.v24i2.1664>
- Stathakis, D., Savin, I., & T., A. (2006). Neuro-fuzzy modeling for crop yield prediction. *Environmental Modelling & Software*, 21(10), 1432–1440. <https://doi.org/10.1016/j.envsoft.2005.07.013>