

Optimización y Evaluación de Redes Neuronales en Sistema de Control del Rendimiento del cultivo de papa en Colombia

Por:

Miguel Angel Panqueva Pulido

Andrés Felipe Arias Guevara



**UNIVERSIDAD DISTRITAL
FRANCISCO JOSÉ DE CALDAS**
Acreditación Institucional de Alta Calidad

Ingeniería de sistemas

Bogotá D.C.

2025

Índice

1. Resumen	3
2. Introducción	3
3. Planteamiento del problema	4
4. Justificación	5
5. Objetivos	6
5.1 General	6
5.2 Específicos	6
6. Marco referencial	6
6.1 Marco Teórico	6
6.1.1 Sistemas dinámicos en Agricultura	6
6.1.2 Redes Neuronales Aplicadas al Control de Sistemas Agrícolas	7
6.1.3 Comparación entre modelos deterministas y data-driven	7
6.1.4 Control Predictivo Basado en Modelo (MPC)	8
6.1.5 Sistemas No Lineales y Modelos de Proceso	9
6.1.6 Modelo Grey-Box Basado en EDO y Red Neuronal	9
6.1.7 Fundamento Físico: Balance Hídrico y FAO-56	10
6.2 Marco conceptual	10
6.3 Antecedentes	11
7. Metodología	14
8. Cronograma tentativo	15
9. Recursos	15
9.1 Recursos de software:	15
9.2 Recursos de hardware:	16
9.3 Recursos de información:	16
9.4 Tiempo estimado de ejecución	16
10. Resultados esperados	16
11. Referencias bibliográficas	17

1. Resumen

El presente trabajo tiene como propósito realizar un análisis comparativo y optimizado de distintos métodos computacionales aplicados a la predicción del rendimiento agrícola. A partir de un estudio previo desarrollado en MATLAB, donde se implementaron redes neuronales NARX y sistemas difusos, se busca superar las limitaciones identificadas en cuanto a calidad de datos, validación y complejidad de los modelos.

La investigación plantea el uso de conjuntos de datos más completos y diversos, incorporando variables adicionales como humedad del suelo, radiación solar y prácticas de cultivo. Así mismo, se emplearán técnicas de optimización matemática para ajustar de manera eficiente los modelos, garantizando interpretabilidad y escalabilidad.

Se espera obtener una comparación clara entre las distintas técnicas, destacando sus fortalezas y limitaciones, con el fin de aportar al ámbito académico y a la toma de decisiones en la producción agrícola. Los resultados de este estudio contribuirán a fortalecer el uso de la inteligencia computacional en el sector, ofreciendo modelos más robustos, precisos y aplicables en escenarios reales.

2. Introducción

En Colombia, un país altamente dependiente de la agricultura, hay algunos tipos de cultivos preponderantes y fundamentales para la economía campesina y la seguridad alimentaria del país, entre estos cultivos está el de la papa, que constituye no solo un producto de consumo básico en la dieta de la población, sino también una de las principales fuentes de ingresos y sustento para comunidades rurales en diversas regiones del país.

La agricultura continúa siendo uno de los sectores más sensibles a la variabilidad climática, la calidad del suelo y los costos de los insumos. Estas condiciones generan una alta incertidumbre en la planeación y gestión de la producción, lo que plantea la necesidad de contar con herramientas que permitan anticipar escenarios y optimizar la toma de decisiones.

La optimización del riego agrícola constituye un desafío técnico y ambiental de gran relevancia, especialmente en regiones donde la disponibilidad de agua es limitada y los patrones climáticos son cada vez más variables. El manejo eficiente del agua en los cultivos requiere comprender y controlar procesos complejos que involucran la interacción entre el suelo, la atmósfera y la planta, los cuales presentan un comportamiento altamente no lineal y dependiente del tiempo. En este contexto, el desarrollo de modelos y sistemas de control inteligente se convierte en una herramienta clave para la sostenibilidad de la producción agrícola y la gestión racional de los recursos hídricos.

En este contexto, los modelos computacionales y las técnicas de control predictivo se presentan como alternativas valiosas para apoyar la gestión automatizada del

riego. El uso de redes neuronales artificiales ofrece un enfoque flexible y robusto para abordar la complejidad de este sistema agrícola, al modelar relaciones no lineales entre variables climáticas, edáficas y de manejo. De igual forma, la incorporación de modelos dinámicos basados en ecuaciones diferenciales permite representar matemáticamente la evolución de procesos como el balance hídrico del suelo, proporcionando una base física para el diseño de controladores inteligentes.

El presente proyecto propone el desarrollo de un sistema de control predictivo basado en modelo (MPC) para el riego del cultivo de papa, utilizando un modelo Grey-Box que combina una ecuación diferencial del balance hídrico con una red neuronal de corrección. Este enfoque busca determinar, en tiempo real, la cantidad óptima de agua a aplicar, garantizando niveles adecuados de humedad en la zona radicular y evitando el desperdicio del recurso hídrico. La investigación se orienta a construir un modelo funcional que sirva como referencia para futuros sistemas de riego automatizados, con potencial de adaptación a distintas regiones y condiciones del suelo, contribuyendo a la sostenibilidad y modernización del sector agrícola colombiano.

3. Planteamiento del problema

La agricultura es uno de los sectores más afectados por la variabilidad climática, la disponibilidad de agua y la eficiencia en el uso de los recursos hídricos. En Colombia, el cultivo de la papa constituye uno de los principales pilares de la producción agrícola, tanto por su impacto en la seguridad alimentaria como por su relevancia económica. Sin embargo, el manejo ineficiente del riego sigue siendo un problema recurrente, derivado de la falta de herramientas de control automatizado que respondan dinámicamente a las condiciones reales del suelo y del ambiente.

Los métodos tradicionales de programación del riego —basados en calendarios fijos o en la experiencia del agricultor— no consideran la dinámica compleja del balance hídrico en la zona radicular, ni las variaciones espaciales y temporales de la humedad del suelo. Esto conlleva a situaciones de sub-riego o sobre-riego, que reducen la productividad y deterioran las propiedades físicas y químicas del suelo.

Aunque existen modelos físicos detallados, como la ecuación de Richards o el enfoque FAO-56, su aplicación práctica es limitada por la necesidad de parámetros difíciles de medir y por la falta de adaptación a condiciones no lineales y variables. Por otro lado, los modelos puramente basados en datos (data-driven), como las redes neuronales o los sistemas NARX, ofrecen buena capacidad de ajuste, pero carecen de interpretabilidad física y tienden a sobreajustarse si los datos son escasos o ruidosos.

En este contexto, surge la necesidad de desarrollar un modelo híbrido o Grey-Box, que combine el conocimiento físico del balance hídrico con el aprendizaje de una red neuronal residual, para representar la dinámica real de la humedad del suelo de manera precisa y explicable. Dicho modelo servirá como base para un control predictivo basado en modelo (MPC) que determine la cantidad óptima de riego a

aplicar en tiempo real, considerando las restricciones del sistema y las condiciones climáticas actuales.

De esta manera, el problema central que aborda este proyecto es la falta de un sistema de control predictivo adaptable y físicamente fundamentado para el manejo del riego en cultivos de papa, que permita optimizar el uso del agua sin comprometer el rendimiento del cultivo ni la sostenibilidad del suelo.

4. Justificación

El desarrollo de sistemas inteligentes de control aplicados a la agricultura representa una oportunidad significativa para mejorar la eficiencia en el uso del agua y garantizar la sostenibilidad de los sistemas productivos. En el caso del cultivo de papa en Colombia, el manejo adecuado del riego es esencial para alcanzar altos niveles de productividad y calidad del producto, dado que el exceso o la falta de agua pueden afectar el crecimiento, la sanidad del cultivo y las condiciones del suelo.

La aplicación de un control predictivo basado en modelo (MPC) permite tomar decisiones óptimas de riego en función del estado actual del sistema y de su comportamiento futuro estimado, anticipando variaciones ambientales y respondiendo de manera dinámica a las condiciones del campo. Este tipo de estrategias ofrecen ventajas frente a los sistemas de control tradicionales, ya que integran explícitamente restricciones de operación, horizontes de predicción y modelos no lineales del proceso.

El uso de un modelo Grey-Box, que combina una ecuación diferencial del balance hídrico con una red neuronal residual, proporciona una representación física y adaptable del sistema, capaz de capturar las dinámicas complejas de la humedad del suelo sin requerir parametrizaciones excesivamente detalladas. Este enfoque permite unir el conocimiento teórico del comportamiento del agua en la zona radicular con la capacidad de las redes neuronales para ajustar las diferencias entre la realidad y el modelo físico.

Desde el punto de vista académico, el proyecto contribuye al avance en la integración entre ingeniería de control, modelado matemático y técnicas de inteligencia artificial, áreas que tradicionalmente han evolucionado por separado en el contexto agrícola. A nivel práctico, los resultados de esta investigación pueden servir como base para el desarrollo de sistemas de riego automatizados más eficientes, escalables y adaptables a diferentes condiciones de suelo y clima, favoreciendo la sostenibilidad de la producción agrícola nacional.

5. Objetivos

5.1 General

Desarrollar un modelo Grey-Box que combine ecuaciones diferenciales ordinarias (EDO) del balance hídrico del suelo con redes neuronales artificiales, con el fin de implementar un esquema de control predictivo basado en modelo (MPC) para optimizar la aplicación de riego en el cultivo de papa en Colombia.

5.2 Específicos

1. Analizar antecedentes científicos sobre modelado físico e inteligencia artificial aplicados al control del riego en papa.
2. Formular el modelo físico mediante una EDO representativa del balance hídrico del suelo y definir los parámetros de entrada (I, P, ETc, D y Zr).
3. Entrenar una red neuronal residual que aprenda los errores del modelo físico y permita capturar dinámicas no modeladas.
4. Integrar ambos componentes en una arquitectura Grey-Box e implementar un esquema de control predictivo (MPC) no lineal.
5. Simular y validar el desempeño del modelo mediante métricas estadísticas y análisis comparativo frente a modelos puramente físicos y data-driven.
6. Documentar el proceso, los resultados y la aplicabilidad del modelo como herramienta para la gestión inteligente del riego agrícola.

6. Marco referencial

6.1 Marco Teórico

6.1.1 Sistemas dinámicos en Agricultura

Los cultivos agrícolas pueden representarse como sistemas dinámicos no lineales, ya que su comportamiento depende de múltiples variables que evolucionan con el tiempo, como la humedad del suelo, la temperatura, la radiación solar, los nutrientes y las prácticas de manejo. Estas variables están interrelacionadas y presentan retroalimentación continua, lo que genera respuestas complejas ante pequeñas variaciones en las condiciones iniciales o ambientales.

Debido a esta naturaleza dinámica y multivariable, el modelado de los procesos agrícolas no puede abordarse mediante relaciones estáticas o lineales simples. En este contexto, los modelos basados en ecuaciones diferenciales ordinarias (EDO) se han utilizado ampliamente para representar la evolución temporal de variables de interés. Pelak, Revelli y Porporato (2017) propusieron un modelo dinámico determinista que describe la interacción entre la cobertura del dosel (C), la humedad del suelo (S) y el nitrógeno disponible (N), mostrando que estas ecuaciones pueden emplearse para simular estrategias de riego y fertilización bajo incertidumbre climática.

Este tipo de formulaciones ofrece una base física sólida sobre la cual diseñar estrategias de control automatizado.

6.1.2 Redes Neuronales Aplicadas al Control de Sistemas Agrícolas

El control en agricultura de precisión tiene como objetivo mantener condiciones óptimas de cultivo mediante la regulación automática de factores como la humedad del suelo, la temperatura o la disponibilidad de nutrientes. A diferencia de los métodos tradicionales, que operan con umbrales fijos o decisiones manuales, los enfoques modernos buscan diseñar sistemas adaptativos, capaces de responder dinámicamente a los cambios en el entorno y a las necesidades fisiológicas del cultivo.

En este contexto, las redes neuronales artificiales (RNA) se han consolidado como una herramienta poderosa para modelar y controlar sistemas no lineales. El teorema de aproximación universal (Hornik, 1991) establece que una red neuronal de tipo *feedforward* puede aproximar cualquier función continua con suficiente número de neuronas y capas ocultas, lo que las convierte en aproximadores universales capaces de capturar relaciones complejas entre variables de entrada y salida.

Dentro del ámbito agrícola, las RNA se han utilizado para modelar procesos físicos y fisiológicos del cultivo, así como para el diseño de controladores inteligentes. Las arquitecturas recurrentes, como NARX, LSTM o GRU, son particularmente útiles para representar la dependencia temporal de las variables del sistema, permitiendo predecir y corregir el comportamiento dinámico del suelo y la planta. Brunton y Kutz (2019) destacan que los controladores basados en RNA pueden operar bajo condiciones de alta incertidumbre, adaptándose al entorno sin necesidad de reparametrizar el modelo físico.

Por otro lado, los modelos puramente deterministas, aunque interpretables, suelen requerir gran cantidad de parámetros físicos difíciles de estimar, mientras que los modelos puramente data-driven carecen de base física y pueden ser inestables fuera del rango de entrenamiento. La literatura reciente propone una solución intermedia: los modelos híbridos o grey-box, que integran ecuaciones diferenciales como estructura base y redes neuronales como mecanismo de corrección o ajuste. Este enfoque, señalado por Bramburger et al. (2020), combina la interpretabilidad de los modelos físicos con la flexibilidad de los métodos de aprendizaje, ofreciendo una alternativa eficaz para el control de sistemas agrícolas complejos.

6.1.3 Comparación entre modelos deterministas y data-driven

Los modelos deterministas basados en ecuaciones diferenciales tienen la ventaja de la interpretabilidad: cada variable y parámetro corresponde a un

proceso físico (ej. fotosíntesis, absorción de nutrientes). Sin embargo, requieren conocimiento profundo de los mecanismos internos y calibración constante.

Por otro lado, los modelos basados en RNA son altamente flexibles y pueden aprender dinámicas a partir de datos experimentales o de sensores sin necesidad de conocer todas las relaciones internas. Su principal limitación es la falta de interpretabilidad y la necesidad de grandes volúmenes de datos.

La literatura actual indica que un enfoque híbrido —usando ecuaciones diferenciales como generadores de datos sintéticos y RNA como aproximadores universales— ofrece un camino prometedor para aplicaciones de control agrícola (Bramburger et al., 2020).

6.1.4 Control Predictivo Basado en Modelo (MPC)

El Model Predictive Control (MPC) es una técnica avanzada de control automático que optimiza la acción de control a lo largo de un horizonte de tiempo futuro, basándose en un modelo dinámico del proceso.

En cada instante de muestreo, el MPC utiliza el modelo para predecir el comportamiento futuro del sistema, resuelve un problema de optimización que minimiza una función de costo y aplica únicamente la primera acción óptima, repitiendo el proceso en la siguiente iteración.

Matemáticamente, el MPC resuelve en cada paso un problema de la forma:

$$\min \sum_{k=1}^{N_p} (y_{ref}(k) - y(k))^2 + \lambda \sum_{k=1}^{N_c} \Delta u(k)^2$$

donde:

- $y(k)$ es la variable de salida o controlada,
- $u(k)$ es la variable manipulada o acción de control,
- N_p y N_c son los horizontes de predicción y control respectivamente
- λ pondera la variación de la señal de control.

El MPC es ampliamente utilizado en procesos industriales y agrícolas porque maneja restricciones explícitas y puede incorporar modelos no lineales o híbridos.

Cuando el modelo es lineal se denomina MPC lineal (LMPC); en sistemas con comportamientos no lineales, como el flujo de agua en el suelo, se emplea la versión no lineal (NMPC) o la linealización sucesiva, según los requerimientos computacionales.

6.1.5 Sistemas No Lineales y Modelos de Proceso

En agricultura, la humedad del suelo, la evapotranspiración y la infiltración presentan comportamientos altamente no lineales.

Por ello, el desempeño del MPC depende fuertemente de la calidad del modelo que describe el proceso.

Entre los modelos más comunes se encuentran:

- ARX/ARMAX (lineales): expresan la salida como una combinación lineal de entradas y retardos; son simples pero limitados ante no linealidades.
- Modelos físicos (EDO): se basan en ecuaciones de balance de masa, como las derivadas del balance hídrico en la zona radicular o de la ecuación de Richards.
- Modelos puramente data-driven (redes neuronales, NARX, LSTM): aprenden la relación entrada-salida directamente de los datos, aunque pierden interpretabilidad física.
- Modelos híbridos o *grey-box*: combinan la formulación física con una corrección aprendida mediante inteligencia artificial, permitiendo representar tanto la base científica como las dinámicas no modeladas.

6.1.6 Modelo Grey-Box Basado en EDO y Red Neuronal

El modelo grey-box representa el punto intermedio entre los enfoques físico y puramente empírico. Su estructura se compone de una ecuación diferencial ordinaria (EDO) que modela el balance hídrico y de una red neuronal residual que aprende los errores del modelo físico.

La EDO describe la variación temporal de la humedad volumétrica del suelo $\theta(t)$:

$$\frac{d\theta}{dt} = \frac{1}{Z_r} [I(t) + P(t) - ET_c(t, \theta) - D(t, \theta)]$$

donde:

- $\theta(t)$: humedad del suelo (variable de estado y salida Y)
- $I(t)$: riego aplicado (entrada de control U)
- $P(t)$: precipitación
- $ET_c(t, \theta)$: evapotranspiración del cultivo
- $D(t, \theta)$: drenaje profundo
- Z_r : profundidad efectiva de raíces.

El componente neuronal se agrega como una corrección residual:

$$\theta_{pred}(t) = \theta_{EDO}(t) + f_{NN}(x(t))$$

donde $f_{NN}(x(t))$ aprende patrones no representados por la ecuación física, como variaciones locales del suelo, microclima o errores de medición.

Esta combinación ofrece un modelo explicable, adaptable y preciso, adecuado para control predictivo no lineal (NMPC), ya que permite linealización local o uso directo en optimización no lineal.

6.1.7 Fundamento Físico: Balance Hídrico y FAO-56

El modelo se apoya en el principio de conservación de masa del agua en la zona radicular, expresado como:

$$\frac{dW}{dt} = I + P - ET - D$$

Dividiendo entre la profundidad efectiva de raíces Z_r se obtiene la ecuación para la humedad volumétrica.

El cálculo de la evapotranspiración del cultivo (ET_c) se realiza siguiendo la metodología FAO-56 (Allen et al., 1998), que utiliza el coeficiente dual de cultivo (K_c) y la evapotranspiración de referencia (ET_0):

$$ET_c = (K_{cb}K_s + K_e) \cdot ET_0$$

Este marco teórico, validado en la literatura agrícola e implementado en herramientas como *pyfao56* (Thorp, 2022), garantiza que el modelo conserve coherencia física y compatibilidad con datos medidos de campo.

6.2 Marco conceptual

Para este proyecto, se consideran algunos conceptos clave:

- Papa: cultivo de gran importancia económica y social en Colombia, sensible a factores climáticos y de manejo agrícola.
- Sistema dinámico: conjunto de variables interrelacionadas cuya evolución se describe en función del tiempo, susceptible de modelarse mediante ecuaciones diferenciales.

- Red neuronal artificial: modelo computacional inspirado en el cerebro humano, capaz de aprender relaciones no lineales a partir de datos de entrada y salida.
- Control agrícola: acción de regular variables críticas del cultivo (ej. humedad, nutrientes) para mantener condiciones óptimas de crecimiento.
- Humedad del suelo (θ) Proporción de agua en el volumen de suelo dentro de la zona de raíces. Variable controlada por el sistema.
- Zona radicular (Z_r) Profundidad efectiva del suelo donde las raíces extraen agua; define el volumen del balance hídrico.
- Riego (I) Entrada de agua controlable aplicada al cultivo mediante el actuador; representa la variable manipulada U
- Evapotranspiración (ET_c) Pérdida combinada de agua por evaporación y transpiración; salida natural del sistema modelada mediante FAO-56.
- Drenaje (D) Flujo de agua que percola fuera de la zona radicular; depende de las condiciones del suelo y la humedad actual.
- Modelo Grey-Box Modelo híbrido que combina una ecuación física (EDO) con una red neuronal residual para mejorar precisión y adaptabilidad.
- Modelo Predictivo Basado en Modelo (MPC) Estrategia de control que predice el comportamiento del sistema y optimiza la acción de riego dentro de un horizonte de tiempo, respetando restricciones.
- Horizonte de Predicción (N_p) Cantidad de pasos futuros que el MPC usa para prever la evolución de la humedad del suelo.
- Horizonte de Control (N_c) Cantidad de acciones de riego consecutivas que el MPC optimiza en cada iteración.
- Control No Lineal (NMPC) Versión del MPC que opera directamente sobre modelos no lineales, como el grey-box propuesto, usando optimización iterativa.

6.3 Antecedentes

El estudio de la dinámica de humedad en el suelo y su relación con el crecimiento del cultivo de papa ha sido ampliamente abordado en la literatura reciente, destacando la importancia de comprender la **profundidad efectiva de raíces**, la **eficiencia en el uso del agua** y la **absorción de nutrientes**. Estos aspectos constituyen la base conceptual del modelo **Grey-Box** propuesto en el presente trabajo, el cual busca representar el comportamiento del sistema suelo-planta-agua mediante ecuaciones diferenciales ordinarias y redes neuronales, integrando conocimiento físico con aprendizaje basado en datos.

En primer lugar, **Kautz y Hoffmann (2024)** realizaron un análisis detallado sobre la profundidad de enraizamiento en distintas variedades de papa mediante el uso de tubos minirhizotrón. Los resultados mostraron que algunas especies pueden alcanzar profundidades de hasta **1.8 metros**, lo cual demuestra la alta capacidad de la papa para explorar estratos profundos del suelo y acceder a reservas de agua y nitrógeno. Este hallazgo resulta fundamental al definir el parámetro de **profundidad**

efectiva de raíces (Z_r) dentro del modelo físico planteado.

De forma complementaria, **Ahmad y Hanjra (2019)** estudiaron la dinámica del agua en el suelo y la zona efectiva de raíces en cultivos de papa bajo riego por aspersión en suelos arenoso-limosos, encontrando que aproximadamente el **85 % del agua extraída por las raíces proviene de los primeros 40 cm del suelo**, lo cual establece un valor de **$Z_r \approx 0.4$ m** representativo para este tipo de suelos. Esta información es clave para parametrizar el modelo diferencial que describe el flujo de agua en el perfil del suelo y estimar la humedad disponible para la planta.

Asimismo, **Chen, Li y Wang (2022)** propusieron un enfoque de manejo del riego basado en la **distribución dinámica de las raíces**, demostrando que adaptar la frecuencia y el volumen de riego a dicha distribución mejora significativamente el rendimiento y la eficiencia en el uso del agua y el nitrógeno. Este enfoque se alinea directamente con los objetivos del modelo Grey-Box, que busca implementar un esquema de **control predictivo (MPC)** para optimizar la aplicación del riego en función de la humedad del suelo.

Por otra parte, un estudio reciente publicado en *Potato Research* (2024) en China aplicó **redes neuronales artificiales optimizadas** para la predicción del rendimiento de papa. Los autores desarrollaron un modelo basado en una red neuronal de retropropagación (BP) mejorada mediante el **Whale Optimization Algorithm (WOA)**, incorporando variables climáticas, hidro-térmicas y del suelo recolectadas entre 2010 y 2022. El modelo mostró un desempeño superior frente a enfoques tradicionales, mejorando la capacidad de generalización y reduciendo los errores de predicción. Este antecedente es relevante porque demuestra cómo la integración de **técnicas de optimización y redes neuronales** puede potenciar el modelado de procesos complejos en el cultivo de papa, abriendo la posibilidad de aplicar enfoques similares para el **control predictivo de variables críticas** más allá de la simple predicción.

De manera complementaria, **van Voorn et al. (2023)** propusieron un **marco conceptual para el modelado dinámico de fenotipos dependientes del tiempo**, considerando la interacción entre genotipo, ambiente y manejo agrícola. Los autores desarrollaron una biblioteca de modelos fenomenológicos de complejidad limitada basados en **ecuaciones diferenciales ordinarias**, con el fin de describir la evolución de rasgos fenotípicos a lo largo del ciclo de cultivo. Este antecedente demuestra que, incluso con modelos deterministas relativamente simples, es posible capturar las dinámicas de crecimiento vegetal bajo diversas condiciones ambientales, constituyendo una base sólida para el diseño de un modelo determinista aplicable al control de variables críticas en papa.

Desde una perspectiva regional, **Marcillo-Pagay et al. (2022)** realizaron un estudio en el departamento de Nariño (Colombia) sobre las respuestas agronómicas y económicas de la papa (*Solanum tuberosum* subsp. *andigena*) bajo diferentes dosis de fertilización en cuatro ambientes contrastantes. Los resultados mostraron que la productividad y la rentabilidad del cultivo dependen de la interacción entre variedad,

tipo de suelo, condiciones climáticas y nivel de fertilización. Este antecedente es especialmente relevante por su carácter local, ya que resalta la necesidad de diseñar **sistemas de control adaptativos** que integren tanto la fertilización como las condiciones ambientales para optimizar la producción de papa en Colombia.

En cuanto al modelado físico del movimiento del agua en el suelo, **Ireson, Spiteri, Clark y Mathias (2023)** desarrollaron un método conservativo y eficiente para resolver la **ecuación de Richards**, implementado en la herramienta de código abierto *openRE*. Este modelo permite describir con gran detalle la dinámica del agua en el suelo, considerando propiedades hidráulicas no lineales y la extracción de agua por las raíces. Si bien representa un referente físico robusto, su complejidad computacional limita su aplicación directa en esquemas de control en tiempo real, por lo que suele emplearse como **modelo de referencia** frente a aproximaciones más simplificadas.

En contraste, **Thorp (2022)** presentó la librería *pyFAO56*, una implementación en Python del método FAO-56 para la estimación de la **evapotranspiración del cultivo (ETc)** mediante el coeficiente dual (K_c). Este enfoque permite calcular el consumo de agua y la depleción hídrica en la zona radicular a partir de datos climáticos y parámetros de cultivo, facilitando la programación de riego con menor complejidad que los modelos derivados de la ecuación de Richards. Su practicidad lo convierte en una herramienta valiosa para integrar balances hídricos en esquemas de gestión y **control predictivo de riego**.

En el ámbito del análisis de incertidumbre, **Mondaca-Duarte, Heinen y van Mourik (2020)** propusieron un marco metodológico para evaluar la **incertidumbre en estrategias de riego** basadas en modelos. Su estudio integró el modelo EMMAN3G, fundamentado en la ecuación de Richards, y el modelo de evapotranspiración de De Graaf, implementados en MATLAB con análisis **Monte Carlo**. Este enfoque permite cuantificar cómo la variabilidad en parámetros del suelo y en la estimación de la evapotranspiración influye en el drenaje y el estrés hídrico, contribuyendo al diseño de **estrategias de riego más robustas** frente a la variabilidad climática.

Asimismo, **Shang, You y Chen (2018)** propusieron un **enfoque de control predictivo robusto basado en datos** para la gestión del riego, combinando la flexibilidad de los modelos *data-driven* con la estructura del MPC. Sus resultados evidenciaron que esta integración reduce significativamente el consumo de agua y mantiene la humedad del suelo en niveles adecuados, consolidándose como una alternativa viable a los modelos puramente físicos. En esta misma línea, **Abioye et al. (2023)** aplicaron un esquema de **control predictivo basado en modelos (MPC)** al riego por goteo en invernaderos, integrando sensores IoT y procesamiento de imágenes para estimar variables como ETc y K_c . El modelo fue implementado en MATLAB y ejecutado en una *Raspberry Pi* para control en tiempo real, logrando una mayor eficiencia en el uso del agua y mejoras en la calidad del fruto en comparación con métodos tradicionales.

Finalmente, **Rossini y Patrignani (2021)** desarrollaron un método alternativo para estimar la **humedad del suelo en la zona radicular** a partir de mediciones superficiales, utilizando un **filtro exponencial** como aproximación simplificada al balance hídrico. El estudio, realizado en campos agrícolas de Kansas, mostró que el filtro exponencial predice con buena precisión el almacenamiento de agua en el perfil del suelo completo, con un error medio de 11 mm y coeficientes de Nash–Sutcliffe de hasta 0.84. Esta aproximación presenta ventajas prácticas frente a la instalación de múltiples sensores, aunque requiere ajustes según las características hidráulicas del sitio.

En conjunto, estos antecedentes evidencian una tendencia creciente hacia la integración de **modelos híbridos**, que combinan el conocimiento físico de los procesos de transporte de agua en el suelo con el aprendizaje automático de las redes neuronales. Esto permite construir modelos más adaptativos y precisos para representar la dinámica hídrica del suelo y su interacción con el cultivo. Por tanto, los estudios revisados constituyen una base sólida para la implementación del modelo **Grey-Box** propuesto, que busca optimizar el control del riego en el cultivo de papa mediante la unión del modelado diferencial y el aprendizaje basado en datos.

7. Metodología

El estudio sigue un enfoque **mixto (físico-computacional)** dividido en cinco fases:

1. Revisión bibliográfica y fundamentación:

- Análisis de literatura reciente sobre dinámica de humedad del suelo, control predictivo, ecuaciones de balance hídrico (FAO-56, Richards) y redes neuronales aplicadas a la agricultura.
- Revisión de estudios previos de predicción de rendimiento y control de humedad en papa.

2. Formulación del modelo físico (EDO):

- Se implementará la ecuación diferencial del balance hídrico:

$$\frac{d\theta}{dt} = \frac{1}{Z_r} [I(t) + P(t) - ETc(t, \theta) - D(t, \theta)]$$

- Los parámetros físicos se estimarán a partir de literatura (por ejemplo, $Z_r \approx 0.4$ m según Ahmad & Hanjra, 2019).

3. Diseño e integración de la red neuronal:

- Entrenamiento de una red neuronal residual $f_{NN}(x(t))$ para ajustar discrepancias entre el modelo físico y datos reales/sintéticos.
- El modelo híbrido final se expresará como:

$$\theta_{pred}(t) = \theta_{EDO}(t) + f_{NN}(x(t))$$

4. Implementación del control predictivo (MPC):

- Diseño de un controlador MPC no lineal sobre el modelo Grey-Box.
- Se emplearán simulaciones en MATLAB/Simulink para optimizar la señal de riego en función de restricciones y horizontes de predicción.

5. Validación y análisis de resultados:

- Evaluación mediante métricas de desempeño (RMSE, R^2 , error absoluto medio).
- Comparación frente a modelos puramente físicos (Richards, FAO-56) y puramente neuronales (NARX, LSTM).
- Discusión sobre la aplicabilidad en escenarios agrícolas colombianos.

8. Cronograma tentativo

Actividad	Mes 1	Mes 2	Mes 3	Mes 4	Mes 5	Mes 6
Revisión bibliográfica	X	X				
Análisis del trabajo previo	X	X				
Procesamiento de datos		X	X			
Implementación de modelos			X	X		
Validación y evaluación comparativa				X	X	
Redacción de monografía					X	X
Revisión final						X

9. Recursos

Para el desarrollo del proyecto se utilizarán herramientas y recursos tanto de software como de hardware, que permitan la implementación y validación del modelo propuesto.

9.1 Recursos de software:

- **MATLAB/Simulink:** para la simulación del modelo físico basado en ecuaciones diferenciales y la implementación del controlador predictivo (MPC).

- **GitHub:** como repositorio de control de versiones y documentación del código fuente del proyecto.

9.2 Recursos de hardware:

- Computador portátil o de escritorio con procesador de mediano rendimiento y mínimo 8 GB de RAM, necesario para el entrenamiento de redes neuronales y simulaciones dinámicas en MATLAB.
Acceso a internet estable para la consulta de bases de datos, descarga de bibliografía científica y sincronización del repositorio de trabajo.

9.3 Recursos de información:

- Bases de datos climáticas y agronómicas (FAO, IDEAM, DANE) para la obtención de variables de entrada como temperatura, humedad relativa, radiación solar y precipitación.
- Publicaciones científicas recientes relacionadas con modelos híbridos (Grey-Box), control predictivo (MPC) y balance hídrico en cultivos de papa.
- Datos simulados mediante el modelo EDO: se generarán conjuntos de datos sintéticos a partir de la ecuación diferencial que describe el balance hídrico del suelo. Estas simulaciones permitirán representar la dinámica temporal de la humedad bajo distintas condiciones de riego y clima, sirviendo como insumo para el entrenamiento y validación del modelo Grey-Box.

9.4 Tiempo estimado de ejecución

Tiempo total estimado para el desarrollo del proyecto es de dos semestres académicos (uno para desarrollo y otro para redacción y análisis).

10. Resultados esperados

- Un modelo **Grey-Box funcional** que describa la dinámica de la humedad del suelo en cultivos de papa.
- Una red neuronal residual capaz de **mejorar la precisión del modelo físico**, reduciendo el error de predicción respecto a enfoques tradicionales.
- Implementación de un esquema de **control predictivo no lineal (NMPC)** que optimice la cantidad y frecuencia de riego.
- Evidencia comparativa que demuestre la **superioridad del modelo híbrido** frente a enfoques puramente empíricos o deterministas.
- Un **documento técnico-científico** que sirva como referencia para futuras investigaciones en agricultura de precisión y gestión inteligente del agua.

11. Referencias bibliográficas

- Abrougui, K., Gabsi, K., Mercatoris, B., Khemis, C., Amami, R., & Chehaibi, S. (2019). Prediction of organic potato yield using tillage systems and soil properties by artificial neural network (ANN) and multiple linear regressions (MLR). *Soil and Tillage Research*, 190, 202–208. <https://doi.org/10.1016/j.still.2019.01.011>
- Garg, B., Aggarwal, S., & Sokhal, J. (2018). Crop yield forecasting using fuzzy logic and regression model. *Computers & Electrical Engineering*, 67, 383–403. <https://doi.org/10.1016/j.compeleceng.2017.08.001>
- Hernández, N., Soto, F., & Caballero, A. (2009). Modelos de simulación de cultivos: Características y usos. *Cultivos Tropicales*, 30(1), 1–10. http://scielo.sld.cu/scielo.php?script=sci_arttext&pid=S0258-59362009000100014
- Jayaram, M. A., & Marad, N. (2013). Fuzzy inference systems for crop yield prediction. *Journal of Intelligent Systems*, 21(4), 363–372. <https://doi.org/10.1515/jisys-2012-0016>
- Khaki, S., & Wang, L. (2019). Crop yield prediction using deep neural networks. *Frontiers in Plant Science*, 10, 621. <https://doi.org/10.3389/fpls.2019.00621>
- López Seijas, T., Cabrera Pérez, J., Hernández, A., & Arias, M. (2010). Adecuación de un modelo de simulación de cultivo para la predicción del crecimiento y producción del arroz en el sur de La Habana. *Revista Ciencias Técnicas Agropecuarias*, 19(1), 90–95. http://scielo.sld.cu/scielo.php?script=sci_arttext&pid=S0258-59362010000100014
- Pascual, I. de los A., Ramírez, J. L., & Ortiz, A. (2016). Métodos de inteligencia artificial para la predicción del rendimiento y calidad de gramíneas. *REDVET. Revista Electrónica de Veterinaria*, 17(12), 1–9. <http://www.redalyc.org/articulo.oa?id=63649052026>
- Rashid, M., Bari, B., Yusup, Y., Kamaruddin, M., & Khan, N. (2021). A comprehensive review of crop yield prediction using machine learning approaches with special emphasis on palm oil yield prediction. *IEEE Access*, 9, 72390–72410. <https://doi.org/10.1109/ACCESS.2021.3075159>
- Servín Palestina, M., Salazar, R., López-Cruz, I., Medina-García, G., & Cid-Ríos, J. (2022). Predicción de la producción y rendimiento de frijol con modelos de redes neuronales artificiales y datos climáticos. *Biotecnia*, 24(2), 104–111. <https://doi.org/10.18633/biotecnia.v24i2.1664>
- Stathakis, D., Savin, I., & T, A. (2006). Neuro-fuzzy modeling for crop yield prediction. *Environmental Modelling & Software*, 21(10), 1432–1440. <https://doi.org/10.1016/j.envsoft.2005.07.013>
- Bramburger, J. J., et al. (2020). Learning dynamics with recurrent neural networks.
- Brunton, S. L., & Kutz, J. N. (2019). *Data-Driven Science and Engineering*. Cambridge UP.
- Pelak, N., Revelli, R., & Porporato, A. (2017). A dynamical systems framework for crop models.
- Lorenz, E. N. (1963). *Deterministic nonperiodic flow*. *Journal of the Atmospheric Sciences*, 20(2), 130–141.
- Hornik, K. (1991). *Approximation capabilities of multilayer feedforward networks*. *Neural Networks*, 4(2), 251–257.
- Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press.

- Potato Research. (2024). *Potato yield prediction research based on improved artificial neural networks using Whale Optimization Algorithm*. European Association for Potato Research. Recuperado de <https://www.eapr.net/publications/potato-research/potato-yield-prediction-research-based-improved-artificial-neural>
- van Voorn, G. A. K., Boer, M. P., Truong, S. H., Friedenbergh, N. A., Gugushvili, S., McCormick, R., Bustos Korts, D., Messina, C. D., & van Eeuwijk, F. (2023). *A conceptual framework for the dynamic modeling of time-resolved phenotypes for sets of genotype-environment-management combinations: A model library*. *Frontiers in Plant Science*, 14, 1172359. <https://doi.org/10.3389/fpls.2023.1172359>
- Marcillo-Paguay, C. A., Benavides-Cardona, C. A., Ramos-Zambrano, H. S., & Romero, J. V. (2022). *Respuesta agronómica y económica de papa (Solanum tuberosum subsp. andigena) a la fertilización diferencial en cuatro ambientes de Nariño, Colombia*. *Revista Colombiana de Ciencias Hortícolas*, 16(2), e13559. <https://doi.org/10.17584/rcch.2022v16i2.13559>
- Kautz, T., & Hoffmann, H. (2024). *Deep Rooting as an Indicator of Deep Soil Water and N Uptake in Potato*. *Potato Research*. Springer. <https://link.springer.com/article/10.1007/s11540-024-09802-4>
- Kautz, T., & Hoffmann, H. (2024). *Deep Rooting as an Indicator of Deep Soil Water and N Uptake in Potato*. *Potato Research*. Springer. <https://link.springer.com/article/10.1007/s11540-024-09802-4>
- Chen, X., Li, Z., & Wang, J. (2022). *Improving Potato Yield, Water Productivity and Nitrogen Use Efficiency by Managing Irrigation Based on Potato Root Distribution*. *International Journal of Plant Production*. Springer. <https://link.springer.com/article/10.1007/s42106-022-00205-4>
- Allen, R. G., Pereira, L. S., Raes, D., & Smith, M. (1998). *Crop evapotranspiration—Guidelines for computing crop water requirements* (FAO Irrigation and Drainage Paper 56). Food and Agriculture Organization of the United Nations.
- Ireson, A. M., Spiteri, R. J., Clark, M. P., & Mathias, S. A. (2023). *A simple, efficient, mass-conservative approach to solving Richards' equation (openRE, v1.0)*. *Geosci. Model Dev.* — con repo [openRE](https://openRE.gmd.copernicus.org). [gmd.copernicus.org+1](https://openRE.gmd.copernicus.org)
- Thorp, K. R. et al. (2022). *pyfao56: FAO-56 evapotranspiration in Python*. *SoftwareX* — repo [kthorp/pyfao56](https://github.com/kthorp/pyfao56). [ScienceDirect+1](https://doi.org/10.1016/j.softx.2022.101010)
- Mondaca-Duarte, F. D., et al. (2020). *Performance analysis method for model-based irrigation — Richards + ET in MATLAB* (PMC article with algorithmic details). [PMC](https://pubmed.ncbi.nlm.nih.gov/34811111/)
- Shang, C., et al. (2018). *Robust/ Data-driven Model Predictive Control of Irrigation Systems*. (arXiv) — integra mecanic + data-driven en MPC. [arXiv](https://arxiv.org/abs/1808.08111)
- Rossini et al. (2021). *Predicting rootzone soil moisture from surface observations — técnicas de estimación y ecuaciones prácticas para root-zone*. [KCARE](https://doi.org/10.1016/j.kcare.2021.100000)