

 UNIVERSIDAD DISTRITAL FRANCISCO JOSÉ DE CALDAS Acreditación Institucional de Alta Calidad	UNIVERSIDAD DISTRITAL FRANCISCO JOSÉ DE CALDAS FACULTAD DE INGENIERÍA FORMATO DE PROPUESTA MODALIDAD GRADO	
---	---	---

IDENTIFICACIÓN BÁSICA DEL PROYECTO					
TÍTULO DEL ANTEPROYECTO	Modelamiento y control de un caso de estudio sobre el riego del cultivo de papa en Colombia				
MODALIDAD	Pasantía		Monografía	X	Emprendimiento
	Producción de artículo académico		Investigación, Investigación – Creación, Innovación		
ESTRUCTURA DE INVESTIGACIÓN (Si aplica)					
TIPO DE ARTICULO DE INVESTIGACIÓN (Si aplica)	Científica () Tecnológica () Reflexión () Revisión () Reporte de caso () Revisión de tema propuesto ()				
TEMATICA ASOCIADA AL PERFIL PROFESIONAL	Cibernética, Redes Neuronales, Control				

IDENTIFICACIÓN DE ESTUDIANTES				
ESTUDIANTE 1	Andrés Felipe Arias Guevara			
	CÓDIGO	20192020147	CORREO INSTITUCIONAL	anfariasg@udistrital.edu.co
ESTUDIANTE 2	Miguel Angel Panqueva Pulido			
	CÓDIGO	20201020174	CORREO INSTITUCIONAL	mapanquevap@udistrital.edu.co
DOCENTE QUE AVALA LA PROPUESTA	Duván Andrés Téllez Castro duatellezc@udistrital.edu.co			
PROFESIONAL RESPONSABLE DEL ACOMPAÑAMIENTO (SOLO PASANTIA)				
ENTIDAD RECEPTORA DEL PASANTE (SOLO PASANTIA)				

PROPUESTA DE MODALIDAD
FORMULACIÓN DEL PROBLEMA
La agricultura es uno de los sectores más afectados por la variabilidad climática, la disponibilidad de agua y la eficiencia en el uso de los recursos hídricos. En Colombia, el cultivo de la papa constituye uno de los principales pilares de la producción agrícola, tanto por su impacto en la seguridad alimentaria como por su relevancia económica. Sin embargo,



UNIVERSIDAD DISTRITAL
FRANCISCO JOSÉ DE CALDAS
Acreditación Institucional de Alta Calidad

UNIVERSIDAD DISTRITAL FRANCISCO JOSÉ DE CALDAS
FACULTAD DE INGENIERÍA

FORMATO DE PROPUESTA MODALIDAD GRADO



Facultad de Ingeniería
Universidad Distrital

el manejo ineficiente del riego sigue siendo un problema recurrente, derivado de la falta de herramientas de control automatizado que respondan dinámicamente a las condiciones reales del suelo y del ambiente.

Los métodos tradicionales de programación del riego —basados en calendarios fijos o en la experiencia del agricultor— no consideran la dinámica compleja del balance hídrico en la zona radicular, ni las variaciones espaciales y temporales de la humedad del suelo. Esto conlleva a situaciones de sub-riego o sobre-riego, que reducen la productividad y deterioran las propiedades físicas y químicas del suelo.

Aunque existen modelos físicos detallados, como la ecuación de Richards o el enfoque FAO-56, su aplicación práctica es limitada por la necesidad de parámetros difíciles de medir y por la falta de adaptación a condiciones no lineales y variables. Por otro lado, los modelos puramente basados en datos (data-driven), como las redes neuronales o los sistemas NARX, ofrecen buena capacidad de ajuste, pero carecen de interpretabilidad física y tienden a sobreajustarse si los datos son escasos o ruidosos.

Por tanto, surge la necesidad de desarrollar un modelo híbrido o Grey-Box, que combine el conocimiento físico del balance hídrico con el aprendizaje de una red neuronal residual, para representar la dinámica real de la humedad del suelo de manera precisa y explicable. Dicho modelo servirá como base para un control predictivo basado en modelo (MPC) que determine la cantidad óptima de riego a aplicar en tiempo real, considerando las restricciones del sistema y las condiciones climáticas actuales.

De esta manera, el problema central que aborda este proyecto es la falta de un sistema de control predictivo adaptable y físicamente fundamentado para el manejo del riego en cultivos de papa, que permita optimizar el uso del agua sin comprometer el rendimiento del cultivo ni la sostenibilidad del suelo.

¿Cómo diseñar e implementar un esquema de Control Predictivo Basado en Modelo (MPC), apoyado en un modelo híbrido Grey-Box, que permita regular la humedad del suelo en el cultivo de papa de manera eficiente y sostenible?

OBJETIVO GENERAL

Desarrollar un modelo Grey-Box basado en la ecuación diferencial del balance hídrico del suelo, complementado con una red neuronal residual para capturar dinámicas no modeladas, con el fin de implementar un esquema de control predictivo basado en modelo (MPC) que permita optimizar la aplicación de riego en el cultivo de papa en Colombia.

OBJETIVOS ESPECÍFICOS

1. Analizar antecedentes científicos sobre modelado físico e inteligencia artificial aplicados al control del riego en papa.



UNIVERSIDAD DISTRITAL
FRANCISCO JOSÉ DE CALDAS
Acreditación Institucional de Alta Calidad

UNIVERSIDAD DISTRITAL FRANCISCO JOSÉ DE CALDAS
FACULTAD DE INGENIERÍA

FORMATO DE PROPUESTA MODALIDAD GRADO



Facultad de Ingeniería
Universidad Distrital

2. Formular el modelo físico del proceso mediante la ecuación diferencial del balance hídrico del suelo, especificando y justificando los parámetros de entrada requeridos (I, P, ETc, D y Zr), con base en el principio de conservación de masa y la metodología FAO-56.
3. Entrenar una red neuronal residual que permita capturar las dinámicas no modeladas por la ecuación física, aprendiendo los errores sistemáticos del modelo base.
4. Integrar a EDO física y la red neuronal residual en una arquitectura Grey-Box e implementar un esquema de control predictivo (MPC) no lineal.
5. Simular y validar el desempeño del modelo mediante métricas estadísticas y análisis comparativo frente a modelos puramente físicos y data-driven.
6. Documentar el proceso, los resultados y la aplicabilidad del modelo como herramienta para la gestión inteligente del riego agrícola.

JUSTIFICACIÓN

El desarrollo de sistemas inteligentes de control aplicados a la agricultura representa una oportunidad significativa para mejorar la eficiencia en el uso del agua y garantizar la sostenibilidad de los sistemas productivos. En el caso del cultivo de papa en Colombia, el manejo adecuado del riego es esencial para alcanzar altos niveles de productividad y calidad del producto, dado que el exceso o la falta de agua pueden afectar el crecimiento, la sanidad del cultivo y las condiciones del suelo.

La aplicación de un control predictivo basado en modelo (MPC) permite tomar decisiones óptimas de riego en función del estado actual del sistema y de su comportamiento futuro estimado, anticipando variaciones ambientales y respondiendo de manera dinámica a las condiciones del campo. Este tipo de estrategias ofrecen ventajas frente a los sistemas de control tradicionales, ya que integran explícitamente restricciones de operación, horizontes de predicción y modelos no lineales del proceso.

El uso de un modelo Grey-Box, que combina una ecuación diferencial del balance hídrico con una red neuronal residual, proporciona una representación física y adaptable del sistema, capaz de capturar las dinámicas complejas de la humedad del suelo sin requerir parametrizaciones excesivamente detalladas. Este enfoque permite unir el conocimiento teórico del comportamiento del agua en la zona radicular con la capacidad de las redes neuronales para ajustar las diferencias entre la realidad y el modelo físico.

Desde el punto de vista académico, el proyecto contribuye al avance en la integración entre ingeniería de control, modelado matemático y técnicas de inteligencia artificial, áreas que tradicionalmente han evolucionado por separado en el contexto agrícola. A nivel práctico, los resultados de esta investigación pueden servir como base para el desarrollo de sistemas de riego automatizados más eficientes, escalables y adaptables a diferentes condiciones de suelo y clima, favoreciendo la sostenibilidad de la producción agrícola nacional.

DESCRIPCION DE LA IDEA DE EMPRENDIMIENTO (SOLO APLICA PARA MODALIDAD DE EMPRENDIMIENTO)

ANTECEDENTES Y MARCO REFERENCIAL



UNIVERSIDAD DISTRITAL
FRANCISCO JOSÉ DE CALDAS
Acreditación Institucional de Alta Calidad

UNIVERSIDAD DISTRITAL FRANCISCO JOSÉ DE CALDAS FACULTAD DE INGENIERÍA

FORMATO DE PROPUESTA MODALIDAD GRADO



Facultad de Ingeniería
Universidad Distrital

Antecedentes

El estudio de la dinámica de humedad en el suelo y su relación con el crecimiento del cultivo de papa ha sido ampliamente abordado en la literatura reciente, destacando la importancia de comprender la profundidad efectiva de raíces, la eficiencia en el uso del agua y la absorción de nutrientes. Estos aspectos constituyen la base conceptual del modelo Grey-Box propuesto en el presente trabajo, el cual busca representar el comportamiento del sistema suelo-planta-agua mediante ecuaciones diferenciales ordinarias y redes neuronales, integrando conocimiento físico con aprendizaje basado en datos.

En primer lugar, Kautz y Hoffmann (2024) realizaron un análisis detallado sobre la profundidad de enraizamiento en distintas variedades de papa mediante el uso de tubos minirhizotrón. Los resultados mostraron que algunas especies pueden alcanzar profundidades de hasta 1.8 metros, lo cual demuestra la alta capacidad de la papa para explorar estratos profundos del suelo y acceder a reservas de agua y nitrógeno. Este hallazgo resulta fundamental al definir el parámetro de profundidad efectiva de raíces (Z_r) dentro del modelo físico planteado.

De forma complementaria, Ahmad y Hanjra (2019) estudiaron la dinámica del agua en el suelo y la zona efectiva de raíces en cultivos de papa bajo riego por aspersión en suelos arenoso-limosos, encontrando que aproximadamente el 85 % del agua extraída por las raíces proviene de los primeros 40 cm del suelo, lo cual establece un valor de $Z_r \approx 0.4$ m representativo para este tipo de suelos. Esta información es clave para parametrizar el modelo diferencial que describe el flujo de agua en el perfil del suelo y estimar la humedad disponible para la planta.

Asimismo, Chen, Li y Wang (2022) propusieron un enfoque de manejo del riego basado en la distribución dinámica de las raíces, demostrando que adaptar la frecuencia y el volumen de riego a dicha distribución mejora significativamente el rendimiento y la eficiencia en el uso del agua y el nitrógeno. Este enfoque se alinea directamente con los objetivos del modelo Grey-Box, que busca implementar un esquema de control predictivo (MPC) para optimizar la aplicación del riego en función de la humedad del suelo.

Por otra parte, un estudio reciente publicado en *Potato Research* (2024) en China aplicó redes neuronales artificiales optimizadas para la predicción del rendimiento de papa. Los autores desarrollaron un modelo basado en una red neuronal de retropropagación (BP) mejorada mediante el Whale Optimization Algorithm (WOA), incorporando variables climáticas, hidro-térmicas y del suelo recolectadas entre 2010 y 2022. El modelo mostró un desempeño superior frente a enfoques tradicionales, mejorando la capacidad de generalización y reduciendo los errores de predicción. Este antecedente es relevante porque demuestra cómo la integración de técnicas de optimización y redes neuronales puede



UNIVERSIDAD DISTRITAL
FRANCISCO JOSÉ DE CALDAS
Acreditación Institucional de Alta Calidad

UNIVERSIDAD DISTRITAL FRANCISCO JOSÉ DE CALDAS FACULTAD DE INGENIERÍA

FORMATO DE PROPUESTA MODALIDAD GRADO



Facultad de Ingeniería
Universidad Distrital

potenciar el modelado de procesos complejos en el cultivo de papa, abriendo la posibilidad de aplicar enfoques similares para el control predictivo de variables críticas más allá de la simple predicción.

De manera complementaria, van Voorn et al. (2023) propusieron un marco conceptual para el modelado dinámico de fenotipos dependientes del tiempo, considerando la interacción entre genotipo, ambiente y manejo agrícola. Los autores desarrollaron una biblioteca de modelos fenomenológicos de complejidad limitada basados en ecuaciones diferenciales ordinarias, con el fin de describir la evolución de rasgos fenotípicos a lo largo del ciclo de cultivo. Este antecedente demuestra que, incluso con modelos deterministas relativamente simples, es posible capturar las dinámicas de crecimiento vegetal bajo diversas condiciones ambientales, constituyendo una base sólida para el diseño de un modelo determinista aplicable al control de variables críticas en papa.

Desde una perspectiva regional, Marcillo-Pagay et al. (2022) realizaron un estudio en el departamento de Nariño (Colombia) sobre las respuestas agronómicas y económicas de la papa (*Solanum tuberosum* subsp. *andigena*) bajo diferentes dosis de fertilización en cuatro ambientes contrastantes. Los resultados mostraron que la productividad y la rentabilidad del cultivo dependen de la interacción entre variedad, tipo de suelo, condiciones climáticas y nivel de fertilización. Este antecedente es especialmente relevante por su carácter local, ya que resalta la necesidad de diseñar sistemas de control adaptativos que integren tanto la fertilización como las condiciones ambientales para optimizar la producción de papa en Colombia.

En cuanto al modelado físico del movimiento del agua en el suelo, Ireson, Spiteri, Clark y Mathias (2023) desarrollaron un método conservativo y eficiente para resolver la ecuación de Richards, implementado en la herramienta de código abierto *openRE*. Este modelo permite describir con gran detalle la dinámica del agua en el suelo, considerando propiedades hidráulicas no lineales y la extracción de agua por las raíces. Si bien representa un referente físico robusto, su complejidad computacional limita su aplicación directa en esquemas de control en tiempo real, por lo que suele emplearse como modelo de referencia frente a aproximaciones más simplificadas.

En contraste, Thorp (2022) presentó la librería *pyFAO56*, una implementación en Python del método FAO-56 para la estimación de la evapotranspiración del cultivo (ET_c) mediante el coeficiente dual (K_c). Este enfoque permite calcular el consumo de agua y la depleción hídrica en la zona radicular a partir de datos climáticos y parámetros de cultivo, facilitando la programación de riego con menor complejidad que los modelos derivados de la ecuación de Richards. Su practicidad lo convierte en una herramienta valiosa para integrar balances hídricos en esquemas de gestión y control predictivo de riego.

En el ámbito del análisis de incertidumbre, Mondaca-Duarte, Heinen y van Mourik (2020) propusieron un marco metodológico para evaluar la incertidumbre en estrategias de riego basadas en modelos. Su estudio integró el modelo EMMAN3G, fundamentado en la ecuación de Richards, y el modelo de evapotranspiración de De Graaf, implementados en MATLAB



UNIVERSIDAD DISTRITAL
FRANCISCO JOSÉ DE CALDAS
Acreditación Institucional de Alta Calidad

UNIVERSIDAD DISTRITAL FRANCISCO JOSÉ DE CALDAS FACULTAD DE INGENIERÍA

FORMATO DE PROPUESTA MODALIDAD GRADO



Facultad de Ingeniería
Universidad Distrital

con análisis Monte Carlo. Este enfoque permite cuantificar cómo la variabilidad en parámetros del suelo y en la estimación de la evapotranspiración influye en el drenaje y el estrés hídrico, contribuyendo al diseño de estrategias de riego más robustas frente a la variabilidad climática.

Asimismo, Shang, You y Chen (2018) propusieron un enfoque de control predictivo robusto basado en datos para la gestión del riego, combinando la flexibilidad de los modelos *data-driven* con la estructura del MPC. Sus resultados evidenciaron que esta integración reduce significativamente el consumo de agua y mantiene la humedad del suelo en niveles adecuados, consolidándose como una alternativa viable a los modelos puramente físicos. En esta misma línea, Abioye et al. (2023) aplicaron un esquema de control predictivo basado en modelos (MPC) al riego por goteo en invernaderos, integrando sensores IoT y procesamiento de imágenes para estimar variables como ET_c y K_c . El modelo fue implementado en *MATLAB* y ejecutado en una *Raspberry Pi* para control en tiempo real, logrando una mayor eficiencia en el uso del agua y mejoras en la calidad del fruto en comparación con métodos tradicionales.

Finalmente, Rossini y Patrignani (2021) desarrollaron un método alternativo para estimar la humedad del suelo en la zona radicular a partir de mediciones superficiales, utilizando un filtro exponencial como aproximación simplificada al balance hídrico. El estudio, realizado en campos agrícolas de Kansas, mostró que el filtro exponencial predice con buena precisión el almacenamiento de agua en el perfil del suelo completo, con un error medio de 11 mm y coeficientes de Nash–Sutcliffe de hasta 0.84. Esta aproximación presenta ventajas prácticas frente a la instalación de múltiples sensores, aunque requiere ajustes según las características hidráulicas del sitio.

En conjunto, estos antecedentes evidencian una tendencia creciente hacia la integración de modelos híbridos, que combinan el conocimiento físico de los procesos de transporte de agua en el suelo con el aprendizaje automático de las redes neuronales. Esto permite construir modelos más adaptativos y precisos para representar la dinámica hídrica del suelo y su interacción con el cultivo. Por tanto, los estudios revisados constituyen una base sólida para la implementación del modelo Grey-Box propuesto, que busca optimizar el control del riego en el cultivo de papa mediante la unión del modelado diferencial y el aprendizaje basado en datos.

Marco referencial

Marco teórico

1. Sistemas dinámicos en agricultura

Los cultivos agrícolas pueden representarse como sistemas dinámicos no lineales, ya que su comportamiento depende de múltiples variables que evolucionan con el tiempo, como la humedad del suelo, la temperatura, la radiación solar, los nutrientes y las prácticas de manejo. Estas variables están interrelacionadas y presentan



UNIVERSIDAD DISTRITAL
FRANCISCO JOSÉ DE CALDAS
Acreditación Institucional de Alta Calidad

UNIVERSIDAD DISTRITAL FRANCISCO JOSÉ DE CALDAS FACULTAD DE INGENIERÍA

FORMATO DE PROPUESTA MODALIDAD GRADO



Facultad de Ingeniería
Universidad Distrital

retroalimentación continua, lo que genera respuestas complejas ante pequeñas variaciones en las condiciones iniciales o ambientales.

Debido a esta naturaleza dinámica y multivariable, el modelado de los procesos agrícolas no puede abordarse mediante relaciones estáticas o lineales simples. En este contexto, los modelos basados en ecuaciones diferenciales ordinarias (EDO) se han utilizado ampliamente para representar la evolución temporal de variables de interés. Pelak, Revelli y Porporato (2017) propusieron un modelo dinámico determinista que describe la interacción entre la cobertura del dosel (C), la humedad del suelo (S) y el nitrógeno disponible (N), mostrando que estas ecuaciones pueden emplearse para simular estrategias de riego y fertilización bajo incertidumbre climática. Este tipo de formulaciones ofrece una base física sólida sobre la cual diseñar estrategias de control automatizado.

2. Redes neuronales aplicadas al control de sistemas agrícolas

El control en agricultura de precisión tiene como objetivo mantener condiciones óptimas de cultivo mediante la regulación automática de factores como la humedad del suelo, la temperatura o la disponibilidad de nutrientes. A diferencia de los métodos tradicionales, que operan con umbrales fijos o decisiones manuales, los enfoques modernos buscan diseñar sistemas adaptativos, capaces de responder dinámicamente a los cambios en el entorno y a las necesidades fisiológicas del cultivo.

En este contexto, las redes neuronales artificiales (RNA) se han consolidado como una herramienta poderosa para modelar y controlar sistemas no lineales. El teorema de aproximación universal (Hornik, 1991) establece que una red neuronal de tipo *feedforward* puede aproximar cualquier función continua con suficiente número de neuronas y capas ocultas, lo que las convierte en aproximadores universales capaces de capturar relaciones complejas entre variables de entrada y salida.

Dentro del ámbito agrícola, las RNA se han utilizado para modelar procesos físicos y fisiológicos del cultivo, así como para el diseño de controladores inteligentes. Las arquitecturas recurrentes, como NARX, LSTM o GRU, son particularmente útiles para representar la dependencia temporal de las variables del sistema, permitiendo predecir y corregir el comportamiento dinámico del suelo y la planta. Brunton y Kutz (2019) destacan que los controladores basados en RNA pueden operar bajo condiciones de alta incertidumbre, adaptándose al entorno sin necesidad de reparametrizar el modelo físico.

Por otro lado, los modelos puramente deterministas, aunque interpretables, suelen requerir gran cantidad de parámetros físicos difíciles de estimar, mientras que los



UNIVERSIDAD DISTRITAL
FRANCISCO JOSÉ DE CALDAS
Acreditación Institucional de Alta Calidad

UNIVERSIDAD DISTRITAL FRANCISCO JOSÉ DE CALDAS FACULTAD DE INGENIERÍA

FORMATO DE PROPUESTA MODALIDAD GRADO



Facultad de Ingeniería
Universidad Distrital

modelos puramente data-driven carecen de base física y pueden ser inestables fuera del rango de entrenamiento. La literatura reciente propone una solución intermedia: los modelos híbridos o grey-box, que integran ecuaciones diferenciales como estructura base y redes neuronales como mecanismo de corrección o ajuste. Este enfoque, señalado por Bramburger et al. (2020), combina la interpretabilidad de los modelos físicos con la flexibilidad de los métodos de aprendizaje, ofreciendo una alternativa eficaz para el control de sistemas agrícolas complejos.

3. Comparación entre modelos deterministas y data-driven

Los modelos deterministas basados en ecuaciones diferenciales tienen la ventaja de la interpretabilidad: cada variable y parámetro corresponde a un proceso físico (ej. fotosíntesis, absorción de nutrientes). Sin embargo, requieren conocimiento profundo de los mecanismos internos y calibración constante.

Por otro lado, los modelos basados en RNA son altamente flexibles y pueden aprender dinámicas a partir de datos experimentales o de sensores sin necesidad de conocer todas las relaciones internas. Su principal limitación es la falta de interpretabilidad y la necesidad de grandes volúmenes de datos.

La literatura actual indica que un enfoque híbrido —usando ecuaciones diferenciales como generadores de datos sintéticos y RNA como aproximadores universales— ofrece un camino prometedor para aplicaciones de control agrícola (Bramburger et al., 2020).

4. Control predictivo basado en modelo (MPC)

El *Model Predictive Control* (MPC) es una técnica avanzada de control automático que optimiza la acción de control a lo largo de un horizonte de tiempo futuro, basándose en un modelo dinámico del proceso (Camacho & Bordons, 2007). Este enfoque permite anticipar la evolución del sistema y seleccionar la acción óptima en cada instante, incorporando de manera explícita restricciones operativas y metas de desempeño.

En cada instante de muestreo, el MPC utiliza el modelo para predecir el comportamiento futuro del sistema, resuelve un problema de optimización que minimiza una función de costo y aplica únicamente la primera acción óptima, siguiendo el principio del horizonte recedente descrito por Camacho & Bordons (2007). Este ciclo se repite continuamente, lo que permite al controlador adaptarse dinámicamente a perturbaciones y variaciones del sistema.

Matemáticamente, el MPC resuelve en cada paso un problema de la forma:



UNIVERSIDAD DISTRITAL
FRANCISCO JOSÉ DE CALDAS
Acreditación Institucional de Alta Calidad

UNIVERSIDAD DISTRITAL FRANCISCO JOSÉ DE CALDAS FACULTAD DE INGENIERÍA

FORMATO DE PROPUESTA MODALIDAD GRADO



$$\min_{u(k)} \sum_{k=1}^{N_p} \left(y_{ref}(k) - y(k) \right)^2 + \lambda \sum_{k=1}^{N_c} \Delta u(k)^2$$

donde:

- $y(k)$ es la variable de salida o controlada,
- $u(k)$ es la variable manipulada o acción de control,
- N_p y N_c son los horizontes de predicción y control respectivamente
- λ pondera la variación de la señal de control.

El MPC es ampliamente utilizado en procesos industriales y agrícolas debido a su capacidad para manejar restricciones explícitas y para incorporar modelos no lineales o híbridos. En problemas con modelos lineales, se emplea la versión MPC lineal (LMPC), mientras que en sistemas con comportamientos no lineales —como el flujo de agua en el suelo o la dinámica del balance hídrico— se utiliza la versión no lineal (NMPC) o enfoques basados en linealización sucesiva, según los requerimientos computacionales (Pelak, Revelli & Porporato, 2017; Mondaca-Duarte et al., 2020).

5. Sistemas no lineales y modelos de proceso

En agricultura, la humedad del suelo, la evapotranspiración y la infiltración presentan comportamientos altamente no lineales (Hernández et al., 2009; Allen et al., 2006; López Seijas et al., 2010). Por ello, el desempeño del MPC depende fuertemente de la calidad del modelo que describe el proceso, dado que un modelo insuficiente puede aumentar el error de predicción y afectar la estabilidad del controlador (Rawlings & Mayne, 2009).

Entre los modelos más comunes se encuentran:

- **ARX/ARMAX (lineales):** expresan la salida como una combinación lineal de entradas y retardos; son simples pero limitados ante no linealidades. Este tipo de modelos se fundamenta en técnicas clásicas de identificación de sistemas como las descritas en Ljung (1999), y han sido utilizados en aplicaciones agrícolas como referencia comparativa frente a métodos más flexibles (Pascual et al., 2016; Abrougui et al., 2019).
- **Modelos físicos (EDO):** se basan en ecuaciones de balance de masa, como las derivadas del balance hídrico en la zona radicular o de la ecuación de Richards (Allen et al., 2006; Ireson et al., 2023). Estos modelos permiten representar procesos fisiológicos y edáficos, aunque requieren parámetros que no siempre son fáciles de medir.
- **Modelos puramente data-driven (redes neuronales, NARX, LSTM):** aprenden la relación entrada-salida directamente de los datos, aunque pierden interpretabilidad física.



UNIVERSIDAD DISTRITAL
FRANCISCO JOSÉ DE CALDAS
Acreditación Institucional de Alta Calidad

UNIVERSIDAD DISTRITAL FRANCISCO JOSÉ DE CALDAS FACULTAD DE INGENIERÍA

FORMATO DE PROPUESTA MODALIDAD GRADO



Este enfoque ha sido ampliamente utilizado en predicción y modelación agrícola (Khaki & Wang, 2019; Servín Palestina et al., 2022; Rashid et al., 2021; Stathakis et al., 2006).

- **Modelos híbridos o grey-box:** combinan la formulación física con una corrección aprendida mediante inteligencia artificial, permitiendo representar tanto la base científica como las dinámicas no modeladas. Este enfoque ha sido aplicado en el modelado de cultivos y humedad del suelo (Pelak et al., 2017; Rossini et al., 2021) y es consistente con las recomendaciones de la literatura en control predictivo no lineal (Rawlings & Mayne, 2009)

6. Arquitectura general del sistema de control

La Figura 5.1 muestra la arquitectura conceptual del sistema de control propuesto, construida a partir de los principios del Control Predictivo Basado en Modelo (MPC) y de la integración entre modelos físicos y data-driven descrita en la literatura. En este esquema, el modelo físico basado en la ecuación diferencial del balance hídrico del suelo proporciona una representación determinista del proceso (Pelak, Revelli & Porporato, 2017; Allen et al., 2006), mientras que el modelo data-driven complementa dicha representación mediante la captura de dinámicas no modeladas o dependientes de los datos, tal como sugieren enfoques híbridos presentes en estudios recientes de modelado agrícola (Mondaca-Duarte et al., 2020; Rossini et al., 2021).

Ambos componentes convergen en el bloque de *planta real*, que representa la dinámica efectiva del cultivo de papa. Este sistema es regulado mediante un esquema de control predictivo no lineal (NMPC), siguiendo el principio de horizonte recedente descrito por Camacho y Bordons (2007). El MPC utiliza el modelo Grey-Box —que combina la EDO con una red neuronal residual— para predecir la evolución de la humedad del suelo y calcular la acción de control óptima UU , correspondiente al riego aplicado. A partir de esta acción, el modelo produce la salida YY , que corresponde a la humedad volumétrica estimada o medida del suelo, y dicha salida se retroalimenta al controlador, cerrando el lazo de control.

Esta arquitectura permite integrar coherencia física, capacidad predictiva y aprendizaje a partir de datos, lo cual es fundamental en sistemas agrícolas no lineales donde intervienen múltiples factores climáticos, edáficos y fisiológicos.



UNIVERSIDAD DISTRITAL
FRANCISCO JOSÉ DE CALDAS
Acreditación Institucional de Alta Calidad

UNIVERSIDAD DISTRITAL FRANCISCO JOSÉ DE CALDAS FACULTAD DE INGENIERÍA

FORMATO DE PROPUESTA MODALIDAD GRADO



Facultad de Ingeniería
Universidad Distrital




Figura: Arquitectura general del sistema de control predictivo propuesto

7. Modelo Grey-Box basado en EDO y red neuronal

El modelo grey-box representa el punto intermedio entre los enfoques físico y puramente empírico. Su estructura se compone de una ecuación diferencial ordinaria (EDO) que modela el balance hídrico y de una red neuronal residual que aprende los errores del modelo físico. Este tipo de integración ha sido ampliamente utilizada para mejorar el desempeño de modelos dinámicos cuando existen incertidumbres en parámetros o procesos no modelados (Brunton & Kutz, 2019; Bramburger et al., 2020).

El componente físico se basa en el balance de agua descrito en FAO-56 (Allen et al., 2006) y complementado con desarrollos recientes de modelación dinámica en sistemas agrícolas (Pelak et al., 2017). La EDO describe la variación temporal de la humedad volumétrica del suelo $\theta(t)$:

$$\frac{d\theta}{dt} = \frac{1}{Zr} [I(t) + P(t) - ETc(t, \theta) - D(t, \theta)]$$

Esta ecuación diferencial corresponde al balance hídrico del suelo (modelo físico), cuya fuente es el principio de conservación de masa y la metodología FAO-56 (ver Subsección 5.1.8)

donde:



UNIVERSIDAD DISTRITAL
FRANCISCO JOSÉ DE CALDAS
Acreditación Institucional de Alta Calidad

UNIVERSIDAD DISTRITAL FRANCISCO JOSÉ DE CALDAS FACULTAD DE INGENIERÍA

FORMATO DE PROPUESTA MODALIDAD GRADO



- $\theta(t)$: humedad del suelo (variable de estado y salida Y)
- $I(t)$: riego aplicado (entrada de control U)
- $P(t)$: precipitación
- $ET_c(t, \theta)$: evapotranspiración del cultivo
- $D(t, \theta)$: drenaje profundo
- Z_r : profundidad efectiva de raíces.

Estos componentes han sido empleados en diversos trabajos sobre simulación de cultivos (Hernández et al., 2009; López Seijas et al., 2010).

El término neuronal introduce una corrección residual que permite capturar dinámicas no representadas explícitamente por la EDO, mejorando la adaptabilidad del modelo ante variaciones locales del suelo, condiciones climáticas o errores de medición, siguiendo principios de aprendizaje residual documentados por Hornik (1991) y aplicados recientemente en modelación agrícola (Servín Palestina et al., 2022; Rossini et al., 2021). Así, la predicción ajustada se expresa como:

$$\theta_{pred}(t) = \theta_{EDO}(t) + f_{NN}(x(t))$$

donde $f_{NN}(x(t))$ aprende patrones no representados por la ecuación física, como variaciones locales del suelo, microclima o errores de medición.

Esta combinación ofrece un modelo explicable, adaptable y preciso, adecuado para control predictivo no lineal (NMPC), ya que permite linealización local o uso directo en optimización no lineal, tal como proponen trabajos recientes en control de riego basados en modelos dinámicos y técnicas de aprendizaje (Shang et al., 2019; Mondaca-Duarte et al., 2020).

8. Fundamento físico: balance hídrico y FAO-56

El modelo se apoya en el principio de conservación de masa del agua en la zona radicular, expresado como:

$$\frac{dW}{dt} = I + P - ET - D$$

Dividiendo entre la profundidad efectiva de raíces Z_r se obtiene la ecuación para la humedad volumétrica.

El cálculo de la evapotranspiración del cultivo (ET_c) se realiza siguiendo la metodología FAO-56 (Allen et al., 2006), que utiliza el coeficiente dual de cultivo (K_c) y la evapotranspiración de referencia (ET_0):

$$ET_c = (K_{cb}K_s + K_e) \cdot ET_0$$



UNIVERSIDAD DISTRITAL
FRANCISCO JOSÉ DE CALDAS
Acreditación Institucional de Alta Calidad

UNIVERSIDAD DISTRITAL FRANCISCO JOSÉ DE CALDAS FACULTAD DE INGENIERÍA

FORMATO DE PROPUESTA MODALIDAD GRADO



Facultad de Ingeniería
Universidad Distrital

Donde:

- K_{cb} : coeficiente basal del cultivo. Representa la transpiración del cultivo sin influencia de la evaporación del suelo y depende de la fase fenológica.
- K_s : coeficiente de estrés hídrico. Toma valores entre 0 y 1 y reduce la transpiración cuando la humedad del perfil no es suficiente.
- K_e : coeficiente de evaporación del suelo. Cuantifica la evaporación superficial y depende del contenido de agua en la capa superior y de la fracción de suelo expuesta.

Este marco teórico, validado en la literatura agrícola e implementado en herramientas como *pyfao56* (Thorp, 2022), garantiza que el modelo conserve coherencia física y compatibilidad con datos medidos de campo.

Marco conceptual

Para este proyecto, se consideran algunos conceptos clave:

- Papa: cultivo de gran importancia económica y social en Colombia, sensible a factores climáticos y de manejo agrícola.
- Sistema dinámico: conjunto de variables interrelacionadas cuya evolución se describe en función del tiempo, susceptible de modelarse mediante ecuaciones diferenciales.
- Red neuronal artificial: modelo computacional inspirado en el cerebro humano, capaz de aprender relaciones no lineales a partir de datos de entrada y salida.
- Control agrícola: acción de regular variables críticas del cultivo (ej. humedad, nutrientes) para mantener condiciones óptimas de crecimiento.
- Humedad del suelo (θ): Proporción de agua en el volumen de suelo dentro de la zona de raíces. Variable controlada por el sistema.
- Zona radicular (Z_r): Profundidad efectiva del suelo donde las raíces extraen agua; define el volumen del balance hídrico.
- Riego (I): Entrada de agua controlable aplicada al cultivo mediante el actuador; representa la variable manipulada U .
- Evapotranspiración (ET_c): Pérdida combinada de agua por evaporación y transpiración; salida natural del sistema modelada mediante FAO-56.
- Drenaje (D): Flujo de agua que percola fuera de la zona radicular; depende de las condiciones del suelo y la humedad actual.
- Modelo Grey-Box: Modelo híbrido que combina una ecuación física (EDO) con una red neuronal residual para mejorar precisión y adaptabilidad.
- Modelo Predictivo Basado en Modelo (MPC): Estrategia de control que predice el comportamiento del sistema y optimiza la acción de riego dentro de un horizonte de tiempo, respetando restricciones.
- Horizonte de Predicción (N_p): Cantidad de pasos futuros que el MPC usa para prever la evolución de la humedad del suelo.



UNIVERSIDAD DISTRITAL
FRANCISCO JOSÉ DE CALDAS
Acreditación Institucional de Alta Calidad

UNIVERSIDAD DISTRITAL FRANCISCO JOSÉ DE CALDAS
FACULTAD DE INGENIERÍA

FORMATO DE PROPUESTA MODALIDAD GRADO



Facultad de Ingeniería
Universidad Distrital

- Horizonte de Control (N_c): Cantidad de acciones de riego consecutivas que el MPC optimiza en cada iteración.
- Control No Lineal (NMPC): Versión del MPC que opera directamente sobre modelos no lineales, como el grey-box propuesto, usando optimización iterativa.

PLAN DE TRABAJO (INDIVIDUAL PARA PASANTIA)

El desarrollo del proyecto se estructurará en cuatro fases principales:

1. Revisión bibliográfica y análisis de modelos existentes. Incluye la recopilación de información sobre MPC, modelos Grey-Box y control de riego.
2. Diseño del modelo híbrido. Formulación del modelo físico (EDO) y de la red neuronal de corrección.
3. Implementación y simulación. Programación en MATLAB/CasADi, integración del controlador MPC y pruebas en distintos escenarios.
4. Validación y documentación. Evaluación del desempeño, análisis de resultados y redacción de la monografía final.

CRONOGRAMA

Actividad	Mes 1	Mes 2	Mes 3	Mes 4	Mes 5	Mes 6
Revisión bibliográfica y recopilación de datos	X	X				
Formulación del modelo físico (EDO)		X	X			
Entrenamiento de la red neuronal y ajuste Grey-Box		X	X			
Diseño e implementación del control predictivo (MPC) en CasADi			X	X		
Validación, simulaciones y comparación de resultados				X	X	
Redacción, conclusiones y revisión del documento					X	X

Cronograma de actividades del proyecto.

PRESUPUESTO

El desarrollo del proyecto requiere diversos recursos humanos, tecnológicos y materiales, estimados en función de su disponibilidad y costo aproximado. La mayor parte de las herramientas son de carácter académico o de libre acceso, por lo que el presupuesto total se mantiene bajo y viable.



UNIVERSIDAD DISTRITAL
FRANCISCO JOSÉ DE CALDAS
Acreditación Institucional de Alta Calidad

UNIVERSIDAD DISTRITAL FRANCISCO JOSÉ DE CALDAS FACULTAD DE INGENIERÍA

FORMATO DE PROPUESTA MODALIDAD GRADO



Facultad de Ingeniería
Universidad Distrital

Recursos Humanos

- Autores del proyecto: responsables de la búsqueda bibliográfica y de datos, modelado matemático, implementación computacional en MATLAB/CasADi y redacción de la monografía.
- Director de proyecto: encargado de la orientación académica, revisión técnica del modelo y supervisión de los avances metodológicos.

Estos recursos corresponden a participación académica, sin costo monetario directo.

Recursos Tecnológicos

- MATLAB (versión académica): herramienta principal para la simulación numérica, el modelado de ecuaciones diferenciales y la integración del controlador MPC.
- CasADi (librería open-source): entorno para la formulación simbólica y la resolución de problemas de optimización no lineal, integrado en MATLAB.
- Equipo de cómputo: computador portátil o de escritorio con procesador i7 o superior y mínimo 16 GB de RAM. Se dispone de este recurso sin costo adicional, ya que pertenece a los autores o está disponible en el entorno institucional. Aunque de ser necesario se dispondrá de \$1.500.000 COP para alquilar un equipo que cumpla las características necesarias.
- Software de oficina (Microsoft Office / LaTeX): para la redacción, edición y formato del documento final.

Recursos Materiales y Administrativos

- Impresiones y encuadernación de la monografía: \$100.000 COP
- Transporte y comunicaciones: \$50.000 COP (reuniones, desplazamientos o conectividad con el director).
- Acceso a bibliografía y bases de datos: gratuito mediante las licencias académicas y bibliotecas digitales de la universidad.

Estimación general

Concepto	Descripción	Costo total (COP)
Equipos de cómputo	Alquiler de computadores	\$1.500.000
Impresiones y encuadernado de la monografía	Reproducción y presentación física del documento final.	\$100.000
Transporte y comunicaciones	Gastos de transporte y conectividad para reuniones académicas	\$50.000



UNIVERSIDAD DISTRITAL
FRANCISCO JOSÉ DE CALDAS
Acreditación Institucional de Alta Calidad

UNIVERSIDAD DISTRITAL FRANCISCO JOSÉ DE CALDAS
FACULTAD DE INGENIERÍA

FORMATO DE PROPUESTA MODALIDAD GRADO



Facultad de Ingeniería
Universidad Distrital

	con el director y asesorías.	
Otros gastos	Gastos imprevistos.	\$2.000.000
Total	-	\$3.650.000

Gastos generales incluidos en el desarrollo del proyecto.

IMPACTO O ALCANCE ESPERADO

Se espera obtener un modelo híbrido Grey-Box implementado en MATLAB, que combine una ecuación diferencial del balance hídrico del suelo con una red neuronal de corrección, capaz de representar adecuadamente la dinámica de la humedad en la zona radicular del cultivo de papa.

Este modelo será integrado dentro de un esquema de Control Predictivo No Lineal (NMPC) utilizando CasADi, con el objetivo de mantener la humedad del suelo dentro de rangos óptimos y minimizar el consumo de agua.

Entre los resultados esperados se incluyen:

- La formulación completa del modelo matemático y su validación mediante simulaciones.
- La implementación del controlador predictivo y su evaluación bajo distintas condiciones de riego y clima.
- Análisis de desempeño mediante métricas como error cuadrático medio (ECM), ahorro de agua y estabilidad del sistema.
- Documentación técnica y monografía con los hallazgos, metodología y recomendaciones.

El impacto esperado se proyecta en tres dimensiones:

- Tecnológica: fomentar el uso de controladores predictivos avanzados en agricultura de precisión, promoviendo prácticas de riego más eficientes y sostenibles.
- Académica: contribuir al desarrollo de metodologías que integran modelado físico, inteligencia artificial y control automatizado, fortaleciendo líneas de investigación en ingeniería de sistemas y control.
- Social y ambiental: apoyar el manejo responsable del recurso hídrico en zonas rurales y optimizar la productividad de los cultivos de papa, reduciendo pérdidas asociadas al riego ineficiente.

El presente anteproyecto contempla varias limitaciones que deben reconocerse:

- Disponibilidad y calidad de datos: el modelo depende de series temporales de humedad del suelo, precipitación, radiación y riego. La ausencia de datos continuos o su baja resolución puede afectar la identificación de parámetros y el entrenamiento de la red neuronal residual.
- Simplificación del modelo físico: el balance hídrico se modela mediante una ecuación diferencial reducida que no considera procesos más complejos como heterogeneidad espacial, redistribución vertical detallada o dinámica del potencial matricial.



UNIVERSIDAD DISTRITAL
FRANCISCO JOSÉ DE CALDAS
Acreditación Institucional de Alta Calidad

UNIVERSIDAD DISTRITAL FRANCISCO JOSÉ DE CALDAS FACULTAD DE INGENIERÍA

FORMATO DE PROPUESTA MODALIDAD GRADO



Facultad de Ingeniería
Universidad Distrital

- Validación únicamente en simulación: dado que el alcance del proyecto es académico, el controlador MPC no se implementará en campo, por lo que la evaluación se realizará únicamente mediante simulaciones numéricas en MATLAB y CasADi.
- No linealidad y costo computacional: la formulación del MPC con un modelo grey-box puede requerir tiempos de cómputo elevados, lo cual podría limitar la extensión del horizonte de predicción o la frecuencia de ejecución del controlador.

Estas limitaciones no reducen la viabilidad del proyecto, pero deben ser consideradas en la interpretación de los resultados y en la formulación de trabajos futuros.

PRODUCTOS DE BASE TECNOLÓGICA, DE INNOVACIÓN O CREACIÓN ESPERADA (MODALIDAD EMPRENDIMIENTO)

REFERENCIAS BIBLIOGRÁFICAS

- Abrougui, K., Gabssi, K., Mercatoris, B., Khemis, C., Amami, R., & Chehaibi, S. (2019). Prediction of organic potato yield using tillage systems and soil properties by artificial neural network (ANN) and multiple linear regressions (MLR). *Soil and Tillage Research*, 190, 202–208. <https://doi.org/10.1016/j.still.2019.01.011>
- Garg, B., Aggarwal, S., & Sokhal, J. (2018). Crop yield forecasting using fuzzy logic and regression model. *Computers & Electrical Engineering*, 67, 383–403. <https://doi.org/10.1016/j.compeleceng.2017.08.001>
- Hernández, N., Soto, F., & Caballero, A. (2009). Modelos de simulación de cultivos: Características y usos. *Cultivos Tropicales*, 30(1), 1–10. http://scielo.sld.cu/scielo.php?script=sci_arttext&pid=S0258-59362009000100014
- Jayaram, M. A., & Marad, N. (2013). Fuzzy inference systems for crop yield prediction. *Journal of Intelligent Systems*, 21(4), 363–372. <https://doi.org/10.1515/jisys-2012-0016>
- Khaki, S., & Wang, L. (2019). Crop yield prediction using deep neural networks. *Frontiers in Plant Science*, 10, 621. <https://doi.org/10.3389/fpls.2019.00621>
- López Seijas, T., Cabrera Pérez, J., Hernández, A., & Arias, M. (2010). Adecuación de un modelo de simulación de cultivo para la predicción del crecimiento y producción del arroz en el sur de La Habana. *Revista Ciencias Técnicas Agropecuarias*, 19(1), 90–95. http://scielo.sld.cu/scielo.php?script=sci_arttext&pid=S0258-59362010000100014
- Pascual, I. de los A., Ramírez, J. L., & Ortiz, A. (2016). Métodos de inteligencia artificial para la predicción del rendimiento y calidad de gramíneas. *REDVET. Revista Electrónica de Veterinaria*, 17(12), 1–9. <http://www.redalyc.org/articulo.oa?id=63649052026>
- Rashid, M., Bari, B., Yusup, Y., Kamaruddin, M., & Khan, N. (2021). A comprehensive review of crop yield prediction using machine learning approaches with special emphasis on palm oil yield prediction. *IEEE Access*, 9, 72390–72410. <https://doi.org/10.1109/ACCESS.2021.3075159>
- Servín Palestina, M., Salazar, R., López-Cruz, I., Medina-García, G., & Cid-Ríos, J. (2022). Predicción de la producción y rendimiento de frijol con modelos de redes neuronales



UNIVERSIDAD DISTRITAL
FRANCISCO JOSÉ DE CALDAS
Acreditación Institucional de Alta Calidad

UNIVERSIDAD DISTRITAL FRANCISCO JOSÉ DE CALDAS
FACULTAD DE INGENIERÍA

FORMATO DE PROPUESTA MODALIDAD GRADO



Facultad de Ingeniería
Universidad Distrital

artificiales y datos climáticos. *Biotecnia*, 24(2), 104–111.

<https://doi.org/10.18633/biotecnia.v24i2.1664>

- Stathakis, D., Savin, I., & T., A. (2006). Neuro-fuzzy modeling for crop yield prediction. *Environmental Modelling & Software*, 21(10), 1432–1440. <https://doi.org/10.1016/j.envsoft.2005.07.013>
- Bramburger, J. J., et al. (2020). Learning dynamics with recurrent neural networks.
- Brunton, S. L., & Kutz, J. N. (2019). *Data-Driven Science and Engineering*. Cambridge UP.
- Pelak, N., Revelli, R., & Porporato, A. (2017). A dynamical systems framework for crop models. <https://doi.org/10.1016/j.ecolmodel.2017.10.003>
- Hornik, K. (1991). *Approximation capabilities of multilayer feedforward networks*. *Neural Networks*, 4(2), 251–257. [https://doi.org/10.1016/0893-6080\(91\)90009-T](https://doi.org/10.1016/0893-6080(91)90009-T)
- Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press.
- Potato Research. (2024). *Potato yield prediction research based on improved artificial neural networks using Whale Optimization Algorithm*. European Association for Potato Research. Recuperado de <https://www.eapr.net/publications/potato-research/potato-yield-prediction-research-based-improved-artificial-neural>
- van Voorn, G. A. K., Boer, M. P., Truong, S. H., Friedenbergh, N. A., Gugushvili, S., McCormick, R., Bustos Korts, D., Messina, C. D., & van Eeuwijk, F. (2023). *A conceptual framework for the dynamic modeling of time-resolved phenotypes for sets of genotype-environment-management combinations: A model library*. *Frontiers in Plant Science*, 14, 1172359. <https://doi.org/10.3389/fpls.2023.1172359>
- Marcillo-Paguay, C. A., Benavides-Cardona, C. A., Ramos-Zambrano, H. S., & Romero, J. V. (2022). *Respuesta agronómica y económica de papa (Solanum tuberosum subsp. andigena) a la fertilización diferencial en cuatro ambientes de Nariño, Colombia*. *Revista Colombiana de Ciencias Hortícolas*, 16(2), e13559. <https://doi.org/10.17584/rcch.2022v16i2.13559>
- Kautz, T., & Hoffmann, H. (2024). *Deep Rooting as an Indicator of Deep Soil Water and N Uptake in Potato*. *Potato Research*. Springer. <https://link.springer.com/article/10.1007/s11540-024-09802-4>
- Chen, X., Li, Z., & Wang, J. (2022). *Improving Potato Yield, Water Productivity and Nitrogen Use Efficiency by Managing Irrigation Based on Potato Root Distribution*. *International Journal of Plant Production*. Springer. <https://link.springer.com/article/10.1007/s42106-022-00205-4>
- Allen, R. G., Pereira, L. S., Raes, D., & Smith, M. (2006). *Evapotranspiración del cultivo Guías para la determinación de los requerimientos de agua de los cultivos* <https://openknowledge.fao.org/handle/20.500.14283/x0490s>
- Ireson, A. M., Spiteri, R. J., Clark, M. P., & Mathias, S. A. (2023). *A simple, efficient, mass-conservative approach to solving Richards' equation (openRE, v1.0)*. *Geosci. Model Dev.* <https://doi.org/10.5194/gmd-16-659-2023>
- Thorp, K. R. et al. (2022). *pyfao56: FAO-56 evapotranspiration in Python*. <https://doi.org/10.1016/j.softx.2022.101208>
- Mondaca-Duarte, F. D., et al. (2020). *Performance analysis method for model-based irrigation — Richards + ET in MATLAB (PMC article with algorithmic details)*. <https://doi.org/10.1016/j.mex.2020.101075>



UNIVERSIDAD DISTRITAL
FRANCISCO JOSÉ DE CALDAS
Acreditación Institucional de Alta Calidad

UNIVERSIDAD DISTRITAL FRANCISCO JOSÉ DE CALDAS
FACULTAD DE INGENIERÍA

FORMATO DE PROPUESTA MODALIDAD GRADO



Facultad de Ingeniería
Universidad Distrital

- Shang, C., et al. (2019). *Robust Model Predictive Control of Irrigation Systems with Active Uncertainty Learning and Data Analytics* (arXiv) <https://doi.org/10.48550/arXiv.1810.05947>
- Rossini et al. (2021). *Predicting rootzone soil moisture from surface observations*. <https://dx.doi.org/10.1002/saj2.20319>
- Ljung, L. (1999). *System Identification: Theory for the User* (2nd ed.). Prentice Hall. https://www.mit.bme.hu/data/migrate/oktatas/targyak/9132/Ljung_L_System_Identification_Theory_for_User-ed2.pdf
- Rawlings, J. B., & Mayne, D. Q. (2009). *Model Predictive Control: Theory and Design*. Nob Hill Publishing.
- Camacho, E. F., & Bordons, C. (2007). *Model Predictive Control* (2nd ed.). Springer. <https://link.springer.com/book/10.1007/978-0-85729-398-5>

PROPIEDAD INTELECTUAL: Declaramos que conocemos el reglamento de propiedad intelectual vigente en la Universidad Distrital Francisco José de Caldas.

Miguel Angel Panqueva

Miguel Angel Panqueva Pulido

Andrés Felipe Arias Guevara

Escaneado con CamScanner

Andrés Felipe Arias Guevara

Duván Téllez

Duván Andrés Téllez Castro

NOMBRE Y FIRMA DEL DOCENTE QUE
AVALA LA PROPUESTA