

MODELAMIENTO Y CONTROL DE UN CASO DE ESTUDIO SOBRE EL RIEGO DEL CULTIVO DE PAPA EN COLOMBIA

Subtítulo si aplica

Andrés Felipe Arias Guevara

Código: 20192020147

Miguel Angel Panqueva Pulido

Código: 20201020174

*Trabajo de Grado para optar al título de
Ingeniero de Sistemas*

Director: Duván Andrés Téllez Castro

Bogotá, D.C.

Mes de Año

Página de aceptación

Dedicatoria

Dedicatorias a personas importantes

Agradecimientos

Agradecimientos a personas, instituciones y proyectos que apoyaron el desarrollo de la investigación.

Resumen Ejecutivo

Contexto: La agricultura de precisión en Colombia enfrenta retos por la variabilidad climática y el uso ineficiente del recurso hídrico, especialmente en cultivos base como la papa (*Solanum tuberosum*). Los métodos de riego tradicionales no logran adaptarse a las dinámicas no lineales del suelo.

Objetivo: Diseñar e implementar un esquema de control predictivo (MPC) basado en un modelo híbrido Grey-Box para regular de manera óptima la humedad del suelo en un cultivo de papa, integrando leyes físicas y redes neuronales residuales.

Metodología: Se utilizó una arquitectura de caja gris donde un modelo de balance hídrico de primer orden se combina con una red neuronal entrenada para compensar errores de modelado. El controlador se formuló como un problema de optimización no lineal resuelto mediante la herramienta CasADi en MATLAB.

Resultados: Las simulaciones muestran que el MPC anticipa perturbaciones climáticas (precipitaciones) y mantiene los niveles de humedad dentro de los umbrales de capacidad de campo y punto de marchitez específicos para la papa, evitando el estrés hídrico.

Conclusiones: El enfoque Grey-Box mejora la precisión del control respecto a modelos puramente físicos, demostrando ser una herramienta robusta para la gestión inteligente del agua en la agricultura.

Palabras clave: Control Predictivo (MPC), Modelo Grey-Box, Redes Neuronales, Cultivo de Papa, CasADi.

Abstract

Context: Precision agriculture in Colombia faces significant challenges due to climate variability and the inefficient use of water resources, particularly in staple crops such as the potato (*Solanum tuberosum*). Traditional irrigation methods often lack the precision needed to adapt to the non-linear dynamics of soil moisture.

Objective: To design and implement a Model Predictive Control (MPC) scheme based on a hybrid Grey-Box model to optimally regulate soil moisture in a potato crop, integrating physical laws with residual neural networks.

Methodology: A grey-box architecture was employed, where a first-order water balance physical model is combined with a neural network trained to compensate for modeling uncertainties. The control problem was formulated as a non-linear optimization task and solved using the CasADi toolkit within the MATLAB environment.

Results: Simulation results demonstrate that the MPC anticipates climatic disturbances (precipitation) and maintains soil moisture levels within the specific field capacity and permanent wilting point thresholds for potato crops, thereby avoiding water stress and over-irrigation.

Conclusions: The Grey-Box approach enhances control precision compared to purely physical models, proving to be a robust technical solution for smart water management in agricultural contexts.

Keywords: Model Predictive Control (MPC), Grey-Box Modeling, Neural Networks, Potato Crop, CasADi.

Índice general

Agradecimientos	3
Resumen Ejecutivo	4
Abstract	5
Lista de Figuras	8
Lista de Tablas	9
1 Introducción	10
1.1 Planteamiento del Problema	12
1.2 Justificación	13
1.3 Objetivos	14
1.3.1 Objetivo General	14
1.3.2 Objetivos Específicos	14
1.4 Alcance	15
1.4.1 Limitaciones del Estudio	15
2 Marco de Referencia	17
2.1 Antecedentes	17
2.1.1 Parametrización de la Dinámica de Raíces y Humedad	17
2.1.2 Modelos de Referencia Física y Mecanística	17
2.1.3 Modelado del Crecimiento y Acople Biológico	18
2.1.4 Contexto Regional y Aplicaciones en Colombia	18
2.2 Estado del Arte	19
2.3 Identificación de Brechas Técnicas	19
2.4 Fundamentos Teóricos	20
2.4.1 Dinámica del Sistema Suelo-Planta y Balance Hídrico	20
2.4.2 Modelado Híbrido: Paradigma de Caja Gris (Grey-Box)	23

2.4.3	Redes Neuronales Residuales para Estimación de Errores	24
2.4.4	Control Predictivo basado en Modelo (MPC) No Lineal	26
2.4.5	Optimización Numérica y Computación Simbólica con CasADi	27
3	Metodología	29
3.1	Tipo de Investigación	29
3.2	Recolección y Preprocesamiento de Datos	30
3.3	Modelado Híbrido y Desarrollo de la Red Residual	31
3.4	Implementación del Controlador NMPC en CasADi	36
3.5	Escenarios de Evaluación y Métricas de Desempeño	38
3.5.1	Definición de Escenarios Climáticos	38
3.5.2	Índices de Desempeño y Validación	38
4	Desarrollo del Proyecto	40
4.1	Entorno de Desarrollo y Configuración Técnica	40
4.2	Implementación del Modelo Físico en MATLAB	41
4.3	Entrenamiento de la Red Neuronal Residual	41
4.4	Integración del Modelo Híbrido en el MPC	42
4.5	Configuración del Horizonte de Predicción y Restricciones	43
5	Resultados y Análisis	44
5.1	Resultados de la Identificación del Modelo Híbrido	44
5.2	Desempeño del Controlador en Escenarios Climáticos	44
5.3	Análisis de Consumo de Agua y Errores de Seguimiento	44
5.4	Comparativa con Métodos de Control Tradicionales	44
6	Conclusiones	45
6.1	Conclusiones sobre el Modelo Híbrido	45
6.2	Efectividad del Control Predictivo en el Riego	45
6.3	Recomendaciones y Trabajos Futuros	45
	Glosario	46
	Referencias	51

Índice de figuras

2.1	Esquema de la arquitectura híbrida Grey-Box: integración del modelo acoplado de segundo orden (humedad y biomasa) y la red neuronal residual para la compensación de errores sistemáticos en la dinámica del cultivo.	24
3.1	Arquitectura de la red neuronal residual propuesta ($5 \times 16 \times 8 \times 2$).	35

Índice de cuadros

Capítulo 1

Introducción

La gestión eficiente del recurso hídrico en la agricultura constituye un desafío prioritario frente a la creciente demanda de alimentos, la variabilidad climática y la restricción de fuentes de agua dulce. La agricultura de riego consume una parte sustancial del agua disponible a nivel mundial, por lo que mejorar la eficiencia en el uso del agua es indispensable para la seguridad alimentaria y la sostenibilidad ambiental [Kijne et al., 2003, SOL, 2022, UNW, 2021]. Dentro de este contexto, los métodos y tecnologías de riego deben evolucionar desde prácticas basadas en calendarios fijos y reglas empíricas hacia estrategias capaces de ajustar el aporte hídrico en función del estado real del suelo y de las predicciones climáticas [Evans and Sadler, 2008, Adeyemi et al., 2017, da Silva et al., 2020].

La papa es un cultivo estratégico en la dieta y en la economía rural de Colombia: su productividad impacta de manera directa la seguridad alimentaria y el ingreso de pequeños y medianos productores. En regiones productoras como Cundinamarca y Boyacá la papa concentra una fracción importante de la producción nacional y, por tanto, hace especialmente relevante la adopción de prácticas de riego que optimicen la eficiencia hídrica y la estabilidad del rendimiento [Valderrama et al., 2023, Corpus Arrieta, 2019, Barrera-Rodríguez et al., 2025]. El tubérculo presenta alta sensibilidad a condiciones de déficit hídrico —que reducen fotosíntesis y formación de tubérculo— y a excesos de humedad —que provocan lixiviación de nutrientes y riesgos de encharcamiento—; por ello, el manejo fino de la humedad en la zona radicular es crítico para obtener rendimientos y calidad comercial adecuados [Daryanto et al., 2017, Ploschuk et al., 2018, Djaman et al., 2021].

Históricamente, el riego en sistemas agrícolas se realizó mediante técnicas por gravedad (surcos, canales, inundación) con bajos niveles de eficiencia y escaso control temporal. Estas prácticas, junto con la falta de realimentación de variables de estado del suelo, conducen con frecuencia a sobre-irrigación o riego insuficiente [Evans and Sadler, 2008]. En las últimas décadas se han adoptado sistemas tecnificados (riego por goteo y aspersión) y soluciones de sensorización que permiten monitoreo continuo de humedad, temperatura y variables climáticas; no obstante, la

mayoría de aplicaciones comerciales siguen operando de forma reactiva, activando el riego cuando se superan umbrales fijos en lugar de anticipar perturbaciones o incorporar objetivos agronómicos y restricciones físicas en la toma de decisiones [Adeyemi et al., 2017, ?, da Silva et al., 2020].

La metodología FAO-56, basada en la ecuación de Penman–Monteith, constituye un referente global para estimar la evapotranspiración de referencia y las necesidades hídricas de los cultivos; sin embargo, su uso tradicional en programación de riego no incorpora siempre realimentación en tiempo real ni estrategias de control que mitiguen incertidumbres paramétricas y perturbaciones climáticas imprevistas [Allen et al., 1998]. Frente a estas limitaciones, el Control Predictivo Basado en Modelo (MPC) ofrece un marco robusto para integrar un modelo dinámico del sistema, predicciones meteorológicas y restricciones físicas (por ejemplo capacidad de campo, límites de caudal de riego) en un problema de optimización receding-horizon, permitiendo decisiones de riego anticipativas y con garantías operativas [Camacho and Bordons, 2013, Bwambale et al., 2024, Liu et al., 2025]. Estudios recientes demuestran que MPC puede reducir significativamente el consumo de agua manteniendo o mejorando la producción en comparación con prácticas convencionales [Bwambale et al., 2023a, Liu et al., 2025].

No obstante, los modelos físicos simplificados del balance hídrico presentan errores por heterogeneidad de suelos, variación de parámetros y procesos no representados (p. ej. percolación no lineal, variación espacial de K_c). Para abordar esta brecha, los enfoques Grey-Box combinan la estructura física interpretable del balance hídrico con componentes de aprendizaje (por ejemplo redes neuronales residuales) que modelan el residuo entre la dinámica real y la predicción física. Este enfoque híbrido conserva la interpretabilidad y la consistencia física del sistema, mientras mejora la capacidad predictiva y la robustez frente a incertidumbres [Islam et al., 2025, Wang et al., 2024]. La incorporación de un modelo Grey-Box dentro del horizonte predictivo del MPC posibilita una planificación de riego que aprovecha tanto las leyes físicas como la información derivada de datos históricos y sensores en campo.

En el caso de la papa, investigaciones aplicadas y revisiones han documentado el beneficio del riego tecnificado (por ejemplo goteo) sobre la eficiencia del uso del agua y el rendimiento, así como la importancia de estimar coeficientes de cultivo específicos (K_c) y adaptar la programación a las condiciones locales del valle andino [Medina et al., 2024, Quispe-Rodríguez et al., 2020, Djaman et al., 2021]. Además, diagnósticos y planes productivos desarrollados por entidades nacionales resaltan la necesidad de fortalecer prácticas de manejo hídrico en cadenas productivas como la papa para aumentar competitividad y sostenibilidad [Valderrama et al., 2023].

Esta monografía propone, implementa y evalúa un esquema de control predictivo para el riego del cultivo de papa basado en un modelo Grey-Box del balance hídrico. El trabajo integra: (i) un modelo dinámico de segundo orden que describe la interacción suelo-planta, vinculando el balance hídrico en la zona radicular con la evolución de la biomasa del cultivo; (ii) una etapa de identificación residual

mediante redes neuronales para capturar discrepancias sistemáticas y dinámicas no modeladas; y (iii) un controlador MPC que incorpora predicciones meteorológicas y restricciones agronómicas. La estructura del documento es la siguiente: el Capítulo 2 presenta el marco teórico y la caracterización agronómica del cultivo; el Capítulo 3 detalla la metodología de modelado y la formulación del controlador; el Capítulo 4 desarrolla la implementación computacional y los experimentos de simulación; el Capítulo 5 muestra resultados y análisis; y el Capítulo 6 discute conclusiones y recomendaciones para validación experimental y escalamiento.

1.1. Planteamiento del Problema

El principal obstáculo para la automatización y optimización del riego en la agricultura de precisión radica en la naturaleza intrínsecamente no lineal, estocástica y multivariable de la dinámica de la humedad del suelo. Esta complejidad se manifiesta en la interacción continua entre el sistema suelo-planta-atmósfera, donde variables como la conductividad hidráulica, la porosidad y la tasa de evapotranspiración cambian no solo en el tiempo, sino también en el espacio.

Tradicionalmente, la ingeniería ha intentado abordar este fenómeno mediante modelos de Caja Blanca.^o puramente físicos, fundamentados en leyes de conservación de masa y energía, como la ecuación de Richards. Sin embargo, como señala [Ljung \[1999\]](#), estos modelos requieren una parametrización exhaustiva y un conocimiento profundo de las condiciones iniciales que, en la práctica agrícola real, resultan impracticables o extremadamente costosos de obtener. La dependencia de parámetros estáticos en entornos dinámicos provoca que los modelos físicos pierdan precisión ante cambios súbitos en la estructura del suelo o ante perturbaciones climáticas no modeladas, limitando su utilidad en sistemas de control en tiempo real.

Por otro lado, el auge de la ciencia de datos ha impulsado enfoques de “Caja Negra”. Si bien estas arquitecturas, basadas en redes neuronales o algoritmos de aprendizaje profundo, son capaces de mapear relaciones complejas sin conocer la física subyacente, presentan una carencia crítica de interpretabilidad física. Para un sistema de soporte de decisiones en un cultivo estratégico como la papa, depender de un modelo que no garantiza consistencia física (como balances de masa coherentes) representa un riesgo operativo, ya que el controlador podría generar acciones de riego que, aunque matemáticamente óptimas para la red, sean físicamente inviables o perjudiciales para la fisiología de la planta [Bwambale et al. \[2022\]](#).

Esta dicotomía entre el rigor físico y la flexibilidad de los datos genera ineficiencias críticas en los sistemas de control convencionales utilizados en Colombia. En el contexto específico del cultivo de papa en regiones andinas como Cundinamarca y Boyacá, el problema se agrava inicialmente por la marcada variabilidad climática local, donde la transición errática entre periodos de sequía e intensas precipitaciones —derivada de los fenómenos de El Niño y La Niña— invalida los

calendarios de riego fijos. Esta situación evidencia que un sistema puramente reactivo, limitado a la medición de la humedad actual, es incapaz de anticipar eventos climáticos inminentes, lo que deriva inevitablemente en el desperdicio de agua y la lixiviación de fertilizantes.

A esta problemática se suma una brecha tecnológica significativa en el modelado, dado que la mayoría de las soluciones de riego tecnificado disponibles en el mercado operan bajo lógicas de control On-Off o proporcionales simples, ignorando de forma predictiva las restricciones físicas fundamentales, como la capacidad de campo y el punto de marchitez permanente del suelo. Finalmente, existe un desacople crítico entre el desarrollo biológico del cultivo y la demanda hídrica estimada; mientras los modelos tradicionales suelen emplear coeficientes de cultivo (K_c) estáticos, el consumo real de agua depende de la evolución dinámica de la biomasa. Ignorar esta interacción dinámica entre el suelo y la planta genera errores de predicción acumulativos que limitan la capacidad del sistema para gestionar la demanda hídrica real en el cultivo de papa.

Como se identificó en la fase de anteproyecto de esta investigación, existe una necesidad latente de modelos que logren un equilibrio: que conserven la estructura de las leyes físicas del balance hídrico pero que posean la capacidad adaptativa de la inteligencia artificial para corregir sus propias deficiencias. La ausencia de un esquema de control que integre estas dos dimensiones en el cultivo de papa no solo afecta la rentabilidad y competitividad del agricultor colombiano, sino que vulnera la sostenibilidad de los ecosistemas al realizar una gestión subóptima de un recurso cada vez más escaso.

1.2. Justificación

La producción de papa en Colombia es un pilar de la seguridad alimentaria y el sustento económico de miles de familias rurales, especialmente en la región andina. Sin embargo, este sector enfrenta desafíos críticos derivados de la variabilidad climática y la gestión ineficiente de los recursos hídricos. La transición hacia una agricultura de precisión no es solo una necesidad ambiental para la preservación de cuencas hidrográficas, sino también un imperativo económico para mejorar la competitividad del productor local.

Desde la perspectiva de la ingeniería de sistemas y el control automático, el manejo del riego presenta una problemática técnica compleja: la dificultad de modelar fielmente la dinámica del suelo mediante leyes físicas puras sin incurrir en costos computacionales excesivos o requerir parametrizaciones impracticables en campo. Los métodos de control convencionales, basados en umbrales estáticos o lógicas reactivas, no logran anticipar perturbaciones climáticas ni optimizar el uso del agua bajo criterios de sostenibilidad.

La relevancia de este trabajo radica en la implementación de una arquitectura de control predictivo no lineal (NMPC) sustentada en un modelo híbrido *Grey-Box*. Este enfoque permite combinar

la interpretabilidad de los modelos físicos de balance hídrico con la capacidad de corrección de las redes neuronales residuales. Al integrar herramientas de optimización avanzadas como CasADi dentro del ciclo de control, esta investigación aporta una solución tecnológica robusta orientada, en primer lugar, a optimizar el recurso hídrico mediante decisiones anticipativas basadas en horizontes de predicción que reducen el desperdicio.

Asimismo, la propuesta busca cerrar la brecha tecnológica actual al ofrecer modelos capaces de adaptarse a las incertidumbres del entorno sin requerir instrumentación de laboratorio de alto costo. Este avance se complementa con un modelado acoplado de alta fidelidad que, al incorporar la biomasa como una variable de estado dinámica, permite que el sistema de control gestione el agua en el suelo comprendiendo la demanda biológica real del cultivo de papa; de este modo, se logra una optimización que maximiza el desarrollo vegetal mientras se minimiza el estrés hídrico. Finalmente, este trabajo fortalece la investigación académica al aplicar teorías modernas de identificación de sistemas y control óptimo a problemas de alto impacto social y ambiental en el contexto colombiano.

En conclusión, el desarrollo de esta monografía no solo representa un avance en la aplicación de técnicas de inteligencia artificial y control en el agro, sino que propone un marco de trabajo escalable que responde a las necesidades actuales de eficiencia y sostenibilidad en la cadena productiva de la papa.

1.3. Objetivos

1.3.1. Objetivo General

Desarrollar un modelo Grey-Box basado en la ecuación diferencial del balance hídrico del suelo, complementado con una red neuronal residual para capturar dinámicas no modeladas, con el fin de implementar un esquema de control predictivo basado en modelo (MPC) que permita optimizar la aplicación de riego en el cultivo de papa en Colombia.

1.3.2. Objetivos Específicos

- Analizar antecedentes científicos sobre modelado físico e inteligencia artificial aplicados al control del riego en papa.
- Formular el modelo físico del proceso mediante la ecuación diferencial del balance hídrico del suelo, especificando y justificando los parámetros de entrada requeridos (I, P, ETc, D y Zr), con base en el principio de conservación de masa y la metodología FAO-56.
- Entrenar una red neuronal residual que permita capturar las dinámicas no modeladas por la ecuación física, aprendiendo los errores sistemáticos del modelo base.

- Integrar a EDO física y la red neuronal residual en una arquitectura Grey-Box e implementar un esquema de control predictivo (MPC) no lineal.
- Simular y validar el desempeño del modelo mediante métricas estadísticas y análisis comparativo frente a modelos puramente físicos y data-driven.
- Documentar el proceso, los resultados y la aplicabilidad del modelo como herramienta para la gestión inteligente del riego agrícola.

1.4. Alcance

La presente investigación se centra en el diseño, desarrollo y validación en entorno de simulación de un esquema de control predictivo no lineal (NMPC) asistido por modelamiento híbrido *Grey-Box*, aplicado a la regulación de la humedad en un cultivo de papa (*Solanum tuberosum*). El alcance de este trabajo se delimita, en primera instancia, por el desarrollo de un modelo híbrido que integra una ecuación diferencial de balance hídrico y una de crecimiento logístico de biomasa. Este sistema de segundo orden representa la interacción suelo-planta, compensando mediante redes neuronales residuales las deficiencias tanto en la física del suelo como en la estimación del coeficiente de cultivo dinámico. Posteriormente, esta arquitectura se integra dentro de un esquema NMPC utilizando el marco de optimización **CasADi**, con el objetivo de mantener la humedad del suelo dentro de rangos agronómicos óptimos y minimizar simultáneamente el consumo del recurso hídrico.

La evaluación del desempeño del controlador se realiza estrictamente mediante simulaciones computacionales en el entorno **MATLAB**, donde se validará el sistema a través del análisis de trayectorias dinámicas y métricas cuantitativas como el Error Cuadrático Medio (ECM) y el porcentaje de ahorro de agua. Como parte de los resultados, se entregará el código fuente desarrollado como evidencia de la implementación lógica del sistema. Finalmente, este proyecto busca fortalecer las líneas de investigación en control avanzado y agricultura de precisión de la Universidad Distrital, promoviendo el uso de herramientas de optimización dinámica en problemas de alto impacto y sostenibilidad ambiental.

1.4.1. Limitaciones del Estudio

Para la correcta interpretación de los resultados, es necesario reconocer las fronteras técnicas del presente trabajo. Inicialmente, el balance hídrico se fundamenta en una simplificación del sistema físico mediante una ecuación diferencial reducida, por lo cual no se consideran procesos de alta complejidad como la heterogeneidad espacial extrema del suelo o la redistribución vertical profunda. Asimismo, la precisión de la red neuronal residual está intrínsecamente sujeta a la

disponibilidad y resolución de las series temporales de humedad, precipitación y riego, dado que cualquier incertidumbre en los datos de entrada puede afectar la capacidad de generalización del modelo híbrido.

Desde la perspectiva computacional, la naturaleza no lineal del modelo *Grey-Box* implica que la resolución del problema de optimización en el MPC puede requerir tiempos de cómputo significativos, lo que limita la extensión del horizonte de predicción en la configuración actual. Es importante subrayar que el sistema se limita estrictamente al análisis del comportamiento dinámico en software, por lo que no contempla la implementación en hardware físico ni pruebas en campo real. Por último, cabe aclarar que el modelo de crecimiento de biomasa adoptado es de naturaleza logística-funcional y está orientado exclusivamente a mejorar la predicción del consumo hídrico; por lo tanto, no sustituye a un modelo agronómico de partición de asimilados ni pretende predecir la calidad específica del tubérculo, enfocándose únicamente en la relación biomasa-evapotranspiración para la optimización del riego.

Capítulo 2

Marco de Referencia

2.1. Antecedentes

La construcción del modelo híbrido Grey-Box para el cultivo de papa se fundamenta en investigaciones previas que han delimitado tanto los parámetros físicos del sistema suelo-planta como las metodologías de estimación hídrica.

2.1.1. Parametrización de la Dinámica de Raíces y Humedad

El establecimiento de la profundidad efectiva de raíces (Z_r) es un factor crítico para la precisión del balance hídrico diferencial. [Kautz and Hoffmann, 2024] determinaron mediante minirhizotrones que, aunque la papa puede explorar estratos de hasta 1.8 m, la mayor actividad se concentra en zonas más superficiales. En concordancia, [Ahmad and Hanjra, 2019] establecieron que en suelos arenoso-limosos, el 85 % de la extracción de agua ocurre en los primeros 0.4 m, proporcionando una base sólida para la parametrización de Z_r en el modelo de esta monografía.

Complementariamente, el trabajo de [Rossini and Patrignani, 2021] aporta un método práctico para estimar la humedad en todo el perfil a partir de datos superficiales mediante filtros exponenciales, lo que valida la posibilidad de utilizar modelos de complejidad reducida para representar sistemas dinámicos complejos.

2.1.2. Modelos de Referencia Física y Mecánica

En cuanto al modelado del transporte de agua, los antecedentes oscilan entre el rigor físico y la viabilidad computacional. [Ireson et al., 2023] desarrollaron la herramienta *openRE* para resolver la ecuación de Richards de forma eficiente; no obstante, su enfoque sigue siendo demandante para aplicaciones de control en tiempo real. Como alternativa, [Thorp et al., 2022] con la librería

pyFAO56 demuestra que el método de balance hídrico de la FAO-56 es una herramienta robusta y práctica para la gestión del riego cuando se integra en entornos de programación modernos.

Finalmente, el marco conceptual de [van Voorn et al., 2023] sobre modelos fenomenológicos basados en ecuaciones diferenciales ordinarias (ODE) refuerza la elección de una estructura determinista simple para capturar las dinámicas de crecimiento, permitiendo que la complejidad sea gestionada por componentes de aprendizaje automático.

2.1.3. Modelado del Crecimiento y Acople Biológico

La literatura reciente enfatiza que el balance hídrico no puede aislarse del desarrollo del cultivo. [Yang et al., 2019] introdujeron el modelo *CropSPAC*, el cual demuestra que la integración de un módulo de crecimiento dinámico (basado en biomasa o LAI) mejora la precisión de la evapotranspiración real en un 15 % frente a modelos estáticos. Para el caso específico de la papa, [Yang et al., 2023] validaron que el crecimiento de la biomasa sigue una trayectoria logística sigmoidea con un ajuste $R^2 > 0,95$, proporcionando una estructura matemática ideal para ser integrada como un segundo estado en sistemas de control predictivo.

2.1.4. Contexto Regional y Aplicaciones en Colombia

A nivel nacional, la tecnificación del riego ha cobrado relevancia mediante el desarrollo de prototipos adaptados a las condiciones edafoclimáticas locales. [Valenzuela Ojeda, 2023], en la Universidad Mariana, diseñó un prototipo inteligente de control de riego tecnificado específicamente para el cultivo de papa, integrando una red de sensores para el monitoreo remoto de la humedad. Este trabajo resalta la viabilidad de utilizar plataformas de hardware abierto para la gestión hídrica, aunque identifica la necesidad de algoritmos de control que superen las lógicas reactivas convencionales.

Por su parte, en la Universidad Distrital Francisco José de Caldas, [García Moreno et al., 2013] desarrollaron un modelo a escala de un sistema de riego automatizado alimentado por energía solar fotovoltaica. Esta investigación sentó las bases institucionales para la integración de energías renovables y automatización en el sector agroindustrial colombiano, destacando la importancia de la gestión eficiente de los recursos naturales mediante el control de variables ambientales.

Finalmente, el estudio de [Marcillo-Paguay et al., 2022] en el departamento de Nariño subraya que la productividad de la papa (*Solanum tuberosum subsp. andigena*) depende críticamente de la interacción entre la variedad, el tipo de suelo y las condiciones climáticas. Estos antecedentes regionales validan la necesidad de desarrollar sistemas de control adaptativos como el propuesto en esta monografía, que permitan ajustar el riego de forma precisa a las demandas específicas de la zona andina colombiana.

2.2. Estado del Arte

El estado del arte en la gestión hídrica de precisión se define actualmente por la convergencia entre el modelado físico tradicional y las técnicas de inteligencia artificial, orientadas hacia el control predictivo en tiempo real y la optimización de recursos.

A nivel internacional, la frontera del conocimiento en la estimación del balance hídrico está marcada por la asimilación de datos multifuente. [Olivera-Guerra et al., 2023] han demostrado que la aplicación del método FAO-56 de coeficiente dual, integrado con módulos de asimilación de datos a escala de distrito, permite capturar la variabilidad de las prácticas de riego con mayor precisión que los modelos estáticos tradicionales. Esta capacidad de ajuste dinámico es fundamental para sistemas que operan bajo condiciones climáticas cambiantes.

En cuanto a las estrategias de implementación, la validación de modelos en entornos controlados ha cobrado relevancia. [Bwambale et al., 2023b] evaluaron una estrategia de control de riego inteligente basada en modelos, demostrando una mejora significativa en la Eficiencia del Uso del Agua (WUE) y en la productividad de biomasa en cultivos de tomate. Este antecedente valida que el control basado en modelos (model-based control) no solo es teóricamente superior, sino que tiene efectos tangibles en el rendimiento agrícola.

Por otro lado, la integración de la Inteligencia Artificial para la predicción del rendimiento ha alcanzado niveles de optimización avanzados. Investigaciones recientes han implementado redes neuronales artificiales mejoradas mediante algoritmos de optimización (como el Whale Optimization Algorithm) para predecir la producción de papa con alta precisión [Potato Research, 2024], lo que subraya la tendencia de usar componentes de aprendizaje automático para gestionar la incertidumbre que los modelos físicos no logran capturar.

Finalmente, en el panorama nacional, el estado del arte muestra una adopción creciente de tecnologías IoT y control automático. [Cohen-Manrique et al., 2020] implementaron un sistema de gestión de riego en el departamento de Sucre utilizando controladores PID sintonizados y conectados a la nube. Si bien estos sistemas representan un avance en la automatización local, la brecha tecnológica actual reside en la transición de estas lógicas reactivas (PID) hacia esquemas de control predictivo no lineal (NMPC) que puedan integrarse con modelos de crecimiento dinámico, tal como se propone en esta investigación.

2.3. Identificación de Brechas Técnicas

Tras el análisis de los antecedentes y el estado del arte, se identifican tres brechas críticas que motivan el desarrollo de la presente investigación:

1. **Desconexión entre modelos físicos e IA:** La literatura reporta una división marcada entre

el uso de modelos mecanísticos como FAO-56 [Allen et al., 2006, Thorp et al., 2022], que son explicables pero rígidos, y modelos de aprendizaje profundo [Wang et al., 2024], que son precisos pero carecen de interpretación física. Existe una oportunidad limitada en el uso de estructuras *Grey-Box* que combinen la robustez de la física del suelo con la capacidad de corrección de las redes neuronales residuales.

2. **Predominancia de control reactivo en el contexto local:** En Colombia, la automatización del riego se ha centrado mayoritariamente en controladores PID y sistemas basados en umbrales fijos [Valenzuela Ojeda, 2023, Cohen-Manrique et al., 2020]. Estas técnicas no consideran el retardo temporal del sistema suelo-planta ni las predicciones climáticas, lo que limita la eficiencia hídrica en cultivos de alta sensibilidad como la papa.
3. **Escasez de aplicaciones de control predictivo (MPC) en pequeña escala:** Aunque el MPC es tendencia en el estado del arte internacional [Bwambale et al., 2024, Liu et al., 2025], su implementación suele estar restringida a grandes distritos de riego o entornos de simulación complejos. No se evidencia un marco de trabajo simplificado y de bajo costo computacional (como el propuesto mediante MATLAB y CasADi) adaptado específicamente a las variedades de papa y condiciones edafoclimáticas de la región andina colombiana.

La presente monografía aborda estas brechas mediante la integración de un modelo híbrido en un esquema de control predictivo no lineal (NMPC), buscando un equilibrio entre precisión técnica y aplicabilidad en el entorno agrícola nacional.

2.4. Fundamentos Teóricos

2.4.1. Dinámica del Sistema Suelo-Planta y Balance Hídrico

El diseño de un sistema de control de riego requiere la caracterización del suelo como un volumen de control donde se gestionan las entradas y salidas de agua. En este contexto, la dinámica hídrica se fundamenta en la capacidad de almacenamiento del estrato radicular y en la tasa de transferencia de humedad hacia la atmósfera.

Constantes Hidrofísicas del Suelo

Siguiendo los lineamientos de la metodología FAO-56 [Allen et al., 2006], la retención de humedad en la zona de raíces del cultivo de papa se define mediante tres límites críticos que determinan la disponibilidad de agua:

- **Capacidad de Campo (CC):** Representa el contenido máximo de agua que el suelo puede retener tras el drenaje por gravedad. Es el límite superior para el almacenamiento hídrico óptimo.
- **Punto de Marchitez Permanente (PMP):** Es el nivel de humedad por debajo del cual las raíces de la planta ya no pueden extraer agua, provocando daños irreversibles en el tejido vegetal.
- **Agua Fácilmente Disponible (RAW):** Es la fracción de agua que el cultivo puede extraer sin experimentar estrés hídrico, calculada como un porcentaje del agotamiento total permisible (p).

Balance de Masa y Discretización por Método de Euler

La dinámica hídrica en el suelo se fundamenta en el principio de conservación de masa dentro de un volumen de control definido por la profundidad efectiva de las raíces (Z_r). La variación temporal del contenido de humedad volumétrica (θ) se describe mediante una ecuación de continuidad, donde el cambio en el almacenamiento es igual a la suma de los flujos de entrada menos los flujos de salida.

Desde una perspectiva física, esta relación se expresa mediante la siguiente ecuación diferencial ordinaria (ODE):

$$\frac{d\theta}{dt} = \frac{1}{Z_r} [I(t) + P(t) - ET_c(t) - D(t)] \quad (2.1)$$

Donde:

- θ : Humedad volumétrica del suelo [m^3/m^3].
- $I(t), P(t)$: Tasas de flujo de entrada por riego y precipitación [$mm/día$].
- $ET_c(t)$: Tasa de salida por evapotranspiración real [$mm/día$].
- $D(t)$: Tasa de pérdida por drenaje profundo [$mm/día$].
- Z_r : Profundidad de control definida por el sistema radicular [mm].

Evapotranspiración del Cultivo (ET_c)

La demanda hídrica del sistema se estima mediante la metodología de coeficiente de cultivo simple de la FAO-56 [Allen et al., 2006]. Bajo este enfoque, la evapotranspiración real del cultivo

(ET_c) se determina ajustando la evapotranspiración de referencia (ET_o) a través de un coeficiente que captura las características fisiológicas de la especie y un factor de reducción por estrés hídrico:

$$ET_c = K_c \cdot K_s \cdot ET_o \quad (2.2)$$

Donde K_c representa el coeficiente de cultivo en sus distintas etapas fenológicas. El factor K_s varía entre 0 y 1, donde un valor de 1 indica ausencia de estrés. De acuerdo con la teoría de balance de masa en el suelo, este coeficiente se define en función del agotamiento del agua disponible total (TAW) y el agua fácilmente disponible (RAW). En términos de humedad volumétrica (θ), esta relación se expresa mediante la siguiente función lineal por tramos:

$$K_s(\theta) = \begin{cases} 1 & \text{si } \theta \geq \theta_{crit} \\ \frac{\theta - PMP}{\theta_{crit} - PMP} & \text{si } PMP < \theta < \theta_{crit} \\ 0 & \text{si } \theta \leq PMP \end{cases} \quad (2.3)$$

Donde θ_{crit} representa el umbral de humedad por debajo del cual el cultivo inicia el cierre estomático, definido por el factor de agotamiento permisible p como $\theta_{crit} = CC - p(CC - PMP)$.

Esta formulación teórica permite representar la reducción de la evapotranspiración a medida que el potencial matricial del suelo dificulta la extracción de agua por parte de las raíces.

Drenaje Profundo (D)

El drenaje representa la pérdida de agua que se desplaza más allá de la zona radicular debido a la fuerza de gravedad cuando la humedad excede la Capacidad de Campo (CC). En el modelado para control, esta variable actúa como un mecanismo de saturación del suelo; su caracterización es fundamental para que el controlador evite aplicaciones de riego que resulten en la lixiviación de nutrientes o en el desperdicio del recurso hídrico.

Acople Suelo-Planta: Dinámica de Biomasa (B)

La representación del sistema de riego no es completa sin considerar la evolución biológica del cultivo, la cual actúa como el motor de la demanda hídrica. En el marco de esta investigación, el desarrollo vegetativo de la papa se describe mediante un modelo de crecimiento logístico. Este enfoque permite que el coeficiente de cultivo (K_c) deje de ser un parámetro estático para convertirse en una función del vigor real de la planta.

De acuerdo con [Yang et al., 2023], la tasa de cambio de la biomasa aérea (B) se define por la siguiente ecuación diferencial:

$$\frac{dB}{dt} = r \cdot B(t) \left(1 - \frac{B(t)}{B_{max}}\right) - \delta \cdot B(t) \quad (2.4)$$

Donde r es la tasa de crecimiento intrínseca, B_{max} la biomasa máxima y δ el coeficiente de senescencia. Esta integración teórica es fundamental para el esquema de control propuesto, ya que transforma el balance hídrico en un **modelo acoplado de segundo orden**. Al vincular la disponibilidad de agua en el suelo con el crecimiento de la planta, el controlador MPC puede optimizar el riego no solo para mantener la humedad, sino para maximizar el desarrollo fisiológico del cultivo en sus fases críticas.

2.4.2. Modelado Híbrido: Paradigma de Caja Gris (Grey-Box)

En la ingeniería de procesos, la representación matemática de la interacción suelo-planta presenta desafíos debido a la alta no-linealidad de los procesos de evapotranspiración y crecimiento vegetal, así como la presencia de variables no observables. El enfoque de *Caja Gris* surge como una solución híbrida que combina el rigor científico de los modelos fenomenológicos con la capacidad de aprendizaje de los modelos basados en datos.

Taxonomía de Modelado

De acuerdo con la naturaleza del conocimiento disponible, se distinguen tres aproximaciones fundamentales para la representación del sistema:

- **Caja Blanca (Mecánicos):** Basados íntegramente en leyes físicas y balances de masa/energía (como la metodología FAO-56). Su ventaja es la interpretabilidad, pero pierden precisión ante perturbaciones no modeladas.
- **Caja Negra (Empíricos):** Basados en algoritmos de aprendizaje automático que encuentran patrones en los datos sin considerar la física subyacente. Carecen de explicabilidad técnica.
- **Caja Gris (Híbridos):** Integran el conocimiento parcial de la física del sistema con un componente de inteligencia artificial para capturar la dinámica residual.

Arquitectura de Modelado Residual

La estructura implementada en este proyecto se basa en un esquema de **Configuración Serie-Paralelo**. En esta configuración (Figura 2.1), el modelo fenomenológico (basado en balance hídrico y crecimiento logístico) actúa como el predictor principal. Simultáneamente, una Red Neuronal Artificial (ANN) se especializa en estimar el vector de error residual $\epsilon = [\epsilon_\theta, \epsilon_B]^T$. Este vector

representa la diferencia entre la realidad observada y la teoría simplificada del modelo físico, permitiendo compensar dinámicas complejas como la capilaridad del suelo o variaciones inesperadas en la tasa de crecimiento foliar.




Figura 2.1: Esquema de la arquitectura híbrida Grey-Box: integración del modelo acoplado de segundo orden (humedad y biomasa) y la red neuronal residual para la compensación de errores sistemáticos en la dinámica del cultivo.

Esta arquitectura híbrida garantiza que, ante una falla en los datos o un comportamiento errático de la red neuronal, el sistema mantenga una salida dictada por las leyes físicas (Caja Blanca), proporcionando una capa de seguridad intrínseca necesaria para aplicaciones reales en el campo.

2.4.3. Redes Neuronales Residuales para Estimación de Errores

La componente de inteligencia artificial del modelo híbrido se fundamenta en el uso de una Red Neuronal Artificial (ANN) de tipo *feed-forward*. En el paradigma de caja gris, esta red actúa como un aproximador universal de funciones encargado de modelar el vector de dinámicas residuales $\mathbf{r}(k) = [\epsilon_\theta, \epsilon_B]^T$ que las ecuaciones fenomenológicas de balance hídrico y crecimiento logístico no logran capturar integralmente.

Topología y Jerarquía de Capas

Para garantizar la capacidad de generalización del modelo sin incurrir en un sobreajuste (*overfitting*), se emplea una arquitectura de perceptrón multicapa (MLP). Esta disposición permite realizar una extracción progresiva de características desde el vector de entrada hacia la salida residual:

- **Capa de Entrada:** Recibe las variables dinámicas del sistema que presentan mayor correlación con el error del modelo físico: variables de estado (θ_k , B), acción de control (I_k) y perturbaciones climáticas (P , ET_c).
- **Capas Ocultas:** Nivel de procesamiento donde la red aprende representaciones internas de la dinámica no lineal mediante múltiples neuronas interconectadas.
- **Capa de Salida:** Genera el escalar de corrección aditiva que ajusta la predicción del modelo fenomenológico.

Dinámica de Activación y Propagación hacia Adelante

El procesamiento de la información ocurre mediante un mecanismo de propagación hacia adelante (*forward propagation*). En cada capa oculta, la señal sufre una transformación afín seguida de una activación no lineal. Para una neurona j en la capa i , la entrada neta $z_j^{(i)}$ y su correspondiente activación $a_j^{(i)}$ se definen como:

$$z_j^{(i)} = \sum_{k=1}^{n_{i-1}} \left(w_{jk}^{(i)} \cdot a_k^{(i-1)} \right) + b_j^{(i)} \quad (2.5)$$

$$a_j^{(i)} = \sigma(z_j^{(i)}) \quad (2.6)$$

Donde $w_{jk}^{(i)}$ es el peso sináptico y $b_j^{(i)}$ es el sesgo (*bias*). σ representa la función de activación no lineal, la cual permite que la red aprenda relaciones complejas entre las variables. Para el modelado de residuos, se emplea la función de activación **Tangente Hiperbólica** ($\tanh$) en las capas ocultas debido a su naturaleza simétrica respecto al origen, permitiendo representar desviaciones bidireccionales (excesos o déficit de humedad). Finalmente, la capa de salida emplea una activación lineal para permitir una corrección de magnitud física real sobre el balance global.

Integración y Mecanismo de Corrección Aditiva

Desde una perspectiva teórica, la red neuronal no busca reemplazar las leyes de conservación, sino complementarlas. El estado futuro del sistema se define por la superposición de la predicción física y la inferencia residual:

$$\mathbf{x}_{k+1} = \mathbf{f}_{phy} + \mathbf{r}_k \quad (2.7)$$

En esta estructura, $\mathbf{f}_{phy}$ representa la dinámica dictada por el conocimiento físico-biológico del sistema, mientras que $\mathbf{r}_k$ es el vector de corrección residual. Esta formulación permite que la inteligencia artificial absorba de manera integral la incertidumbre paramétrica y las dinámicas de

orden superior, manteniendo la interpretabilidad del modelo global sin comprometer su precisión ante fenómenos no modelados explícitamente.

2.4.4. Control Predictivo basado en Modelo (MPC) No Lineal

El Control Predictivo basado en Modelo (MPC, por sus siglas en inglés) es una estrategia de control avanzado que utiliza un modelo dinámico del proceso para pronosticar el comportamiento futuro de las variables de estado y calcular una secuencia de acciones de control óptimas. En el contexto del riego de precisión para el cultivo de papa, el MPC permite gestionar el recurso hídrico anticipando la demanda evaporativa y las perturbaciones climáticas.

Principio del Horizonte Deslizante

El funcionamiento del MPC se rige por el principio del horizonte deslizante (*Receding Horizon Control*). En cada instante de muestreo k , el controlador resuelve un problema de optimización en un horizonte de predicción N , obteniendo una secuencia de maniobras de riego $\{u_0, u_1, \dots, u_{N-1}\}$. De esta secuencia, únicamente se aplica la primera acción (u_0), descartando el resto y repitiendo el proceso en el siguiente paso $k + 1$ con la nueva medición de humedad.

Definición del Vector de Estados Acoplado

A diferencia de los esquemas de control hídrico convencionales que solo consideran la humedad del suelo, el NMPC propuesto opera sobre un vector de estados de segundo orden $x = [\theta, B]^T$. Esta configuración permite que el controlador entienda la relación biológica entre el consumo de agua y el crecimiento del cultivo. Al incluir la biomasa (B) como un estado, el optimizador puede ajustar las láminas de riego no solo en función del agotamiento actual, sino anticipando las necesidades futuras de una planta en crecimiento.

Función de Costo y Objetivos de Control

Para el sistema de riego acoplado, la función de costo J se formula como un problema de seguimiento de trayectoria multivariable con penalización del esfuerzo de control. El objetivo es minimizar la discrepancia entre el estado actual del sistema y el vector de referencia $x_{ref} = [\theta_{ref}, B_{max}]^T$, optimizando simultáneamente el uso del agua:

$$\min_U J = \underbrace{\sum_{k=1}^N \|x_k - x_{ref}\|_Q^2}_{\text{Seguimiento}} + \underbrace{\sum_{k=0}^{N-1} \|I_k\|_R^2}_{\text{Esfuerzo de Control}} \quad (2.8)$$

Donde $x_{ref} = [\theta_{ref}, B_{max}]^T$. En esta formulación:

- Q es una matriz de pesos diagonales $[q_\theta, q_B]$. El peso q_θ prioriza el confort hídrico para evitar el estrés, mientras que q_B incentiva al sistema a seguir la trayectoria de crecimiento potencial de la biomasa.
- R es el factor de penalización sobre el riego aplicado, encargado de minimizar el desperdicio de agua.

Restricciones de Estado y Control

Una de las ventajas fundamentales del MPC es su capacidad para manejar restricciones físicas y operativas de forma nativa. En este modelo acoplado, el problema de optimización queda sujeto a las siguientes desigualdades:

$$PMP \leq \theta_k \leq CC \quad (2.9)$$

$$0 \leq B_k \leq B_{max} \quad (2.10)$$

$$0 \leq I_k \leq I_{max} \quad (2.11)$$

Estas fronteras garantizan que el contenido de humedad se mantenga en el rango de confort hídrico y que la biomasa no exceda los límites biológicos esperados. Asimismo, se asegura que las láminas de riego aplicadas (I_k) sean técnicamente viables según la capacidad instalada del sistema de riego.

2.4.5. Optimización Numérica y Computación Simbólica con CasADi

La implementación práctica del controlador MPC requiere la resolución de un problema de Programación No Lineal (NLP) en cada paso de muestreo. Para este propósito, se utiliza el framework de optimización simbólica **CasADi**, integrado con el solucionador de punto interior **IPOPT**.

Diferenciación Automática y Modelado Simbólico

A diferencia de los métodos de derivación numérica tradicionales, CasADi emplea la técnica de **Diferenciación Automática (AD)** mediante grafos computacionales. Esto permite calcular las derivadas de primer y segundo orden (Gradientes y Hesiano) de la función de costo J y de las restricciones de dinámica del suelo con precisión de máquina.

El uso de variables simbólicas (SX) facilita la definición del modelo acoplado y la integración de la red neuronal residual dentro del grafo computacional. Esto permite que el optimizador reciba

expresiones analíticas exactas de la dinámica híbrida en lugar de aproximaciones, lo que reduce el error numérico y asegura la estabilidad del controlador incluso ante las no linealidades de la biomasa y el estrés hídrico.

Algoritmo de Punto Interior (IPOPT)

Para hallar la secuencia óptima de riego $u(k)$, se emplea el solucionador **IPOPT** (*Interior Point OPTimizer*). Este algoritmo está diseñado para resolver problemas de optimización no lineal a gran escala mediante un método de barrera logarítmica.

IPOPT es especialmente eficiente para el sistema de riego propuesto debido a:

- **Manejo de Restricciones:** Gestiona eficientemente los límites de capacidad de campo (CC), punto de marchitez (PMP) y los topes biológicos de la biomasa como barreras infranqueables en el espacio de estados.
- **Velocidad de Convergencia:** Gracias a la información del gradiente y del Hesiano proporcionada por CasADi, el algoritmo converge a la solución óptima en milisegundos, permitiendo una ejecución compatible con sistemas de tiempo real.
- **Robustez ante No Linealidades:** Es capaz de manejar de forma estable las funciones sigmoideas de lluvia, el drenaje suavizado y la naturaleza logística del crecimiento del cultivo de papa.

Esta combinación de herramientas constituye la infraestructura computacional que permite al modelo *Grey-Box* funcionar como un sistema de soporte a la decisión automatizado y preciso.

Capítulo 3

Metodología

3.1. Tipo de Investigación

El presente proyecto se enmarca bajo un enfoque de **investigación aplicada** con alcance **tecnológico y experimental**, orientado al desarrollo de una solución técnica para la optimización de procesos en sistemas de riego de precisión.

Dada la naturaleza del problema —la gestión no lineal del balance hídrico y el crecimiento vegetal—, la metodología se subdivide en tres ejes fundamentales:

- **Investigación Cuantitativa:** Se fundamenta en el análisis de datos climáticos y fenológicos mediante el procesamiento de series de tiempo, permitiendo la cuantificación de variables clave como el contenido de humedad (θ) y la tasa de crecimiento de biomasa (B).
- **Investigación de Modelado y Simulación (*In-Silico*):** Dada la imposibilidad de manipular físicamente las condiciones climáticas del campo durante la etapa de diseño, se emplea el paradigma de simulación numérica. Este enfoque permite evaluar la respuesta del controlador NMPC bajo diversos escenarios de estrés, garantizando la seguridad del cultivo antes de una posible implementación física.
- **Desarrollo Tecnológico:** Se enfoca en la síntesis de un sistema híbrido (Grey-Box) que combina leyes físicas de conservación de masa con modelos de aprendizaje profundo (ANN), integrados mediante herramientas de optimización simbólica (CasADi).

El carácter de esta investigación es, por tanto, **propositivo**, ya que no solo busca identificar la dinámica del sistema, sino controlar su comportamiento mediante la convergencia de algoritmos avanzados de optimización no lineal y técnicas de inteligencia artificial, validando su desempeño mediante el contraste de métricas de eficiencia hídrica.

3.2. Recolección y Preprocesamiento de Datos

El desempeño de la arquitectura *Grey-Box* depende de la calidad y representatividad de los datos utilizados tanto para la validación del modelo físico como para el entrenamiento de la red neuronal residual. En esta fase, se gestionan series de tiempo multivariantes que capturan la interacción entre el forzamiento climático y la respuesta dinámica del sistema suelo-papa.

Fuentes de Información y Variables Capturadas

Para el desarrollo del modelo híbrido y la validación del controlador, se utilizan series de tiempo que capturan la dinámica hídrica y biológica. Las variables se categorizan de acuerdo con su rol dentro de la arquitectura de control, considerando el acople dinámico entre la demanda hídrica y el crecimiento foliar:

- **Perturbaciones Climáticas:** Evapotranspiración de referencia (ET_o) y Precipitación (P). Estas variables representan las entradas externas que fuerzan la dinámica del balance hídrico.
- **Variables de Estado:**
 - Contenido volumétrico de agua o humedad del suelo (θ) (valores de referencia iniciales).
 - Biomasa seca o desarrollo vegetativo (B), variable fundamental para la determinación dinámica del coeficiente del cultivo (K_c) en lugar de valores estáticos por etapas.
- **Variables de Control (Entradas):** Láminas de riego aplicadas (I), expresadas en milímetros (mm) para asegurar la consistencia dimensional en el cálculo de la evapotranspiración real (ET_c).

Protocolo de Preprocesamiento

Para asegurar la convergencia de los algoritmos de optimización en CasADi y el aprendizaje eficiente de la ANN, los datos crudos se someten a un flujo de tratamiento que incluye:

1. **Sincronización Temporal:** Remuestreo de las señales a un paso de tiempo constante (Δt), alineando las mediciones climáticas con los registros de humedad y biomasa.

2. **Tratamiento de Datos Atípicos y Faltantes:** Identificación de valores fuera de rango físico (p. ej., humedades negativas o superiores a la saturación) mediante filtros de media móvil o interpolación lineal según la criticidad del segmento.
3. **Normalización y Escalamiento:** Transformación de las variables a rangos acotados (típicamente $[0, 1]$ o $[-1, 1]$). Este paso es fundamental para la función de activación $\tanh$ de la red neuronal, evitando la saturación prematura de los gradientes durante el entrenamiento.
4. **Estructuración de Conjuntos:** División de la base de datos en subconjuntos de entrenamiento, validación y prueba, asegurando que la red neuronal sea evaluada con escenarios climáticos no vistos durante su ajuste.

3.3. Modelado Híbrido y Desarrollo de la Red Residual

Esta sección describe el desarrollo de un modelo híbrido que integra ecuaciones fenomenológicas de balance hídrico con una Red Neuronal Artificial (ANN). El enfoque de caja gris busca aprovechar la estructura física del sistema suelo-planta y corregir sus limitaciones mediante el aprendizaje de residuos, garantizando predicciones de humedad y biomasa más precisas para el controlador.

Dinámica del Balance Hídrico de Segundo Orden

El núcleo del modelo fenomenológico se fundamenta en la representación del sistema suelo-planta mediante un espacio de estados acoplado $\mathbf{x} = [\theta, B]^T$. Este enfoque permite describir la interacción dinámica entre la disponibilidad hídrica en la zona radicular y el desarrollo vegetativo del cultivo de papa. La evolución temporal de estas variables se rige por el siguiente sistema de ecuaciones diferenciales ordinarias (ODE):

$$\begin{cases} \frac{d\theta}{dt} = \frac{1}{Z_r} (I(t) + P(t) - ET_c(\theta, B, t) - D(\theta)) \\ \frac{dB}{dt} = rB(t) \left(1 - \frac{B(t)}{B_{max}}\right) - \delta B(t) \end{cases} \quad (3.1)$$

Donde las variables y parámetros se definen bajo criterios de consistencia dimensional de la siguiente manera:

- θ : Contenido volumétrico de agua o humedad del suelo [*adimensional*, m^3/m^3].
- B : Biomasa seca acumulada por unidad de área [g/m^2].
- Z_r : Profundidad efectiva de las raíces del cultivo [mm].

- $I(t), P(t)$: Láminas de riego y precipitación, respectivamente [$mm/día$].
- ET_c : Evapotranspiración real del cultivo [$mm/día$], calculada mediante el producto $K_c(B) \cdot K_s(\theta) \cdot ET_o$.
- $D(\theta)$: Tasa de drenaje profundo o percolación [$mm/día$].
- r : Tasa intrínseca de crecimiento vegetativo [$día^{-1}$].
- δ : Tasa de senescencia o mortalidad natural de la biomasa [$día^{-1}$].
- B_{max} : Capacidad de carga o biomasa máxima teórica [g/m^2].

Mecanismo de Acople: La interdependencia de los estados ocurre en dos direcciones:

1. **De la Biomasa a la Humedad:** Un incremento en B aumenta el coeficiente de cultivo $K_c(B)$, elevando la demanda hídrica (ET_c) y acelerando el agotamiento de θ .
2. **De la Humedad a la Biomasa:** Una reducción de θ por debajo del umbral crítico activa el factor de estrés $K_s(\theta)$, el cual penaliza la tasa neta de crecimiento de biomasa, modelando el marchitamiento o retraso en el desarrollo foliar.

Modelado Biológico: Coeficiente K_c y Estrés K_s Adaptado

Para que el modelo híbrido represente fielmente la fisiología del cultivo de papa (*Solanum tuberosum*), se requiere una parametrización dinámica de los coeficientes que regulan el intercambio gaseoso y la transpiración. A diferencia de los modelos tradicionales que emplean valores tabulados fijos, este trabajo propone un enfoque adaptativo. El desarrollo del modelo dinámico para esta investigación se fundamenta en un enfoque de coeficiente simple ajustado por estrés ($K_c \cdot K_s$). Para el desarrollo de esta investigación se optó por esta simplificación estructural para optimizar la eficiencia computacional del controlador NMPC, reduciendo la dimensionalidad del problema de optimización. Bajo la arquitectura *Grey-Box*, las dinámicas de evaporación y las incertidumbres del modelo físico son absorbidas por la red neuronal residual, garantizando precisión sin comprometer la velocidad de ejecución en **MATLAB**.

Coeficiente de Cultivo Dinámico (K_c): Dado que el desarrollo foliar está directamente relacionado con la biomasa seca acumulada, el coeficiente K_c deja de ser una función del tiempo cronológico para convertirse en una función del estado $B(t)$. Se implementa una relación lineal segmentada (o sigmoideal) que estima la demanda hídrica proporcional al desarrollo biológico:

$$K_c(B) = K_{c,min} + (K_{c,max} - K_{c,min}) \cdot \frac{B(t)}{B_{max}} \quad (3.2)$$

Esta formulación asegura que el consumo de agua (ET_c) escale de manera realista con el crecimiento de la planta, permitiendo al controlador anticipar mayores necesidades de riego a medida que aumenta la biomasa.

Factor de Estrés Hídrico (K_s) y Adaptación Regional: El factor K_s actúa como el mecanismo de acople que reduce la evapotranspiración cuando la humedad cae por debajo de un umbral crítico. Para adaptar la respuesta biológica a las condiciones de los suelos andinos y la sensibilidad de la papa, se establecen los siguientes parámetros:

- **Factor de agotamiento (p):** Se establece en 0,35, reflejando la alta sensibilidad del cultivo.
- **Límites de humedad:** Los valores de CC y PMP se parametrizan según las propiedades de los Andisoles locales.

Considerando que la función de estrés definida en el Marco Teórico (Sección 2.4.1.3) presenta discontinuidades en sus derivadas, para la implementación en **CasADi** se utiliza una aproximación sigmoideal. Esta técnica de suavizado permite que el optimizador **IPOPT** calcule trayectorias de control estables, anticipando la entrada en la zona de estrés hídrico mediante gradientes continuos.

Tratamiento Numérico de Perturbaciones y Drenaje

Para asegurar la convergencia de los algoritmos basados en gradiente dentro del framework CasADi, es imperativo que todas las funciones del modelo sean diferenciables. En esta sección se detallan las aproximaciones utilizadas para suavizar las discontinuidades físicas del sistema.

Aproximación de Eventos Climáticos: El modelado de la precipitación (P) mediante funciones tipo escalón presenta discontinuidades que dificultan el cálculo de derivadas. Se implementa una representación basada en la superposición de funciones sigmoideales para permitir una transición suave de la intensidad de lluvia:

$$P(t) = P_{max} \cdot \left(\frac{1}{1 + e^{-k(t-t_{start})}} - \frac{1}{1 + e^{-k(t-t_{end})}} \right) \quad (3.3)$$

Donde P_{max} es la intensidad máxima, t_{start} y t_{end} definen el intervalo del evento, y k es el parámetro de suavizado.

Modelado de Drenaje Suave: De igual forma, para evitar los desafíos numéricos del drenaje físico tradicional, se emplea una aproximación basada en la función *Softplus*:

$$D(x) = \frac{K_d}{\alpha} \ln \left(1 + e^{\alpha(x-CC)} \right) \quad (3.4)$$

Donde K_d representa la tasa de drenaje y α es un parámetro de suavizado. Esta formulación permite que el optimizador identifique gradientes de error incluso cerca del límite de Capacidad de Campo (CC), mejorando la velocidad de convergencia del algoritmo.

Esta formulación permite que el optimizador *IPOPT* identifique gradientes incluso en la vecindad de la Capacidad de Campo (CC), mejorando drásticamente la estabilidad numérica del controlador NMPC.

Diseño de la Red Neuronal Residual Multivariable

En el paradigma de modelado *Grey-Box*, la Red Neuronal Artificial (ANN) tiene la función de mapear las dinámicas no lineales y las incertidumbres que el modelo fenomenológico no logra capturar. En lugar de predecir el estado futuro directamente, la ANN se diseña para estimar el vector de residuos $\mathbf{r}_k = [r_{\theta,k}, r_{B,k}]^T$.

Arquitectura de la Red: Se implementa una red neuronal de tipo *Feed-Forward* multicapa (MLP) con una estructura de dos capas ocultas, configuradas con **16 neuronas en la primera capa y 8 neuronas en la segunda**. Esta topología en forma de embudo permite una extracción de características eficiente sin comprometer la velocidad de cómputo del controlador. Se selecciona la función de activación **tangente hiperbólica (tanh)** para las capas ocultas, debido a su capacidad para representar gradientes suaves y valores tanto positivos como negativos, lo cual es esencial para corregir el error del modelo físico en ambas direcciones. La capa de salida emplea una activación lineal para evitar la saturación de los residuos estimados.

Definición del Vector de Entradas ($\mathbf{u}_{ann}$): Para que la red identifique el origen del error, se propone un vector de entradas multivariable que captura el estado actual y las fuerzas externas. Aunque la configuración final dependerá de la disponibilidad del dataset, el diseño base considera:

$$\mathbf{u}_{ann,k} = \left[\theta_k \quad B_k \quad I_k \quad P_k \quad ET_{o,k} \right]^T \quad (3.5)$$

Donde se incluyen los estados actuales (θ, B) y las perturbaciones climáticas (P, ET_o) para que la red pueda entender si el error residual está correlacionado con un evento de lluvia o con una etapa específica del crecimiento.




Figura 3.1: Arquitectura de la red neuronal residual propuesta ($5 \times 16 \times 8 \times 2$).

Discretización mediante Algoritmo de Runge-Kutta (RK4)

Para la implementación del controlador NMPC en el entorno de CasADi, es necesario transformar las ecuaciones diferenciales ordinarias (ODE) del modelo físico continuo en un sistema de tiempo discreto. Se ha seleccionado el método de integración numérica de cuarto orden de Runge-Kutta (RK4), debido a su robustez y equilibrio entre precisión y costo computacional frente a pasos de integración fijos.

Formulación del Método: Dado un paso de tiempo Δt y el vector de estados actual $\mathbf{x}_k = [\theta_k, B_k]^T$, el método RK4 aproxima el estado siguiente $\mathbf{x}_{k+1}$ mediante la evaluación ponderada de cuatro pendientes intermedias. El cálculo se realiza siguiendo el esquema iterativo:

$$\begin{aligned}
 \mathbf{k}_1 &= \mathbf{f}_{phy}(\mathbf{x}_k, \mathbf{u}_k) \\
 \mathbf{k}_2 &= \mathbf{f}_{phy}\left(\mathbf{x}_k + \frac{\Delta t}{2}\mathbf{k}_1, \mathbf{u}_k\right) \\
 \mathbf{k}_3 &= \mathbf{f}_{phy}\left(\mathbf{x}_k + \frac{\Delta t}{2}\mathbf{k}_2, \mathbf{u}_k\right) \\
 \mathbf{k}_4 &= \mathbf{f}_{phy}(\mathbf{x}_k + \Delta t\mathbf{k}_3, \mathbf{u}_k) \\
 \mathbf{x}_{k+1} &= \mathbf{x}_k + \frac{\Delta t}{6}(\mathbf{k}_1 + 2\mathbf{k}_2 + 2\mathbf{k}_3 + \mathbf{k}_4)
 \end{aligned} \tag{3.6}$$

Donde $\mathbf{f}_{phy}$ representa el sistema de ecuaciones acoplado del balance hídrico y crecimiento biológico definido en la Sección 3.3.1.

Importancia en la Optimización: La elección de RK4 garantiza que el error de truncamiento global sea del orden $O(\Delta t^4)$, proporcionando una trayectoria de predicción lo suficientemente suave para que el optimizador *Interior Point Optimizer* (IPOPT) calcule los gradientes simbólicos necesarios sin problemas de convergencia. Esta discretización permite que el controlador NMPC anticipe el comportamiento de la humedad y la biomasa con una precisión superior a la de métodos más simples como Euler, asegurando una toma de decisiones coherente con la dinámica no lineal del cultivo.

Mecanismo de Integración Híbrida y Corrección Aditiva

La etapa final del modelado dinámico consiste en la consolidación del esquema *Grey-Box*, donde se integran las leyes físicas y la capacidad de aprendizaje de la Red Neuronal Residual. Este mecanismo permite que el modelo sea físicamente consistente pero estadísticamente flexible frente a las incertidumbres del entorno agrícola.

Estructura de Corrección Aditiva: El estado futuro predicho por el sistema, $\mathbf{x}_{k+1}$, se obtiene mediante la suma vectorial del estado estimado por el modelo físico (tras el proceso de discretización por RK4) y el vector de residuos calculado por la ANN. La ecuación maestra del modelo híbrido se define como:

$$\mathbf{x}_{k+1} = \mathbf{f}_{phy}(\mathbf{x}_k, \mathbf{u}_k) + \text{ANN}(\mathbf{u}_{ann,k}; \mathbf{W}) \quad (3.7)$$

Donde:

- $\mathbf{f}_{phy}(\mathbf{x}_k, \mathbf{u}_k)$: Representa la evolución del sistema según el balance hídrico y la dinámica de biomasa discretizada (Sección 3.3.5).
- $\text{ANN}(\mathbf{u}_{ann,k}; \mathbf{W})$: Es la corrección residual que compensa errores de modelado o efectos climáticos no lineales (Sección 3.3.4).

Esta configuración garantiza que, incluso en ausencia de datos suficientes para un entrenamiento exhaustivo de la red, el término físico $\mathbf{f}_{phy}$ actúe como un respaldo estructural (*failsafe*), impidiendo que el controlador genere trayectorias fuera de los límites biológicos reales.

3.4. Implementación del Controlador NMPC en CasADi

En esta sección se detalla la configuración técnica del controlador *Non-linear Model Predictive Control* (NMPC) dentro del entorno de **MATLAB**, utilizando la herramienta de optimización

simbólica **CasADi**. La implementación se enfoca en resolver el problema de optimización definido en el marco teórico, adaptándolo a la dinámica híbrida del cultivo de papa.

Configuración del Optimizador y Parámetros

En esta sección se detalla la configuración técnica del controlador *Non-linear Model Predictive Control* (NMPC) dentro del entorno de **MATLAB**, utilizando la herramienta de optimización simbólica **CasADi**. La implementación se enfoca en resolver el problema de optimización definido en el marco teórico, adaptándolo a la dinámica híbrida del cultivo de papa.

Configuración del Optimizador y Parámetros

La implementación computacional se basa en la formulación de un problema de programación no lineal (NLP). Se utilizan variables simbólicas de tipo **SX** para representar los estados y controles sobre el horizonte de predicción.

- **Solucionador:** Se emplea el optimizador *Interior Point Optimizer* (**IPOPT**), el cual utiliza métodos de barrera para gestionar las restricciones de humedad (θ) y riego (I).
- **Horizonte de Predicción (N):** Se establece un horizonte de $N = 7$ días. Este valor permite al controlador anticipar la dinámica de crecimiento semanal del cultivo y las pérdidas acumuladas por drenaje sin elevar el costo computacional.
- **Dinámica Interna del Predictor:** El optimizador integra la formulación completa del sistema, incluyendo los términos de drenaje $D(\theta)$, la tasa de crecimiento biótico r y el factor de senescencia δ . Esto garantiza que las trayectorias predichas respeten tanto las limitaciones físicas del suelo como el ciclo de vida biológico de la papa.
- **Ponderación de la Función de Costo:** Las matrices de peso se configuran como $Q = \text{diag}(q_\theta, q_B)$. Se asigna una prioridad relativa mayor a q_θ para mantener el confort hídrico, mientras que R penaliza el uso innecesario de agua.

Flujo de Ejecución en MATLAB

El algoritmo opera bajo la estrategia de horizonte deslizante, integrando el modelo de caja gris y el optimizador en cada paso de tiempo de la siguiente manera:

1. **Inicialización:** Se capturan los estados actuales $\mathbf{x}_k = [\theta_k, B_k]^T$, corregidos aditivamente por el residuo de la red neuronal para compensar errores en los parámetros r o δ .

2. **Optimización:** Se pasan los estados y las perturbaciones climáticas previstas (P, ET_o) como parámetros al objeto `solver` de CasADi.
3. **Cómputo:** IPOPT resuelve la secuencia óptima de riego $\{I_0, I_1, \dots, I_{N-1}\}$ minimizando J . En este cálculo, el modelo interno descuenta automáticamente las pérdidas por drenaje previstas según el nivel de humedad.
4. **Acción de Control:** Se extrae únicamente el primer valor de la secuencia (I_0) y se aplica al sistema.
5. **Actualización:** El proceso se repite en $k + 1$, actualizando el modelo con la nueva medición de humedad y reiniciando el cálculo del crecimiento y drenaje.

3.5. Escenarios de Evaluación y Métricas de Desempeño

Para validar la robustez y eficiencia del controlador NMPC híbrido, se establecen escenarios de simulación que representan condiciones críticas de operación y se definen métricas cuantitativas para evaluar el cumplimiento de los objetivos de control.

3.5.1. Definición de Escenarios Climáticos

Se han diseñado dos escenarios principales basados en datos históricos para someter al sistema a condiciones de estrés contrastantes:

- **Escenario de Sequía Extrema (Verano):** Caracterizado por una alta evapotranspiración de referencia (ET_o) y ausencia de precipitaciones ($P = 0$). Este escenario evalúa la capacidad del controlador para racionar el recurso hídrico sin permitir que la humedad caiga por debajo del punto de marchitez permanente (PMP).
- **Escenario de Lluvias Intensas (Invierno):** Caracterizado por eventos de precipitación súbitos que pueden saturar el suelo. Aquí se evalúa la respuesta del NMPC ante perturbaciones externas, verificando si es capaz de suspender el riego de forma oportuna para evitar el desperdicio y el lixiviado de nutrientes por exceso de drenaje.

3.5.2. Índices de Desempeño y Validación

El desempeño del sistema se cuantifica mediante tres indicadores fundamentales que permiten comparar el modelo de caja gris y el controlador propuesto frente a métodos convencionales:

Precisión del Modelo (MAE y RMSE): Para evaluar la capacidad de predicción de la Red Neuronal Residual acoplada a la física, se utilizan el Error Absoluto Medio (MAE) y la Raíz del Error Cuadrático Medio (RMSE) respecto a los datos de validación:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|, \quad RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (3.8)$$

Eficiencia en el Uso del Agua (WUD): Se calcula el ahorro total de agua comparando la lámina acumulada aplicada por el NMPC frente a un esquema de riego de umbral fijo (riego por calendario):

$$\text{Ahorro}(\%) = \left(\frac{\sum I_{conv} - \sum I_{nmpc}}{\sum I_{conv}} \right) \times 100 \quad (3.9)$$

Índice de Confort Hídrico: Se mide el tiempo total en que la humedad del suelo se mantuvo dentro de la zona de agotamiento permisible ($[p \cdot (CC - PMP), CC]$). Un desempeño exitoso implica minimizar los periodos de estrés hídrico mientras se maximiza el crecimiento de la biomasa (B).

Capítulo 4

Desarrollo del Proyecto

Este capítulo detalla la fase de ejecución técnica del proyecto, abarcando desde la estructuración del entorno computacional hasta la validación integral del esquema de control propuesto. El desarrollo sigue una secuencia lógica de integración donde se transforman los principios fenomenológicos y las arquitecturas de aprendizaje automático en un sistema de control predictivo funcional. Para ello, se establece un flujo de trabajo basado en la interconexión de herramientas de optimización simbólica y procesamiento matricial, lo que permite gestionar la complejidad no lineal del modelo híbrido y garantizar la estabilidad numérica en los horizontes de predicción analizados.

El proceso comienza con la codificación de las ecuaciones diferenciales acopladas de humedad y biomasa, asegurando la consistencia dimensional de los flujos de agua en el suelo. Posteriormente, se describe la fase de generación de datos sintéticos y reales para el entrenamiento de la red neuronal residual, detallando la selección de hiperparámetros y la validación del error de predicción. Una vez consolidado el modelo *Grey-Box*, se procede a su integración en la estructura del controlador predictivo, donde se definen las funciones de costo y las restricciones operativas necesarias para proteger la fisiología del cultivo de papa. Finalmente, se establecen los escenarios climáticos de prueba que permitirán evaluar la capacidad adaptativa del sistema frente a perturbaciones externas.

4.1. Entorno de Desarrollo y Configuración Técnica

La infraestructura computacional utilizada para la ejecución de este proyecto se seleccionó bajo criterios de eficiencia para procesos de optimización no lineal. La estación de trabajo cuenta con un procesador AMD Ryzen 5 7520U y 16 GB de memoria RAM, componentes necesarios para gestionar el flujo de datos entre la red neuronal y el solver de optimización sin cuellos de botella en el procesamiento. Esta base de hardware permite que el horizonte de predicción del controlador se evalúe con una latencia mínima, garantizando la viabilidad de la simulación dinámica.

En el ámbito del software, se detalla el uso de **MATLAB R2025b** como plataforma principal

para el procesamiento numérico y la gestión de datos. El entrenamiento de la arquitectura residual se realizó mediante una implementación nativa en el entorno de programación matricial de MATLAB, aprovechando su eficiencia en el manejo de vectores y operaciones de gradiente. Para la formulación de las funciones de costo del controlador y la integración de la red neuronal dentro del bucle de optimización, se utilizó el framework **CasADi 3.6.3**. La resolución de los problemas de programación no lineal (NLP) se delegó al solver **IPOPT**, cuya configuración interna fue ajustada para priorizar la convergencia en sistemas de segundo orden acoplados. Esta combinación de herramientas permite la diferenciación automática de las ecuaciones del cultivo, facilitando que el algoritmo NMPC encuentre soluciones óptimas en entornos de alta no linealidad.

4.2. Implementación del Modelo Físico en MATLAB

La base del desarrollo técnico consiste en la traducción de las dinámicas hídricas y biológicas del cultivo a un entorno de computación numérica. Para ello, se diseñó un script maestro en *MATLAB* capaz de gestionar un sistema multivariable donde la humedad del suelo (θ) y el crecimiento de la biomasa (B) operan de manera acoplada. Esta arquitectura permite que el modelo de caja blanca capture la interdependencia entre el desarrollo vegetativo y la demanda de agua, utilizando la biomasa calculada para actualizar dinámicamente el coeficiente del cultivo (K_c) en cada paso de tiempo.

La función de estado se estructuró para procesar simultáneamente las variables de control y las perturbaciones ambientales. En esta lógica, la lámina de riego (u) actúa como la entrada de decisión, mientras que la precipitación y la evapotranspiración de referencia se integran como vectores exógenos. La programación se enfocó en la modularidad de parámetros críticos como la eficiencia de asimilación de biomasa y las tasas de drenaje profundo, asegurando que el modelo responda fielmente a la fisiología de la planta de papa y a las propiedades físicas del suelo.

Dada la naturaleza no lineal del acoplamiento entre humedad y biomasa, se seleccionó el método de **Runge-Kutta de cuarto orden (RK4)** para la discretización temporal. La implementación de RK4 proporciona la estabilidad numérica necesaria para manejar las diferentes escalas de tiempo en las que evolucionan ambos estados, garantizando que el controlador predictivo trabaje sobre una base física de alta fidelidad. Esta precisión es fundamental para que el modelo físico represente la tendencia estructural del sistema antes de ser refinado por la componente de aprendizaje automático.

4.3. Entrenamiento de la Red Neuronal Residual

Una vez estructurado el modelo físico, se procedió a la implementación y entrenamiento de la componente de aprendizaje automático encargada de estimar el residuo dinámico del sistema.

A diferencia de los enfoques que emplean librerías predefinidas de alto nivel, el entrenamiento de la red se programó de manera nativa en *MATLAB* mediante el algoritmo de retropropagación (*backpropagation*). Esta decisión técnica permitió un control exhaustivo sobre la actualización de los gradientes y la gestión de los pesos y sesgos, garantizando una integración transparente con el flujo de datos del modelo híbrido.

La arquitectura seleccionada consiste en una red perceptrón multicapa (*MLP*) con una capa de entrada de cinco neuronas, correspondientes a los estados actuales del sistema (θ, B), la acción de control (u) y las perturbaciones climáticas (P, ET_o). Esta configuración permite que la red identifique cómo la interacción entre el desarrollo vegetativo y las condiciones del entorno afectan la precisión del modelo físico. A esta capa le siguen dos capas ocultas y una capa de salida que estima el vector de corrección aditiva, el cual compensa las dinámicas no modeladas en ambos estados.

El entrenamiento se realizó bajo un esquema de supervisión basado en el error cuadrático medio (*MSE*), el cual fue minimizado iterativamente hasta lograr una estabilización de la pérdida. El resultado final de esta etapa es un archivo de parámetros optimizados que encapsula el conocimiento de las dinámicas no modeladas. Estos pesos y sesgos se exportan para su posterior uso en la fase de inferencia, permitiendo que el controlador *MPC* acceda a una predicción corregida de la humedad y la biomasa en tiempo de ejecución, compensando así errores de truncamiento o variaciones estocásticas del entorno real.

4.4. Integración del Modelo Híbrido en el MPC

El núcleo del desarrollo técnico reside en el acoplamiento del modelo híbrido dentro de la estructura del controlador predictivo no lineal (*NMPC*). Para esta integración, se utilizó el framework de optimización simbólica **CasADi**, el cual permite definir los estados del sistema (θ, B) y la red neuronal residual como expresiones matemáticas diferenciables. En esta arquitectura, la función de predicción se construye de manera aditiva: en cada paso del horizonte de tiempo, el solver evalúa la respuesta del modelo físico mediante el integrador *RK4* y le suma la corrección calculada por la red neuronal entrenada. Esta sinergia garantiza que el optimizador trabaje sobre una trayectoria que compensa tanto las pérdidas por drenaje como las dinámicas no lineales del consumo hídrico real.

La formulación del problema de control se define mediante una función de costo que busca minimizar el error cuadrático entre la humedad predicha y el límite de capacidad de campo, penalizando simultáneamente variaciones abruptas en la acción de riego (u). La ventaja de esta estructura *Grey-Box* es su capacidad de respuesta proactiva; al incluir el estado de la biomasa en la predicción, el controlador ajusta la lámina de riego anticipando que un mayor desarrollo foliar incrementará la evapotranspiración. Para la resolución del problema de programación no lineal

(*NLP*), se configuró el solver **IPOPT** con una estrategia de inicio en caliente (*Warm-start*), lo que optimiza el tiempo de convergencia al utilizar la solución del paso anterior como punto de partida para la optimización actual.

4.5. Configuración del Horizonte de Predicción y Restricciones

Para asegurar la viabilidad operativa del sistema y la protección fisiológica del cultivo de papa, se procedió a la configuración de los parámetros de horizonte y las restricciones del optimizador. Se estableció un horizonte de predicción (N) de 10 días, una ventana temporal que permite al algoritmo anticipar tendencias climáticas de mediano plazo y gestionar el agotamiento de la humedad de manera estratégica. Este valor se seleccionó tras evaluar el compromiso entre la capacidad de anticipación y el costo computacional, garantizando que el solver encuentre soluciones óptimas dentro de los tiempos de muestreo definidos.

El espacio de búsqueda de la optimización está delimitado por restricciones físicas y técnicas impuestas tanto a los estados como a la variable de control. Para la humedad del suelo (θ), se definieron límites que evitan el estrés hídrico severo por debajo del punto de marchitez permanente y la anoxia por saturación. Por otro lado, la acción de riego (u) fue restringida a un rango entre 0 y 6 mm/día, reflejando las limitaciones reales de la infraestructura hidráulica y evitando el desperdicio del recurso. Estas fronteras se implementaron en *CasADi* mediante vectores de límites inferiores (lbw) y superiores (ubw), obligando al solver **IPOPT** a descartar cualquier trayectoria que comprometa la integridad del cultivo o la capacidad del sistema de riego.

Capítulo 5

Resultados y Análisis

- 5.1. Resultados de la Identificación del Modelo Híbrido**
- 5.2. Desempeño del Controlador en Escenarios Climáticos**
- 5.3. Análisis de Consumo de Agua y Errores de Seguimiento**
- 5.4. Comparativa con Métodos de Control Tradicionales**

Capítulo 6

Conclusiones

6.1. Conclusiones sobre el Modelo Híbrido

6.2. Efectividad del Control Predictivo en el Riego

6.3. Recomendaciones y Trabajos Futuros

Glosario

CasADi: Marco de software de código abierto para la optimización numérica y la diferenciación algorítmica, utilizado en este trabajo para la formulación simbólica del control óptimo.

Capacidad de Campo (CC): Contenido de agua que un suelo puede retener tras haber sido saturado y drenado libremente, representando el límite superior de humedad aprovechable para el cultivo.

Cibernética: Ciencia que estudia los sistemas de comunicación y control en máquinas y seres vivos; en este proyecto, se aplica a la regulación automática y retroalimentada del riego.

Control Predictivo basado en Modelo (NMPC): Estrategia de control avanzado que utiliza un modelo dinámico no lineal para predecir comportamientos futuros y calcular secuencias de control óptimas bajo restricciones.

Evapotranspiración (ET_c): Cantidad de agua que se pierde a través de la evaporación del suelo y la transpiración de la planta, calculada mediante el producto de la ET_o , el coeficiente de estrés hídrico (K_s) y el coeficiente de cultivo (K_c).

Identificación de Sistemas: Metodología para obtener modelos matemáticos de sistemas dinámicos a partir de datos experimentales, empleada para ajustar los parámetros del modelo físico al suelo real.

Modelo Grey-Box (Caja Gris): Enfoque de modelado híbrido que combina ecuaciones fenomenológicas (basadas en principios físicos) con estructuras de aprendizaje de datos para representar dinámicas complejas e inciertas.

Punto de Marchitez Permanente (PMP): Nivel crítico de humedad en el suelo por debajo del cual la planta no puede extraer agua con la fuerza suficiente para recuperar su turgencia, sufriendo daños fisiológicos.

Redes Neuronales Residuales (ResNet): Arquitectura de aprendizaje profundo basada en el aprendizaje de residuos o errores, utilizada aquí para compensar las discrepancias entre el modelo

físico y la realidad del cultivo.

Solanum tuberosum: Nombre científico de la planta de papa, especie dicotiledónea perteneciente a la familia Solanaceae y objeto de estudio de la presente investigación.

Unidad de Toma de Decisión (DTU): En el contexto de este trabajo, se refiere al algoritmo que procesa la información climática y de humedad para determinar la lámina de riego óptima.

Bibliografía

The United Nations World Water Development Report 2021: Valuing Water. United Nations Educational, Scientific and Cultural Organization (UNESCO), Paris, France, 2021. Open access (UNESCO).

The State of the World's Land and Water Resources for Food and Agriculture 2021-2030 Systems at Breaking Point. Food and Agriculture Organization of the United Nations (FAO), Rome, Italy, 2022. doi:[10.4060/cb9910en](https://doi.org/10.4060/cb9910en). Open access (FAO).

O. Adeyemi, I. Grove, S. Peets, and J. Norton. Advanced monitoring and management systems for improving sustainability in precision irrigation. *Sustainability*, 9(3):353, 2017. doi:[10.3390/su9030353](https://doi.org/10.3390/su9030353).

I. Ahmad and M. A. Hanjra. Soil water dynamics and root zone of potato crop under sprinkler irrigation. *Agricultural Water Management*, 2019.

R. G. Allen, L. S. Pereira, D. Raes, and M. Smith. *Crop Evapotranspiration 2013 Guidelines for Computing Crop Water Requirements*, volume 56 of *FAO Irrigation and Drainage Paper*. Food and Agriculture Organization of the United Nations, Rome, Italy, 1998.

Richard G. Allen, Luis S. Pereira, Dirk Raes, and Martin Smith. *Evapotranspiración del cultivo: Guías para la determinación de los requerimientos de agua de los cultivos*. Number 56 in Estudio FAO: Riego y Drenaje. Organización de las Naciones Unidas para la Agricultura y la Alimentación (FAO), Roma, Italia, 2006. ISBN 92-5-304219-2. URL <https://openknowledge.fao.org/handle/20.500.14283/x0490s>. Reimpresión de la edición original de 1998.

D. A. Barrera-Rodríguez, O. M. Gómez-Miranda, and Y. K. Parra-Acosta. Análisis del rendimiento de la producción de la papa en los departamentos de antioquia, boyacá y cundinamarca, colombia. *Región Científica*, 4(2), 2025. doi:[10.58763/rc2025479](https://doi.org/10.58763/rc2025479). Open access.

E. Bwambale, F. K. Abagale, and G. K. Anornu. Data-driven model predictive control for precision irrigation management. *Smart Agricultural Technology*, 3:100074, 2023a. doi:[10.1016/j.atech.2022.100074](https://doi.org/10.1016/j.atech.2022.100074).

- E. Bwambale, F. K. Abagale, and G. K. Anornu. Towards a modelling, optimization and predictive control framework for smart irrigation. *Heliyon*, 10(18):e38095, 2024. doi:[10.1016/j.heliyon.2024.e38095](https://doi.org/10.1016/j.heliyon.2024.e38095). Open access.
- Edward Bwambale, Francis Abagale, and Gideon Anornu. Smart irrigation monitoring and control strategies for improving water use efficiency in agriculture: A review. *Agricultural Water Management*, 260:107324, 2022. doi:[10.1016/j.agwat.2021.107324](https://doi.org/10.1016/j.agwat.2021.107324).
- Erion Bwambale, Felix K. Abagale, and Geophrey K. Anornu. Model-based smart irrigation control strategy and its effect on water use efficiency in tomato production. *Cogent Engineering*, 10(2): 2259217, 2023b. doi:[10.1080/23311916.2023.2259217](https://doi.org/10.1080/23311916.2023.2259217).
- E. F. Camacho and C. Bordons. *Model Predictive Control*. Springer, London, UK, 2 edition, 2013. ISBN 978-1852336943.
- Carlos S. Cohen-Manrique, Andrea F. Burbano-Bustos, Rodrigo D. Salgado-Ordosgoitia, and Rafael H. Merlano-Porto. Control de riego en cultivos de ahuyama en sincelejo, sucre (colombia) gestionados a través del internet de las cosas. *Información Tecnológica*, 31(5):79–88, 2020. doi:[10.4067/S0718-07642020000500079](https://doi.org/10.4067/S0718-07642020000500079).
- G. Corpus Arrieta. Elementos diagnósticos en el sector agropecuario: Caso de la producción de papa en boyacá. *Nova et Vetera*, 28:3–20, 2019. doi:[10.22431/25005103.n28.1](https://doi.org/10.22431/25005103.n28.1). Open access.
- D. C. da Silva, J. A. S. Dias, R. G. A. da Silva, and L. C. S. Junior. A review on monitoring and advanced control strategies for precision irrigation. *Computers and Electronics in Agriculture*, 173:105441, 2020. doi:[10.1016/j.compag.2020.105441](https://doi.org/10.1016/j.compag.2020.105441).
- Si Daryanto, Lixin Wang, and P.-A. Jacinthe. Global synthesis of drought effects on cereal, legume, tuber and root crops production: A review. *Agricultural Water Management*, 179:18–33, 2017. doi:[10.1016/j.agwat.2016.04.022](https://doi.org/10.1016/j.agwat.2016.04.022).
- K. Djaman, S. Irmak, K. Koudahe, and S. Allen. Irrigation management in potato (*Solanum tuberosum* L.) production: A review. *Sustainability*, 13(3):1504, 2021. doi:[10.3390/su13031504](https://doi.org/10.3390/su13031504). Open access.
- R. G. Evans and E. J. Sadler. Methods and technologies to improve efficiency of water use. *Water Resources Research*, 44(7):W00E04, 2008. doi:[10.1029/2007WR006200](https://doi.org/10.1029/2007WR006200).
- Flor García Moreno, Juan Bedoya Fierro, and Germán Arturo López Martínez. Modelo a escala de un sistema de riego automatizado, alimentado con energía solar fotovoltaica: nueva perspectiva para el desarrollo agroindustrial colombiano. *Tecnura*, 17(Especial 2):33–47, 2013.

- A. M. Ireson, R. J. Spiteri, M. P. Clark, and S. A. Mathias. A simple, efficient, mass-conservative approach to solving richards' equation (openre, v1.0). *Geoscientific Model Development*, 2023. doi:[10.5194/gmd-16-659-2023](https://doi.org/10.5194/gmd-16-659-2023).
- Md B. Islam, Antonio Guerrieri, Raffaele Gravina, Declan T. Delaney, and Giancarlo Fortino. From traditional machine learning to fine-tuning large language models: A review for sensors-based soil moisture forecasting. *Sensors*, 25(22):6903, 2025. doi:[10.3390/s25226903](https://doi.org/10.3390/s25226903). Open access.
- T. Kautz and H. Hoffmann. Deep rooting as an indicator of deep soil water and n uptake in potato. *Potato Research*, 2024. doi:[10.1007/s11540-024-09802-4](https://doi.org/10.1007/s11540-024-09802-4).
- Jacob W. Kijne, Rodney Barker, and David Molden. *Unlocking the Water Potential of Agriculture*. Food and Agriculture Organization of the United Nations (FAO), Rome, Italy, 2003. ISBN 978-92-5-104911-2. Open access (FAO).
- Ao Liu, Dongbao Zhao, and Yichang Wei. Model predictive control of adaptive irrigation decisions incorporating rainfall intensity and soil properties. *Agriculture*, 15(5):527, 2025. doi:[10.3390/agriculture15050527](https://doi.org/10.3390/agriculture15050527). Open access.
- Lennart Ljung. *System Identification: Theory for the User*. Prentice Hall, 2nd edition, 1999.
- C. A. Marcillo-Paguay, C. A. Benavides-Cardona, H. S. Ramos-Zambrano, and J. V. Romero. Respuesta agronómica y económica de papa (*solanum tuberosum* subsp. andigena) a la fertilización diferencial en cuatro ambientes de nariño, colombia. *Revista Colombiana de Ciencias Hortícolas*, 16(2):e13559, 2022. doi:[10.17584/rcch.2022v16i2.13559](https://doi.org/10.17584/rcch.2022v16i2.13559). URL <https://doi.org/10.17584/rcch.2022v16i2.13559>.
- J. R. Medina, C. Rodriguez, A. Arias, et al. Impact of drip irrigation and soil management on yield and water use efficiency of potato (*solanum tuberosum*) in the colombian andes. *Revista Facultad Nacional de Agronomía Medellín*, 18(1):169–180, 2024. doi:[10.17584/rcch.2024v18i1.16954](https://doi.org/10.17584/rcch.2024v18i1.16954).
- Luis-Enrique Olivera-Guerra, Pierre Laluet, Víctor Altés, Chloé Ollivier, Yann Pageot, Giovanni Paolini, Eric Chavanon, Vincent Rivalland, Gilles Boulet, Josep-Maria Villar, and Olivier Merlin. Modeling actual water use under different irrigation regimes at district scale: Application to the fao-56 dual crop coefficient method. *Agricultural Water Management*, 278:108119, 2023. doi:[10.1016/j.agwat.2023.108119](https://doi.org/10.1016/j.agwat.2023.108119).
- R. A. Ploschuk, D. J. Miralles, T. D. Colmer, E. L. Ploschuk, and G. G. Striker. Waterlogging of winter crops at early and late stages: Impacts on leaf physiology, growth and yield. *Frontiers in Plant Science*, 9:1863, 2018. doi:[10.3389/fpls.2018.01863](https://doi.org/10.3389/fpls.2018.01863). Open access.

- Potato Research. Potato yield prediction research based on improved artificial neural networks using whale optimization algorithm. *Potato Research*, 2024. URL <https://www.eapr.net/publications/potato-research/potato-yield-prediction-research-based-improved-artificial-neural>.
- J. Quispe-Rodríguez, U. Quispe-Quezada, R. Hinojosa-Benavides, and J. Quispe-Medrano. Determinación de coeficientes de uso consuntivo (kc) en cultivo de papa (*Solanum tuberosum*) por el método lisimétrico en el valle del mantaro. *PURIQ*, 2(3):196–205, 2020. doi:[10.37073/puriq.2.3.88](https://doi.org/10.37073/puriq.2.3.88). Open access.
- P. Rossini and A. Patrignani. Predicting rootzone soil moisture from surface observations. *Soil Science Society of America Journal*, 2021. doi:[10.1002/saj2.20319](https://doi.org/10.1002/saj2.20319).
- K. R. Thorp et al. pyfao56: Fao-56 evapotranspiration in python. *SoftwareX*, 2022. doi:[10.1016/j.softx.2022.101208](https://doi.org/10.1016/j.softx.2022.101208).
- P. A. Valderrama, A. González, P. Porras, H. Samacá, M. Fonseca, L. Quintero, J. Gómez, E. Garcés, and J. Viveros. Plan de ordenamiento productivo para la cadena de papa en colombia. 2023. URL https://upra.gov.co/sites/default/files/2024-09/POP_Cadena_Papa.pdf. Open access (UPRA).
- Christian Alexander Valenzuela Ojeda. Prototipo inteligente de control de riego tecnificado en cultivos de papa, 2023.
- G. A. K. van Voorn et al. A conceptual framework for the dynamic modeling of time-resolved phenotypes for sets of genotype-environment-management combinations: A model library. *Frontiers in Plant Science*, 14, 2023. doi:[10.3389/fpls.2023.1172359](https://doi.org/10.3389/fpls.2023.1172359).
- Yanling Wang, Liangsheng Shi, Yaan Hu, Xiaolong Hu, Wenxiang Song, and Lijun Wang. A comprehensive study of deep learning for soil moisture prediction. *Hydrology and Earth System Sciences*, 28:917–943, 2024. doi:[10.5194/hess-28-917-2024](https://doi.org/10.5194/hess-28-917-2024). Open access.
- Yingpan Yang, Juan Yin, Zhenghu Ma, and Yinhao Zhu. A coupled model for simulating water and heat transfer in soil-plant-atmosphere continuum with crop growth. *Water*, 11(1):47, 2019. doi:[10.3390/w11010047](https://doi.org/10.3390/w11010047).
- Yingpan Yang, Juan Yin, Zhenghu Ma, and Yinhao Zhu. Dynamic response of potato growth indicators to effective cumulative temperature and water and nitrogen regulation based on a logistic model. *SSRN Electronic Journal*, 2023. doi:[10.2139/ssrn.4577472](https://doi.org/10.2139/ssrn.4577472). Acceso abierto bajo repositorio SSRN.