

Modelamiento y control de un caso de estudio sobre el riego del cultivo de papa en Colombia

Por:

Andrés Felipe Arias Guevara

Miguel Angel Panqueva Pulido

Universidad Distrital Francisco José de Caldas

Facultad de Ingeniería

Programa de Ingeniería de Sistemas

Bogotá D.C., Colombia

2025

Índice general

Resumen	3
1. Introducción	4
2. Planteamiento del problema	6
3. Justificación	8
4. Objetivos	10
4.1. Objetivo general	10
4.2. Objetivos específicos	10
5. Marco referencial	11
5.1. Marco teórico	11
5.1.1. Sistemas dinámicos en agricultura	11
5.1.2. Redes neuronales aplicadas al control de sistemas agrícolas	11
5.1.3. Comparación entre modelos deterministas y Data-Driven	12
5.1.4. Control predictivo basado en modelo (MPC)	13
5.1.5. Arquitectura general del sistema de control	14
5.1.6. Sistemas no lineales y modelos de proceso	14
5.1.7. Modelo Grey-Box basado en EDO y red neuronal	15
5.1.8. Fundamento físico: balance hídrico y FAO-56	15
5.2. Marco conceptual	16
5.3. Antecedentes	17

6. Metodología	22
6.0.1. Revisión bibliográfica y fundamentación	22
6.0.2. Formulación del modelo físico (EDO)	22
6.0.3. Diseño e integración de la red neuronal	23
6.0.4. Implementación del control predictivo (MPC)	23
6.0.5. Validación y análisis de resultados	23
7. Implementación del control predictivo con CasADi	24
7.1. Implementación del control predictivo basado en modelo (MPC)	24
7.1.1. Definición del modelo Grey-Box	25
7.1.2. Configuración del problema de MPC	25
7.1.3. Simulación del horizonte recedente (Receding Horizon)	26
8. Cronograma	27
9. Presupuesto	28
10.Resultados e impacto esperado	30
11.Referencias	32

Resumen

El presente trabajo tiene como propósito desarrollar y analizar un modelo de Control Predictivo Basado en Modelo (MPC) aplicado al manejo de la humedad del suelo en el cultivo de papa. A partir de un enfoque híbrido tipo Grey-Box, se integra una ecuación diferencial del balance hídrico —que describe los procesos de riego, precipitación, evapotranspiración y drenaje— con una red neuronal de corrección capaz de capturar dinámicas no lineales no modeladas.

La investigación emplea herramientas computacionales en MATLAB y la librería CasADi para formular y resolver el problema de control no lineal, evaluando distintas estrategias de discretización (Single y Multiple Shooting) y considerando restricciones físicas propias del sistema agrícola.

Se espera obtener un modelo robusto y de comportamiento estable que optimice el uso del agua de riego y mantenga la humedad del suelo dentro de rangos óptimos. Los resultados contribuirán al avance de la agricultura de precisión y al fortalecimiento de las aplicaciones de la ingeniería de control e inteligencia computacional en el sector agropecuario colombiano.

1. Introducción

En Colombia, un país altamente dependiente de la agricultura, hay algunos tipos de cultivos preponderantes y fundamentales para la economía campesina y la seguridad alimentaria del país, entre estos cultivos está el de la papa, que constituye no solo un producto de consumo básico en la dieta de la población, sino también una de las principales fuentes de ingresos y sustento para comunidades rurales en diversas regiones del país.

La agricultura continúa siendo uno de los sectores más sensibles a la variabilidad climática, la calidad del suelo y los costos de los insumos. Estas condiciones generan una alta incertidumbre en la planeación y gestión de la producción, lo que plantea la necesidad de contar con herramientas que permitan anticipar escenarios y optimizar la toma de decisiones.

La optimización del riego agrícola constituye un desafío técnico y ambiental de gran relevancia, especialmente en regiones donde la disponibilidad de agua es limitada y los patrones climáticos son cada vez más variables. El manejo eficiente del agua en los cultivos requiere comprender y controlar procesos complejos que involucran la interacción entre el suelo, la atmósfera y la planta, los cuales presentan un comportamiento altamente no lineal y dependiente del tiempo. En este contexto, el desarrollo de modelos y sistemas de control inteligente se convierte en una herramienta clave para la sostenibilidad de la producción agrícola y la gestión racional de los recursos hídricos.

Los modelos computacionales y las técnicas de control predictivo se presentan como alternativas valiosas para apoyar la gestión automatizada del riego. El uso de redes neuronales artificiales ofrece un enfoque flexible y robusto para abordar la complejidad de este sistema agrícola, al modelar relaciones no lineales entre variables climáticas, edáficas y de manejo. De igual forma, la incorporación de modelos dinámicos basados en ecuaciones diferenciales permite representar matemáticamente la evolución de procesos como el balance hídrico del

suelo, proporcionando una base física para el diseño de controladores inteligentes.

El presente proyecto propone el desarrollo de un sistema de control predictivo basado en modelo (MPC) para el riego del cultivo de papa, utilizando un modelo Grey-Box que combina una ecuación diferencial del balance hídrico con una red neuronal de corrección. Este enfoque busca determinar, en tiempo real, la cantidad óptima de agua a aplicar, garantizando niveles adecuados de humedad en la zona radicular y evitando el desperdicio del recurso hídrico. La investigación se orienta a construir un modelo funcional que sirva como referencia para futuros sistemas de riego automatizados, con potencial de adaptación a distintas regiones y condiciones del suelo, contribuyendo a la sostenibilidad y modernización del sector agrícola colombiano.

2. Planteamiento del problema

La agricultura es uno de los sectores más afectados por la variabilidad climática, la disponibilidad de agua y la eficiencia en el uso de los recursos hídricos. En Colombia, el cultivo de la papa constituye uno de los principales pilares de la producción agrícola, tanto por su impacto en la seguridad alimentaria como por su relevancia económica. Sin embargo, el manejo ineficiente del riego sigue siendo un problema recurrente, derivado de la falta de herramientas de control automatizado que respondan dinámicamente a las condiciones reales del suelo y del ambiente.

Los métodos tradicionales de programación del riego —basados en calendarios fijos o en la experiencia del agricultor— no consideran la dinámica compleja del balance hídrico en la zona radicular, ni las variaciones espaciales y temporales de la humedad del suelo. Esto conlleva a situaciones de sub-riego o sobre-riego, que reducen la productividad y deterioran las propiedades físicas y químicas del suelo.

Aunque existen modelos físicos detallados, como la ecuación de Richards o el enfoque FAO-56, su aplicación práctica es limitada por la necesidad de parámetros difíciles de medir y por la falta de adaptación a condiciones no lineales y variables. Por otro lado, los modelos puramente basados en datos (data-driven), como las redes neuronales o los sistemas NARX, ofrecen buena capacidad de ajuste, pero carecen de interpretabilidad física y tienden a sobreajustarse si los datos son escasos o ruidosos.

Por tanto, surge la necesidad de desarrollar un modelo híbrido o Grey-Box, que combine el conocimiento físico del balance hídrico con el aprendizaje de una red neuronal residual, para representar la dinámica real de la humedad del suelo de manera precisa y explicable. Dicho modelo servirá como base para un control predictivo basado en modelo (MPC) que determine la cantidad óptima de riego a aplicar en tiempo real, considerando las restricciones

del sistema y las condiciones climáticas actuales.

De esta manera, el problema central que aborda este proyecto es la falta de un sistema de control predictivo adaptable y físicamente fundamentado para el manejo del riego en cultivos de papa, que permita optimizar el uso del agua sin comprometer el rendimiento del cultivo ni la sostenibilidad del suelo.

3. Justificación

El desarrollo de sistemas inteligentes de control aplicados a la agricultura representa una oportunidad significativa para mejorar la eficiencia en el uso del agua y garantizar la sostenibilidad de los sistemas productivos. En el caso del cultivo de papa en Colombia, el manejo adecuado del riego es esencial para alcanzar altos niveles de productividad y calidad del producto, dado que el exceso o la falta de agua pueden afectar el crecimiento, la sanidad del cultivo y las condiciones del suelo.

La aplicación de un control predictivo basado en modelo (MPC) permite tomar decisiones óptimas de riego en función del estado actual del sistema y de su comportamiento futuro estimado, anticipando variaciones ambientales y respondiendo de manera dinámica a las condiciones del campo. Este tipo de estrategias ofrecen ventajas frente a los sistemas de control tradicionales, ya que integran explícitamente restricciones de operación, horizontes de predicción y modelos no lineales del proceso.

El uso de un modelo Grey-Box, que combina una ecuación diferencial del balance hídrico con una red neuronal residual, proporciona una representación física y adaptable del sistema, capaz de capturar las dinámicas complejas de la humedad del suelo sin requerir parametrizaciones excesivamente detalladas. Este enfoque permite unir el conocimiento teórico del comportamiento del agua en la zona radicular con la capacidad de las redes neuronales para ajustar las diferencias entre la realidad y el modelo físico.

Desde el punto de vista académico, el proyecto contribuye al avance en la integración entre ingeniería de control, modelado matemático y técnicas de inteligencia artificial, áreas que tradicionalmente han evolucionado por separado en el contexto agrícola. A nivel práctico, los resultados de esta investigación pueden servir como base para el desarrollo de sistemas de riego automatizados más eficientes, escalables y adaptables a diferentes condiciones de suelo.

y clima, favoreciendo la sostenibilidad de la producción agrícola nacional.

4. Objetivos

4.1. Objetivo general

Desarrollar un modelo Grey-Box que combine ecuaciones diferenciales ordinarias (EDO) del balance hídrico del suelo con redes neuronales artificiales, con el fin de implementar un esquema de control predictivo basado en modelo (MPC) para optimizar la aplicación de riego en el cultivo de papa en Colombia.

4.2. Objetivos específicos

1. Analizar antecedentes científicos sobre modelado físico e inteligencia artificial aplicados al control del riego en papa.
2. Formular el modelo físico mediante una EDO representativa del balance hídrico del suelo y definir los parámetros de entrada (I, P, ETc, D y Zr).
3. Entrenar una red neuronal residual que aprenda los errores del modelo físico y permita capturar dinámicas no modeladas.
4. Integrar ambos componentes en una arquitectura Grey-Box e implementar un esquema de control predictivo (MPC) no lineal.
5. Simular y validar el desempeño del modelo mediante métricas estadísticas y análisis comparativo frente a modelos puramente físicos y data-driven.
6. Documentar el proceso, los resultados y la aplicabilidad del modelo como herramienta para la gestión inteligente del riego agrícola.

5. Marco referencial

5.1. Marco teórico

5.1.1. Sistemas dinámicos en agricultura

Los cultivos agrícolas pueden representarse como sistemas dinámicos no lineales, ya que su comportamiento depende de múltiples variables que evolucionan con el tiempo, como la humedad del suelo, la temperatura, la radiación solar, los nutrientes y las prácticas de manejo. Estas variables están interrelacionadas y presentan retroalimentación continua, lo que genera respuestas complejas ante pequeñas variaciones en las condiciones iniciales o ambientales.

Debido a esta naturaleza dinámica y multivariable, el modelado de los procesos agrícolas no puede abordarse mediante relaciones estáticas o lineales simples. En este contexto, los modelos basados en ecuaciones diferenciales ordinarias (EDO) se han utilizado ampliamente para representar la evolución temporal de variables de interés.

Pelak, Revelli y Porporato (2017) propusieron un modelo dinámico determinista que describe la interacción entre la cobertura del dosel (C), la humedad del suelo (S) y el nitrógeno disponible (N), mostrando que estas ecuaciones pueden emplearse para simular estrategias de riego y fertilización bajo incertidumbre climática. Este tipo de formulaciones ofrece una base física sólida sobre la cual diseñar estrategias de control automatizado.

5.1.2. Redes neuronales aplicadas al control de sistemas agrícolas

El control en agricultura de precisión tiene como objetivo mantener condiciones óptimas de cultivo mediante la regulación automática de factores como la humedad del suelo, la temperatura o la disponibilidad de nutrientes. A diferencia de los métodos tradicionales, que operan con umbrales fijos o decisiones manuales, los enfoques modernos buscan diseñar

sistemas adaptativos, capaces de responder dinámicamente a los cambios en el entorno y a las necesidades fisiológicas del cultivo.

En este contexto, las redes neuronales artificiales (RNA) se han consolidado como una herramienta poderosa para modelar y controlar sistemas no lineales. El teorema de aproximación universal (14) establece que una red neuronal de tipo *feedforward* puede aproximar cualquier función continua con suficiente número de neuronas y capas ocultas, lo que las convierte en aproximadores universales capaces de capturar relaciones complejas entre variables de entrada y salida.

Dentro del ámbito agrícola, las RNA se han utilizado para modelar procesos físicos y fisiológicos del cultivo, así como para el diseño de controladores inteligentes. Las arquitecturas recurrentes, como NARX, LSTM o GRU, son particularmente útiles para representar la dependencia temporal de las variables del sistema, permitiendo predecir y corregir el comportamiento dinámico del suelo y la planta. Brunton y Kutz (2019) destacan que los controladores basados en RNA pueden operar bajo condiciones de alta incertidumbre, adaptándose al entorno sin necesidad de reparametrizar el modelo físico.

Por otro lado, los modelos puramente deterministas, aunque interpretables, suelen requerir gran cantidad de parámetros físicos difíciles de estimar, mientras que los modelos puramente *data-driven* carecen de base física y pueden ser inestables fuera del rango de entrenamiento. La literatura reciente propone una solución intermedia: los modelos híbridos o *grey-box*, que integran ecuaciones diferenciales como estructura base y redes neuronales como mecanismo de corrección o ajuste. Este enfoque, señalado por Bramburger et al. (2020), combina la interpretabilidad de los modelos físicos con la flexibilidad de los métodos de aprendizaje, ofreciendo una alternativa eficaz para el control de sistemas agrícolas complejos.

5.1.3. Comparación entre modelos deterministas y Data-Driven

Los modelos deterministas basados en ecuaciones diferenciales tienen la ventaja de la interpretabilidad: cada variable y parámetro corresponde a un proceso físico (por ejemplo, fotosíntesis o absorción de nutrientes). Sin embargo, requieren conocimiento profundo de los mecanismos internos y calibración constante.

Por otro lado, los modelos basados en RNA son altamente flexibles y pueden aprender

dinámicas a partir de datos experimentales o de sensores sin necesidad de conocer todas las relaciones internas. Su principal limitación es la falta de interpretabilidad y la necesidad de grandes volúmenes de datos.

La literatura actual indica que un enfoque híbrido —usando ecuaciones diferenciales como generadores de datos sintéticos y RNA como aproximadores universales— ofrece un camino prometedor para aplicaciones de control agrícola (11).

5.1.4. Control predictivo basado en modelo (MPC)

El *Model Predictive Control* (MPC) es una técnica avanzada de control automático que optimiza la acción de control a lo largo de un horizonte de tiempo futuro, basándose en un modelo dinámico del proceso.

En cada instante de muestreo, el MPC utiliza el modelo para predecir el comportamiento futuro del sistema, resuelve un problema de optimización que minimiza una función de costo y aplica únicamente la primera acción óptima, repitiendo el proceso en la siguiente iteración.

Matemáticamente, el MPC resuelve en cada paso un problema de la forma:

$$\min_{u(k)} \sum_{k=1}^{N_p} (y_{ref}(k) - y(k))^2 + \lambda \sum_{k=1}^{N_c} \Delta u(k)^2$$

donde:

- $y(k)$ es la variable de salida o controlada,
- $u(k)$ es la variable manipulada o acción de control,
- N_p y N_c son los horizontes de predicción y control respectivamente,
- λ pondera la variación de la señal de control.

El MPC es ampliamente utilizado en procesos industriales y agrícolas porque maneja restricciones explícitas y puede incorporar modelos no lineales o híbridos. Cuando el modelo es lineal se denomina MPC lineal (LMPC); en sistemas con comportamientos no lineales, como el flujo de agua en el suelo, se emplea la versión no lineal (NMPC) o la linealización sucesiva, según los requerimientos computacionales.

5.1.5. Arquitectura general del sistema de control




Figura 5.1: Arquitectura general del sistema de control predictivo propuesto.

5.1.6. Sistemas no lineales y modelos de proceso

En agricultura, la humedad del suelo, la evapotranspiración y la infiltración presentan comportamientos altamente no lineales. Por ello, el desempeño del MPC depende fuertemente de la calidad del modelo que describe el proceso.

Entre los modelos más comunes se encuentran:

- **ARX/ARMAX (lineales):** expresan la salida como una combinación lineal de entradas y retardos; son simples pero limitados ante no linealidades.
- **Modelos físicos (EDO):** se basan en ecuaciones de balance de masa, como las derivadas del balance hídrico en la zona radicular o de la ecuación de Richards.
- **Modelos puramente data-driven (RNA, NARX, LSTM):** aprenden la relación entrada-salida directamente de los datos, aunque pierden interpretabilidad física.
- **Modelos híbridos o grey-box:** combinan la formulación física con una corrección aprendida mediante inteligencia artificial, permitiendo representar tanto la base científica como las dinámicas no modeladas.

5.1.7. Modelo Grey-Box basado en EDO y red neuronal

El modelo *grey-box* representa el punto intermedio entre los enfoques físico y puramente empírico. Su estructura se compone de una ecuación diferencial ordinaria (EDO) que modela el balance hídrico y de una red neuronal residual que aprende los errores del modelo físico.

La EDO describe la variación temporal de la humedad volumétrica del suelo $\theta(t)$:

$$\frac{d\theta}{dt} = \frac{1}{Z_r} [I(t) + P(t) - ET_c(t, \theta) - D(t, \theta)]$$

donde:

- $\theta(t)$: humedad del suelo (variable de estado y salida Y),
- $I(t)$: riego aplicado (entrada de control U),
- $P(t)$: precipitación,
- $ET_c(t, \theta)$: evapotranspiración del cultivo,
- $D(t, \theta)$: drenaje profundo,
- Z_r : profundidad efectiva de raíces.

El componente neuronal se agrega como una corrección residual:

$$\theta_{pred}(t) = \theta_{EDO}(t) + f_{NN}(x(t))$$

donde $f_{NN}(x(t))$ aprende patrones no representados por la ecuación física, como variaciones locales del suelo, microclima o errores de medición. Esta combinación ofrece un modelo explicable, adaptable y preciso, adecuado para control predictivo no lineal (NMPC), ya que permite linealización local o uso directo en optimización no lineal.

5.1.8. Fundamento físico: balance hídrico y FAO-56

El modelo se apoya en el principio de conservación de masa del agua en la zona radicular, expresado como:

$$\frac{dW}{dt} = I + P - ET - D$$

Dividiendo entre la profundidad efectiva de raíces Z_r se obtiene la ecuación para la humedad volumétrica.

El cálculo de la evapotranspiración del cultivo (ET_c) se realiza siguiendo la metodología FAO-56 (21), que utiliza el coeficiente dual de cultivo (K_c) y la evapotranspiración de referencia (ET_0):

$$ET_c = (K_{cb}K_s + K_e) \cdot ET_0$$

Este marco teórico, validado en la literatura agrícola e implementado en herramientas como `pyfao56` (23), garantiza que el modelo conserve coherencia física y compatibilidad con datos medidos de campo.

5.2. Marco conceptual

Para este proyecto, se consideran algunos conceptos fundamentales:

- **Papa:** cultivo de gran importancia económica y social en Colombia, sensible a factores climáticos y de manejo agrícola.
- **Sistema dinámico:** conjunto de variables interrelacionadas cuya evolución se describe en función del tiempo, susceptible de modelarse mediante ecuaciones diferenciales.
- **Red neuronal artificial:** modelo computacional inspirado en el cerebro humano, capaz de aprender relaciones no lineales a partir de datos de entrada y salida.
- **Control agrícola:** acción de regular variables críticas del cultivo (por ejemplo, humedad y nutrientes) para mantener condiciones óptimas de crecimiento.
- **Humedad del suelo (θ):** proporción de agua en el volumen de suelo dentro de la zona de raíces. Es la variable controlada por el sistema.

- **Zona radicular (Z_r):** profundidad efectiva del suelo donde las raíces extraen agua; define el volumen del balance hídrico.
- **Riego (I):** entrada de agua controlable aplicada al cultivo mediante el actuador; representa la variable manipulada u .
- **Evapotranspiración (ET_c):** pérdida combinada de agua por evaporación y transpiración; salida natural del sistema modelada mediante el método FAO-56.
- **Drenaje (D):** flujo de agua que percola fuera de la zona radicular; depende de las condiciones del suelo y de la humedad actual.
- **Modelo Grey-Box:** modelo híbrido que combina una ecuación física (EDO) con una red neuronal residual para mejorar la precisión y adaptabilidad.
- **Modelo Predictivo Basado en Modelo (MPC):** estrategia de control que predice el comportamiento del sistema y optimiza la acción de riego dentro de un horizonte de tiempo, respetando restricciones.
- **Horizonte de Predicción (N_p):** cantidad de pasos futuros que el MPC usa para prever la evolución de la humedad del suelo.
- **Horizonte de Control (N_c):** cantidad de acciones de riego consecutivas que el MPC optimiza en cada iteración.
- **Control No Lineal (NMPC):** versión del MPC que opera directamente sobre modelos no lineales, como el *grey-box* propuesto, utilizando optimización iterativa.

5.3. Antecedentes

El estudio de la dinámica de humedad en el suelo y su relación con el crecimiento del cultivo de papa ha sido ampliamente abordado en la literatura reciente, destacando la importancia de comprender la profundidad efectiva de raíces, la eficiencia en el uso del agua y la absorción de nutrientes. Estos aspectos constituyen la base conceptual del modelo **Grey-Box**

propuesto en el presente trabajo, el cual busca representar el comportamiento del sistema *suelo-planta-agua* mediante ecuaciones diferenciales ordinarias y redes neuronales, integrando conocimiento físico con aprendizaje basado en datos.

En primer lugar, **Kautz y Hoffmann (2024)** realizaron un análisis detallado sobre la profundidad de enraizamiento en distintas variedades de papa mediante el uso de tubos minirhizotróf. Los resultados mostraron que algunas especies pueden alcanzar profundidades de hasta 1.8 m, lo cual demuestra la alta capacidad de la papa para explorar estratos profundos del suelo y acceder a reservas de agua y nitrógeno. Este hallazgo resulta fundamental al definir el parámetro de *profundidad efectiva de raíces* (Z_r) dentro del modelo físico planteado.

De forma complementaria, **Ahmad y Hanjra (2019)** estudiaron la dinámica del agua en el suelo y la zona efectiva de raíces en cultivos de papa bajo riego por aspersión en suelos arenoso-limosos, encontrando que aproximadamente el 85 % del agua extraída por las raíces proviene de los primeros 40 cm del suelo, lo cual establece un valor de $Z_r \approx 0,4$ m representativo para este tipo de suelos. Esta información es clave para parametrizar el modelo diferencial que describe el flujo de agua en el perfil del suelo y estimar la humedad disponible para la planta.

Asimismo, **Chen, Li y Wang (2022)** propusieron un enfoque de manejo del riego basado en la distribución dinámica de las raíces, demostrando que adaptar la frecuencia y el volumen de riego a dicha distribución mejora significativamente el rendimiento y la eficiencia en el uso del agua y el nitrógeno. Este enfoque se alinea directamente con los objetivos del modelo Grey-Box, que busca implementar un esquema de **control predictivo (MPC)** para optimizar la aplicación del riego en función de la humedad del suelo.

Por otra parte, un estudio reciente publicado en *Potato Research* (2024) en China aplicó **redes neuronales artificiales optimizadas** para la predicción del rendimiento de papa. Los autores desarrollaron un modelo basado en una red neuronal de retropropagación (BP) mejorada mediante el *Whale Optimization Algorithm (WOA)*, incorporando variables climáticas, hidro-térmicas y del suelo recolectadas entre 2010 y 2022. El modelo mostró un desempeño superior frente a enfoques tradicionales, mejorando la capacidad de generalización y reduciendo los errores de predicción. Este antecedente es relevante porque demuestra cómo la integración de técnicas de optimización y redes neuronales puede potenciar el mode-

lado de procesos complejos en el cultivo de papa, abriendo la posibilidad de aplicar enfoques similares para el control predictivo de variables críticas más allá de la simple predicción.

De manera complementaria, **van Voorn et al. (2023)** propusieron un marco conceptual para el modelado dinámico de fenotipos dependientes del tiempo, considerando la interacción entre genotipo, ambiente y manejo agrícola. Los autores desarrollaron una biblioteca de modelos fenomenológicos de complejidad limitada basados en ecuaciones diferenciales ordinarias, con el fin de describir la evolución de rasgos fenotípicos a lo largo del ciclo de cultivo. Este antecedente demuestra que, incluso con modelos deterministas relativamente simples, es posible capturar las dinámicas de crecimiento vegetal bajo diversas condiciones ambientales, constituyendo una base sólida para el diseño de un modelo determinista aplicable al control de variables críticas en papa.

Desde una perspectiva regional, **Marcillo-Pagay et al. (2022)** realizaron un estudio en el departamento de Nariño (Colombia) sobre las respuestas agronómicas y económicas de la papa (*Solanum tuberosum* subsp. *andigena*) bajo diferentes dosis de fertilización en cuatro ambientes contrastantes. Los resultados mostraron que la productividad y la rentabilidad del cultivo dependen de la interacción entre variedad, tipo de suelo, condiciones climáticas y nivel de fertilización. Este antecedente es especialmente relevante por su carácter local, ya que resalta la necesidad de diseñar sistemas de control adaptativos que integren tanto la fertilización como las condiciones ambientales para optimizar la producción de papa en Colombia.

En cuanto al modelado físico del movimiento del agua en el suelo, **Ireson, Spiteri, Clark y Mathias (2023)** desarrollaron un método conservativo y eficiente para resolver la ecuación de Richards, implementado en la herramienta de código abierto *openRE*. Este modelo permite describir con gran detalle la dinámica del agua en el suelo, considerando propiedades hidráulicas no lineales y la extracción de agua por las raíces. Si bien representa un referente físico robusto, su complejidad computacional limita su aplicación directa en esquemas de control en tiempo real, por lo que suele emplearse como modelo de referencia frente a aproximaciones más simplificadas.

En contraste, **Thorp (2022)** presentó la librería *pyFAO56*, una implementación en Python del método FAO-56 para la estimación de la evapotranspiración del cultivo (ETc) mediante

el coeficiente dual (K_c). Este enfoque permite calcular el consumo de agua y la depleción hídrica en la zona radicular a partir de datos climáticos y parámetros de cultivo, facilitando la programación de riego con menor complejidad que los modelos derivados de la ecuación de Richards. Su practicidad lo convierte en una herramienta valiosa para integrar balances hídricos en esquemas de gestión y control predictivo de riego.

En el ámbito del análisis de incertidumbre, **Mondaca-Duarte, Heinen y van Mourik (2020)** propusieron un marco metodológico para evaluar la incertidumbre en estrategias de riego basadas en modelos. Su estudio integró el modelo EMMAN3G, fundamentado en la ecuación de Richards, y el modelo de evapotranspiración de De Graaf, implementados en **MATLAB** con análisis Monte Carlo. Este enfoque permite cuantificar cómo la variabilidad en parámetros del suelo y en la estimación de la evapotranspiración influye en el drenaje y el estrés hídrico, contribuyendo al diseño de estrategias de riego más robustas frente a la variabilidad climática.

Asimismo, **Shang, You y Chen (2018)** propusieron un enfoque de control predictivo robusto basado en datos para la gestión del riego, combinando la flexibilidad de los modelos *data-driven* con la estructura del MPC. Sus resultados evidenciaron que esta integración reduce significativamente el consumo de agua y mantiene la humedad del suelo en niveles adecuados, consolidándose como una alternativa viable a los modelos puramente físicos. En esta misma línea, **Abioye et al. (2023)** aplicaron un esquema de *control predictivo basado en modelos (MPC)* al riego por goteo en invernaderos, integrando sensores IoT y procesamiento de imágenes para estimar variables como ET_c y K_c . El modelo fue implementado en **MATLAB** y ejecutado en una *Raspberry Pi* para control en tiempo real, logrando una mayor eficiencia en el uso del agua y mejoras en la calidad del fruto en comparación con métodos tradicionales.

Finalmente, **Rossini y Patrignani (2021)** desarrollaron un método alternativo para estimar la humedad del suelo en la zona radicular a partir de mediciones superficiales, utilizando un *filtro exponencial* como aproximación simplificada al balance hídrico. El estudio, realizado en campos agrícolas de Kansas, mostró que el filtro exponencial predice con buena precisión el almacenamiento de agua en el perfil del suelo completo, con un error medio de 11 mm y coeficientes de Nash–Sutcliffe de hasta 0.84. Esta aproximación presenta venta-

jas prácticas frente a la instalación de múltiples sensores, aunque requiere ajustes según las características hidráulicas del sitio.

En conjunto, estos antecedentes evidencian una tendencia creciente hacia la integración de **modelos híbridos**, que combinan el conocimiento físico de los procesos de transporte de agua en el suelo con el aprendizaje automático de las redes neuronales. Esto permite construir modelos más adaptativos y precisos para representar la dinámica hídrica del suelo y su interacción con el cultivo. Por tanto, los estudios revisados constituyen una base sólida para la implementación del modelo Grey-Box propuesto, que busca optimizar el control del riego en el cultivo de papa mediante la unión del modelado diferencial y el aprendizaje basado en datos.

6. Metodología

El estudio sigue un enfoque mixto (físico-computacional), dividido en cinco fases principales:

6.0.1. Revisión bibliográfica y fundamentación

- Análisis de literatura reciente sobre la dinámica de la humedad del suelo, control predictivo, ecuaciones de balance hídrico (FAO-56, Richards) y redes neuronales aplicadas a la agricultura.
- Revisión de estudios previos sobre la predicción del rendimiento y el control de humedad en el cultivo de papa.

6.0.2. Formulación del modelo físico (EDO)

Se implementará la ecuación diferencial del balance hídrico del suelo, expresada como:

$$\frac{d\theta}{dt} = \frac{1}{Z_r} [I(t) + P(t) - ET_c(t, \theta) - D(t, \theta)] \quad (6.1)$$

donde θ representa la humedad volumétrica del suelo, Z_r la profundidad efectiva de la zona radicular, $I(t)$ el riego aplicado, $P(t)$ la precipitación, $ET_c(t, \theta)$ la evapotranspiración de cultivo y $D(t, \theta)$ el drenaje. Los parámetros físicos serán estimados a partir de literatura técnica, por ejemplo, una profundidad radicular de $Z_r \approx 0,4m$ según Ahmad & Hanjra (2019).

6.0.3. Diseño e integración de la red neuronal

- Se entrenará una red neuronal residual $f_{NN}(x(t))$ para ajustar las discrepancias entre el modelo físico y los datos experimentales o sintéticos.
- El modelo híbrido resultante (Grey-Box) se expresará como:

$$\theta_{pred}(t) = \theta_{EDO}(t) + f_{NN}(x(t)) \quad (6.2)$$

6.0.4. Implementación del control predictivo (MPC)

- Se diseñará un controlador predictivo no lineal (NMPC) basado en el modelo Grey-Box.
- Se realizarán simulaciones en MATLAB/Simulink para optimizar la señal de riego considerando restricciones del sistema y horizontes de predicción definidos.

6.0.5. Validación y análisis de resultados

- Evaluación del desempeño mediante métricas como el error cuadrático medio (RMSE), el coeficiente de determinación (R^2) y el error absoluto medio (MAE).
- Comparación de resultados frente a modelos puramente físicos (Richards, FAO-56) y puramente neuronales (NARX, LSTM).
- Discusión sobre la aplicabilidad del enfoque propuesto en escenarios agrícolas colombianos.

7. Implementación del control predictivo con CasADi

7.1. Implementación del control predictivo basado en modelo (MPC)

Para la implementación del esquema de **Control Predictivo Basado en Modelo (MPC)** se utilizará **CasADi**, una librería de código abierto compatible con **MATLAB**, ampliamente empleada en la formulación y resolución de problemas de optimización no lineal y control dinámico.

CasADi proporciona un marco simbólico eficiente que permite derivar ecuaciones, calcular gradientes y resolver problemas de optimización en tiempo real mediante solvers como **IPOPT** o **ACADO**, los cuales pueden integrarse directamente al entorno de MATLAB.

En este proyecto, CasADi se utilizará para integrar el modelo *Grey-Box* —compuesto por la ecuación diferencial del balance hídrico y la red neuronal de corrección— dentro de un esquema de **Control Predictivo No Lineal (NMPC)**.

Las principales tareas a realizar con esta herramienta serán:

- Formular el modelo dinámico del proceso (EDO + red neuronal) en lenguaje simbólico.
- Definir el horizonte de predicción, la función de costo y las restricciones del sistema (niveles de humedad, caudal máximo de riego, etc.).
- Resolver iterativamente el problema de optimización para determinar la acción de control óptima $U(t)$ que mantenga la humedad $Y(t)$ en su rango deseado.

El uso de CasADi dentro de MATLAB facilita la integración con herramientas de simulación como **Simulink**, permitiendo validar el desempeño del controlador en lazo cerrado y

ajustar parámetros antes de su posible implementación práctica.

7.1.1. Definición del modelo Grey-Box

Primero se representa el modelo físico, correspondiente a la **Ecuación Diferencial Ordinaria (EDO)** del balance hídrico del suelo, junto con la corrección neuronal. En una primera etapa, se probará únicamente la EDO para verificar el correcto funcionamiento del esquema MPC antes de incorporar la red neuronal.

```
import casadi.*

% Parámetros físicos del modelo
Zr = 0.3;      % profundidad efectiva de raíces [m]
K_ET = 0.002;  % coeficiente de evapotranspiración [mm/h]
K_D = 0.001;   % coeficiente de drenaje [mm/h]

% Variables simbólicas
theta = SX.sym('theta'); % humedad del suelo
I = SX.sym('I');          % riego aplicado (entrada de control)
P = SX.sym('P');          % precipitación (disturbio externo)

% Funciones no lineales dependientes de la humedad
ETc = K_ET * theta;       % evapotranspiración proporcional a la humedad
D = K_D * theta^2;        % drenaje cuadrático (flujo no lineal)

% Ecuación diferencial del balance hídrico (modelo físico)
dtheta_dt = (1/Zr)*(I + P - ETc - D);

% Definición del modelo simbólico
f = Function('f', {theta, I, P}, {dtheta_dt});
```

Figura 7.1: Representación del modelo Grey-Box inicial con la ecuación del balance hídrico.

7.1.2. Configuración del problema de MPC

En esta etapa se formula el problema de optimización no lineal (*Nonlinear Programming Problem*, NLP) dentro de CasADi. Se definen los horizontes de predicción y control, la función objetivo y las restricciones operacionales del sistema.

Por simplicidad, se comienza con un horizonte corto de $N = 10$ pasos, lo cual permite realizar pruebas iniciales de desempeño del algoritmo de control.

```

% Horizonte de predicción
N = 10;
dt = 0.1; % paso de tiempo (h)

% Variables simbólicas
U = SX.sym('U', N); % secuencia de riego a optimizar
theta0 = SX.sym('theta0'); % estado inicial

% Inicialización
theta_k = theta0;
cost = 0;

for k = 1:N
    theta_k = theta_k + dt * f(theta_k, U(k)); % integración de Euler
    cost = cost + (theta_k - 0.25)^2 + 0.01*(U(k))^2; % mantener  $\theta \approx 0.25$  y penalizar riego
end

% Definición del problema NLP
nlp = struct('x', U, 'f', cost, 'p', theta0);
solver = nlpsol('solver', 'ipopt', nlp);

```

Figura 7.2: Formulación del problema de optimización del MPC en CasADi.

7.1.3. Simulación del horizonte recedente (Receding Horizon)

Finalmente, se implementa el esquema de horizonte recedente, en el cual el controlador aplica únicamente la primera acción óptima calculada y luego actualiza el estado del sistema antes de volver a resolver el problema de optimización. Este procedimiento permite mantener el control adaptativo ante cambios en las condiciones del entorno o perturbaciones externas.

```

% Estado inicial
theta_actual = 0.2;

for t = 1:30
    sol = solver('x0', 0.001*ones(N,1), 'p', theta_actual);
    U_opt = full(sol.x);
    I_aplicado = U_opt(1);

    % Actualización del estado según el modelo
    theta_actual = full(theta_actual + dt * f(theta_actual, I_aplicado));

    % Mostrar resultado
    fprintf('Paso %d |  $\theta$  = %.3f | Riego aplicado = %.4f\n', t, theta_actual, I_aplicado);
end

```

Figura 7.3: Simulación del esquema de control en horizonte recedente (NMPC).

8. Cronograma

Actividad	Mes 1	Mes 2	Mes 3	Mes 4	Mes 5	Mes 6
Revisión bibliográfica y recopilación de datos	X	X				
Formulación del modelo físico (EDO)		X				
Entrenamiento de la red neuronal y ajuste Grey-Box		X	X			
Diseño e implementación del control predictivo (MPC) en CasADi			X	X		
Validación, simulaciones y comparación de resultados					X	
Redacción, conclusiones y revisión del documento					X	X

Cuadro 8.1: Cronograma de actividades del proyecto.

9. Presupuesto

El desarrollo del proyecto requiere diversos recursos humanos, tecnológicos y materiales, estimados en función de su disponibilidad y costo aproximado. La mayor parte de las herramientas son de carácter académico o de libre acceso, por lo que el presupuesto total se mantiene bajo y viable.

Recursos Humanos

- **Autores del proyecto:** responsables de la búsqueda bibliográfica y de datos, modelado matemático, implementación computacional en **MATLAB/CasADi** y redacción de la monografía.
- **Director de proyecto:** encargado de la orientación académica, revisión técnica del modelo y supervisión de los avances metodológicos.

Estos recursos corresponden a participación académica, sin costo monetario directo.

Recursos Tecnológicos

- **MATLAB (versión académica):** herramienta principal para la simulación numérica, el modelado de ecuaciones diferenciales y la integración del controlador MPC.
- **CasADi (librería open-source):** entorno para la formulación simbólica y la resolución de problemas de optimización no lineal, integrado en MATLAB.
- **Equipo de cómputo:** computador portátil o de escritorio con procesador i7 o superior y mínimo 16 GB de RAM. Se dispone de este recurso sin costo adicional, ya que pertenece a los autores o está disponible en el entorno institucional. Aunque de ser

necesario se dispondrá de \$1,500,000 COP para alquilar un equipo que cumpla las características necesarias.

- **Software de oficina (Microsoft Office / LaTeX):** para la redacción, edición y formato del documento final.

Recursos Materiales y Administrativos

- **Impresiones y encuadernación de la monografía:** \$100,000 COP.
- **Transporte y comunicaciones:** \$50,000 COP (reuniones, desplazamientos o conectividad con el director).
- **Acceso a bibliografía y bases de datos:** gratuito mediante las licencias académicas y bibliotecas digitales de la universidad.

Estimación General

Concepto	Descripción	Costo total (COP)
Equipos de cómputo	Alquiler de computadores.	\$1.500.000
Impresiones y encuadernado de la monografía	Reproducción y presentación física del documento final.	\$100.000
Transporte y comunicaciones	Gastos de transporte y conectividad para reuniones académicas con el director y asesorías.	\$50.000
Otros gastos	Gastos imprevistos.	\$2.000.000
Total		\$3.650.000

Cuadro 9.1: Gastos generales incluidos en el desarrollo del proyecto.

10. Resultados e impacto esperado

Se espera obtener un **modelo híbrido Grey-Box** implementado en **MATLAB**, que combine una ecuación diferencial del balance hídrico del suelo con una red neuronal de corrección, capaz de representar adecuadamente la dinámica de la humedad en la zona radicular del cultivo de papa.

Este modelo será integrado dentro de un esquema de **Control Predictivo No Lineal (NMPC)** utilizando **CasADi**, con el objetivo de mantener la humedad del suelo dentro de rangos óptimos y minimizar el consumo de agua.

Resultados Esperados

- Formulación completa del modelo matemático y su validación mediante simulaciones.
- Implementación del controlador predictivo y evaluación bajo distintas condiciones de riego y clima.
- Análisis de desempeño mediante métricas como el *error cuadrático medio (ECM)*, ahorro de agua y estabilidad del sistema.
- Documentación técnica y monografía con los hallazgos, metodología y recomendaciones.

Impacto Esperado

El impacto esperado se proyecta en tres dimensiones:

- **Tecnológica:** fomentar el uso de controladores predictivos avanzados en agricultura de precisión, promoviendo prácticas de riego más eficientes y sostenibles.

- **Académica:** contribuir al desarrollo de metodologías que integran modelado físico, inteligencia artificial y control automatizado, fortaleciendo líneas de investigación en ingeniería de sistemas y control.
- **Social y ambiental:** apoyar el manejo responsable del recurso hídrico en zonas rurales y optimizar la productividad de los cultivos de papa, reduciendo pérdidas asociadas al riego ineficiente.

11. Referencias

beginthebibliography99

Abrougui, K., Gabsi, K., Mercatoris, B., Khemis, C., Amami, R., & Chehaibi, S. (2019). *Prediction of organic potato yield using tillage systems and soil properties by artificial neural network (ANN) and multiple linear regressions (MLR)*. *Soil and Tillage Research*, 190, 202–208. <https://doi.org/10.1016/j.still.2019.01.011>

Garg, B., Aggarwal, S., & Sokhal, J. (2018). *Crop yield forecasting using fuzzy logic and regression model*. *Computers & Electrical Engineering*, 67, 383–403. <https://doi.org/10.1016/j.compeleceng.2017.0>

Hernández, N., Soto, F., & Caballero, A. (2009). *Modelos de simulación de cultivos: Características y usos*. *Cultivos Tropicales*, 30(1), 1–10. [http://scielo.sld.cu/scielo.php?script=sci_arttext&pid = S0258 – 59362009000100014](http://scielo.sld.cu/scielo.php?script=sci_arttext&pid=S0258-59362009000100014)

Jayaram, M. A., & Marad, N. (2013). *Fuzzy inference systems for crop yield prediction*. *Journal of Intelligent Systems*, 21(4), 363–372. <https://doi.org/10.1515/jisys-2012-0016>

Khaki, S., & Wang, L. (2019). *Crop yield prediction using deep neural networks*. *Frontiers in Plant Science*, 10, 621. <https://doi.org/10.3389/fpls.2019.00621>

López Seijas, T., Cabrera Pérez, J., Hernández, A., & Arias, M. (2010). *Adecuación de un modelo de simulación de cultivo para la predicción del crecimiento y producción del arroz en el sur de La Habana*. *Revista Ciencias Técnicas Agropecuarias*, 19(1), 90–95. [http://scielo.sld.cu/scielo.php?script S0258 – 59362010000100014](http://scielo.sld.cu/scielo.php?script=sci_arttext&pid=S0258-59362010000100014)

Pascual, I. de los A., Ramírez, J. L., & Ortiz, A. (2016). *Métodos de inteligencia artificial para la predicción del rendimiento y calidad de gramíneas*. *REDVET. Revista Electrónica de Veterinaria*, 17(12), 1–9. <http://www.redalyc.org/articulo.oa?id=63649052026>

- Rashid, M., Bari, B., Yusup, Y., Kamaruddin, M., & Khan, N. (2021). *A comprehensive review of crop yield prediction using machine learning approaches with special emphasis on palm oil yield prediction. IEEE Access*, 9, 72390–72410. <https://doi.org/10.1109/ACCESS.2021.3075159>
- Servín Palestina, M., Salazar, R., López-Cruz, I., Medina-García, G., & Cid-Ríos, J. (2022). *Predicción de la producción y rendimiento de frijol con modelos de redes neuronales artificiales y datos climáticos. Biotecnia*, 24(2), 104–111. <https://doi.org/10.18633/biotecnia.v24i2.1664>
- Stathakis, D., Savin, I., & T., A. (2006). *Neuro-fuzzy modeling for crop yield prediction. Environmental Modelling & Software*, 21(10), 1432–1440. <https://doi.org/10.1016/j.envsoft.2005.07.013>
- Bramburger, J. J., et al. (2020). *Learning dynamics with recurrent neural networks*.
- Brunton, S. L., & Kutz, J. N. (2019). *Data-Driven Science and Engineering*. Cambridge University Press.
- Pelak, N., Revelli, R., & Porporato, A. (2017). *A dynamical systems framework for crop models*. <https://doi.org/10.1016/j.ecolmodel.2017.10.003>
- Hornik, K. (1991). *Approximation capabilities of multilayer feedforward networks. Neural Networks*, 4(2), 251–257. [https://doi.org/10.1016/0893-6080\(91\)90009-T](https://doi.org/10.1016/0893-6080(91)90009-T)
- Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press.
- Potato Research. (2024). *Potato yield prediction research based on improved artificial neural networks using Whale Optimization Algorithm*. European Association for Potato Research. <https://www.eapr.net/publications/potato-research/potato-yield-prediction-research-based-improved-artificial-neural>
- van Voorn, G. A. K., Boer, M. P., Truong, S. H., Friedenberg, N. A., Gugushvili, S., McCormick, R., Bustos Korts, D., Messina, C. D., & van Eeuwijk, F. (2023). *A conceptual framework for the dynamic modeling of time-resolved phenotypes for sets of genotype-environment-management combinations: A model library. Frontiers in Plant Science*, 14, 1172359. <https://doi.org/10.3389>
- Marcillo-Paguay, C. A., Benavides-Cardona, C. A., Ramos-Zambrano, H. S., & Romero, J. V. (2022). *Respuesta agronómica y económica de papa (Solanum tuberosum subsp. andigena) a la fertilización diferencial en cuatro ambientes de Nariño, Colombia. Revista Colombiana de Ciencias Hortícolas*, 16(2), e13559. <https://doi.org/10.17584/rcch.2022v16i2.13559>

Kautz, T., & Hoffmann, H. (2024). *Deep Rooting as an Indicator of Deep Soil Water and N Uptake in Potato*. *Potato Research*. Springer. <https://link.springer.com/article/10.1007/s11540-024-09802-4>

Chen, X., Li, Z., & Wang, J. (2022). *Improving Potato Yield, Water Productivity and Nitrogen Use Efficiency by Managing Irrigation Based on Potato Root Distribution*. *International Journal of Plant Production*. Springer. <https://link.springer.com/article/10.1007/s42106-022-00205-4>

Allen, R. G., Pereira, L. S., Raes, D., & Smith, M. (2006). *Evapotranspiración del cultivo: Guías para la determinación de los requerimientos de agua de los cultivos*. FAO. <https://openknowledge.fao.org/>

Ireson, A. M., Spiteri, R. J., Clark, M. P., & Mathias, S. A. (2023). *A simple, efficient, mass-conservative approach to solving Richards' equation (openRE, v1.0)*. *Geoscientific Model Development*. <https://doi.org/10.5194/gmd-16-659-2023>

Thorp, K. R., et al. (2022). *pyfao56: FAO-56 evapotranspiration in Python*. <https://doi.org/10.1016/j.softx.2022.101075>

Mondaca-Duarte, F. D., et al. (2020). *Performance analysis method for model-based irrigation — Richards + ET in MATLAB*. <https://doi.org/10.1016/j.mex.2020.101075>

Shang, C., et al. (2019). *Robust Model Predictive Control of Irrigation Systems with Active Uncertainty Learning and Data Analytics*. arXiv. <https://doi.org/10.48550/arXiv.1810.05947>

Rossini, L., et al. (2021). *Predicting rootzone soil moisture from surface observations*. <https://dx.doi.org/10.1016/j.agrso.2021.101075>